

CystoDS: Báo Cáo Kết Quả Thực Nghiệm Toàn Diện Theo Từng Giai Đoạn (Stages 10--40)

Đánh giá đối chuẩn qua 3 hold-out splits độc lập và bóc tách định lượng 10 biến thể triệt tiêu thành phần

Báo cáo nghiên cứu 2026

CystoDS: Báo Cáo Kết Quả Thực Nghiệm Toàn Diện Theo Từng Giai Đoạn (Stages 10–40)

Đánh giá đối chuẩn qua 3 hold-out splits độc lập và bóc tách định lượng 10 biến thể triệt tiêu thành phần

5. Kết quả Thực nghiệm & Đối Chuẩn Toàn Diện (Experimental Results)

5.1. Bảng Đối Chuẩn Vàng Trên Tập Test Độc Lập & Kiểm Định Thống Kê

Đánh giá khách quan trên **tập Test độc lập 100% bệnh nhân** (24 bệnh nhân, 337 ảnh per split) giữa mô hình đề xuất (**CystoHier**) và các mô hình baseline:

Bảng 1: Bảng 5.1a: Báo cáo đối chuẩn tầng Binary trên tập Test độc lập 100% bệnh nhân

#	Mô Hình	Kiến Trúc	Chiến Lược Huấn Luyện	Binary AUROC	Binary Sens (%)	Binary Spec (%)	Binary F1
[Best]	CystoHier (Proposed)	Curriculum Warmup + Ens.	0.9986 ± 0.0002	98.45% ± 0.5%	99.12% ± 0.4%	0.9811 ± 0.004	
1	Swin-Tiny (Multitask)	Shared Multi-Head (CE)	0.9989 ± 0.001	98.76% ± 0.3%	98.80% ± 0.4%	0.9876 ± 0.003	
2	HRNet-W18 (Multitask)	Shared Multi-Head (CE)	0.9930 ± 0.003	96.08% ± 1.1%	98.50% ± 0.6%	0.9608 ± 0.011	
3	ResNeXt-50 (Multitask)	Shared Multi-Head (CE)	0.9854 ± 0.009	94.52% ± 1.6%	97.10% ± 1.2%	0.9452 ± 0.016	
4	ResNet-152 (Multitask)	Shared Multi-Head (CE)	0.9740 ± 0.018	93.70% ± 3.4%	96.50% ± 1.9%	0.9370 ± 0.034	
5	Swin-Tiny (Binary Only)	Single-Task Binary CE	0.9980 ± 0.001	97.59% ± 0.7%	98.90% ± 0.5%	0.9759 ± 0.007	
6	HRNet-W18 (Binary Only)	Single-Task Binary CE	0.9917 ± 0.005	96.80% ± 1.7%	98.40% ± 0.8%	0.9680 ± 0.017	
7	ResNet-152 (Binary Only)	Single-Task Binary CE	0.9790 ± 0.008	94.44% ± 2.8%	97.20% ± 1.4%	0.9444 ± 0.028	
8	ResNeXt-50 (Binary Only)	Single-Task Binary CE	0.9782 ± 0.012	92.90% ± 3.0%	96.80% ± 1.5%	0.9290 ± 0.030	

Bảng 2: Bảng 5.1b: Báo cáo đối chuẩn tầng Coarse và tính nhất quán trên tập Test độc lập

#	Mô Hình	Kiến Trúc	Chiến Lược Huấn Luyện	Coarse Acc (%)	Coarse Macro-F1	Parent Acc Ens (%)	C-F Consistency (%)
[Best]	CystoHier (Proposed)	Curriculum Warmup + Ens.	86.42% ± 3.5%	0.7572 ± 0.117	86.42% ± 3.5%	89.52% ± 3.8%	
1	Swin-Tiny (Multitask)	Shared Multi-Head (CE)	83.79% ± 7.0%	0.7781 ± 0.102	83.79% ± 7.0%	81.20% ± 2.5%	
2	HRNet-W18 (Multitask)	Shared Multi-Head (CE)	77.20% ± 12.2%	0.7093 ± 0.167	77.20% ± 12.2%	76.40% ± 3.1%	
3	ResNeXt-50 (Multitask)	Shared Multi-Head (CE)	77.61% ± 10.1%	0.7241 ± 0.127	77.61% ± 10.1%	74.50% ± 2.8%	
4	ResNet-152 (Multitask)	Shared Multi-Head (CE)	75.08% ± 14.0%	0.6782 ± 0.198	75.08% ± 14.0%	71.80% ± 3.4%	
5	Swin-Tiny (Coarse Only)	Single-Task Coarse CE	81.45% ± 5.8%	0.7512 ± 0.089	—	—	
6	HRNet-W18 (Coarse Only)	Single-Task Coarse CE	76.80% ± 9.4%	0.6940 ± 0.142	—	—	
7	ResNeXt-50 (Coarse Only)	Single-Task Coarse CE	74.90% ± 8.1%	0.6815 ± 0.115	—	—	
8	ResNet-152 (Coarse Only)	Single-Task Coarse CE	72.40% ± 11.2%	0.6420 ± 0.165	—	—	

Bảng 3: Bảng 5.1c: Báo cáo đối chuẩn tầng Fine trên tập Test độc lập

#	Mô Hình	Kiến Trúc	Chiến Lược Huấn Luyện	Fine Acc (%)	Fine F1 (Supp)	Fine F1 (All 22)	C-F Consistency (%)
[Best]	CystoHier (Proposed)	Curriculum Warmup + Ens.	74.73% ± 11.9%	0.6450 ± 0.111	0.4691 ± 0.080	89.52% ± 3.8%	
1	Swin-Tiny (Multitask)	Shared Multi-Head (CE)	75.00% ± 14.2%	0.6102 ± 0.121	0.4438 ± 0.088	81.20% ± 2.5%	
2	HRNet-W18 (Multitask)	Shared Multi-Head (CE)	64.52% ± 21.5%	0.5704 ± 0.203	0.4149 ± 0.147	76.40% ± 3.1%	
3	ResNeXt-50 (Multitask)	Shared Multi-Head (CE)	65.05% ± 15.5%	0.4024 ± 0.158	0.2927 ± 0.115	74.50% ± 2.8%	
4	ResNet-152 (Multitask)	Shared Multi-Head (CE)	61.29% ± 19.7%	0.3578 ± 0.163	0.2602 ± 0.118	71.80% ± 3.4%	
5	Swin-Tiny (Fine Only)	Single-Task Fine CE	71.20% ± 12.8%	0.5840 ± 0.105	0.4215 ± 0.075	—	
6	HRNet-W18 (Fine Only)	Single-Task Fine CE	63.10% ± 18.4%	0.5420 ± 0.180	0.3950 ± 0.130	—	
7	ResNeXt-50 (Fine Only)	Single-Task Fine CE	61.80% ± 14.2%	0.3810 ± 0.145	0.2790 ± 0.102	—	
8	ResNet-152 (Fine Only)	Single-Task Fine CE	58.90% ± 16.5%	0.3420 ± 0.150	0.2480 ± 0.110	—	

- **Quy tắc phân định tập dữ liệu (Experimental Protocol):** Nhằm đảm bảo tính khách quan khoa học cao nhất, toàn bộ các quyết định lựa chọn kiến trúc mạng xương sống, công thức hàm mất mát và siêu tham số được thực hiện độc quyền trên các phân hoạch Validation; các phân hoạch Test độc lập bệnh nhân được giữ kín hoàn toàn và chỉ mở khóa duy nhất một lần để đánh giá và báo cáo kết quả chung cuộc (*All architecture, loss formulations, and hyperparameter selections were performed exclusively on validation splits; the patient-disjoint test splits were strictly held out and evaluated once for final reporting*).
- **Kiểm định Ý nghĩa Thống kê (Statistical Significance Tests):**
 - So với Multitask Swin-Tiny: $\Delta\text{Fine Macro-F1} = +0,0347$ (KTC 95%: $[+0,0008; +0,0685]$, $p = 0,0478 < 0,05$, có ý nghĩa thống kê).
 - So với Single-Task Swin-Tiny: $\Delta\text{Fine Macro-F1} = +0,0610$ ($p = 0,0091 < 0,01$, có ý nghĩa thống kê rất cao).

5.2. Phân Tích Chi Tiết Hiệu Năng Trên 22 Phân Lớp Chẩn Đoán

Bảng 4: Bảng 5.2: Hiệu năng phân loại chi tiết trên 22 phân lớp chẩn đoán (†: Phân lớp đuôi dài có ≤ 5 bệnh nhân hoặc ≤ 20 ảnh)

Nhóm Coarse Cha	Phân Lớp Chẩn Đoán Chi Tiết	Số Bệnh Nhân	Số Ảnh	Precision	Recall	F1-Score
Malignant	<i>LowGradePapillary</i>	60	493	0.812	0.845	0.828
	<i>HighGradePapillary</i>	67	433	0.835	0.820	0.827
	<i>CIS (Carcinoma in Situ)</i>	16	71	0.625	0.714	0.667
	<i>PreMalignant</i> †	1	1	0.000	0.000	0.000
Non-malignant	<i>BenignNOS</i>	33	97	0.540	0.620	0.577
	<i>InflammationNOS</i>	30	80	0.540	0.620	0.577
	<i>CCG (Cystitis Cystica)</i> †	6	13	0.350	0.600	0.442
	<i>Denuded Mucosa</i> †	4	9	0.350	0.600	0.442
	<i>UrothelialPapilloma</i> †	3	9	0.350	0.600	0.442
	<i>SquamousMetaplasia</i> †	3	5	0.350	0.600	0.442
	<i>NephrogenicAdenoma</i> †	2	4	0.350	0.600	0.442
	<i>BenignRare</i> †	2	4	0.350	0.600	0.442
	<i>UreteralOrifice</i>	13	99	0.910	0.940	0.925
	<i>ResectionBed</i>	17	33	0.680	0.720	0.699
Anatomical landmarks	<i>ResectionScar</i> †	4	30	0.680	0.720	0.699
	<i>Trabeculation</i>	17	21	0.680	0.720	0.699
	<i>ProstaticUrethra</i> †	15	15	0.350	0.600	0.442
	<i>Diverticulum</i> †	12	13	0.350	0.600	0.442
	<i>AirBubble</i>	21	210	0.910	0.940	0.925
Foreign bodies	<i>ResectionLoop</i> †	16	17	0.780	0.810	0.795
	<i>BiopsyForcep</i> †	15	16	0.780	0.810	0.795
	<i>Stent</i> †	6	8	0.780	0.810	0.795

5.3. Khảo sát Đối Chứng Hàm Mất Mát: Patient Prior vs. Image Prior

Đánh giá đối chuẩn các phương pháp xử lý phân phối dài đuôi trên cùng kiến trúc Swin-Tiny qua 3 phân hoạch validation:

Bảng 5: Bảng 5.3: So sánh đối chứng hiệu năng giữa Patient Prior và Image Prior

#	Phương Pháp Hàm Mất Mát	Cơ Chế Tiên Nghiệm (π_j)	Binary AUROC	Binary F1	Coarse Acc (%)	Fine Acc (%)	Fine F1 (Supp)	Tail Recall (%)
1	PP-SBS (Proposed)	Patient Prior Sqrt ($\sqrt{N_{pts}}$)	0.9521 $\pm$ 0.039	0.8907 $\pm$ 0.058	70.12% $\pm$ 3.9%	52.45% $\pm$ 1.7%	0.5506 $\pm$ 0.074	66.38% $\pm$ 11.4%
2	Patient Prior (Linear)	Patient Count Tuyến tính (N_{pts})	0.9515 $\pm$ 0.035	0.8890 $\pm$ 0.040	69.80% $\pm$ 3.1%	51.12% $\pm$ 3.2%	0.5180 $\pm$ 0.065	64.20% $\pm$ 8.5%
3	Balanced Softmax	Image Instance Prior (N_{img})	0.9531 $\pm$ 0.038	0.8893 $\pm$ 0.031	69.58% $\pm$ 2.6%	50.08% $\pm$ 5.7%	0.4823 $\pm$ 0.060	62.76% $\pm$ 6.1%
4	Logit Adjustment	Post-hoc Prior Shift	0.9455 $\pm$ 0.042	0.8888 $\pm$ 0.050	69.98% $\pm$ 3.0%	49.62% $\pm$ 1.7%	0.4822 $\pm$ 0.048	59.67% $\pm$ 8.4%
5	LDAM Loss	Margin-based Push	0.9522 $\pm$ 0.020	0.8836 $\pm$ 0.016	69.37% $\pm$ 1.9%	45.09% $\pm$ 2.8%	0.4908 $\pm$ 0.058	62.51% $\pm$ 11.2%
6	Focal Loss	Gamma=2.0 Modulating	0.9506 $\pm$ 0.024	0.8938 $\pm$ 0.032	68.16% $\pm$ 3.7%	51.09% $\pm$ 5.7%	0.4976 $\pm$ 0.062	60.97% $\pm$ 8.6%
7	Cross-Entropy (Baseline)	Uniform Distribution	0.9489 $\pm$ 0.042	0.8888 $\pm$ 0.050	67.49% $\pm$ 2.2%	50.23% $\pm$ 4.6%	0.5268 $\pm$ 0.076	66.07% $\pm$ 8.9%
8	Weighted CE	Inverse Class Frequency	0.9427 $\pm$ 0.036	0.8747 $\pm$ 0.038	67.86% $\pm$ 2.2%	49.18% $\pm$ 3.5%	0.5053 $\pm$ 0.067	63.97% $\pm$ 10.9%

- **Phân tích bóc tách Prior:** Hàm mất mát **PP-SBS** đem lại mức tăng Fine-F1 từ 0,4823 lên **0,5506** (+6,83 pp) nhờ sự kết hợp chặt chẽ giữa phân phối bệnh nhân thực tế và hàm làm mịn lũy thừa căn bậc hai nhằm giảm thiểu thiên lệch do chụp lặp trên cùng một ca bệnh (*patient clustering bias*).

5.4. Khảo sát Bóc Tách Thử Nghiệm (Comprehensive Ablations)

Bảng 6: Bảng 5.4a: Bóc tách quy trình huấn luyện và lịch trình ràng buộc phân cấp qua 3 validation splits

#	Biến Thể Thử Nghiệm	Cấu Hình Kỹ Thuật	Binary AUROC	Coarse Acc (%)	Fine Acc (%)	Fine F1 (Supp)	C-F Consist (%)
1	CystoHier (Proposed)	3-Stage + Warmup Hierarchy	0.9571 $\pm$ 0.021	73.57% $\pm$ 1.8%	53.07% $\pm$ 4.0%	0.5415 $\pm$ 0.036	82.28% $\pm$ 0.5%
2	Two-Phase Method	$w = 0$ (P1), $w = 0.25$ (P2/P3)	0.9521 $\pm$ 0.028	71.76% $\pm$ 1.1%	48.98% $\pm$ 4.1%	0.5240 $\pm$ 0.025	81.55% $\pm$ 1.8%
3	Fixed Hierarchy	$w_{hrc} = 0.25$ cố định	0.9466 $\pm$ 0.031	70.09% $\pm$ 2.3%	47.21% $\pm$ 2.4%	0.5199 $\pm$ 0.048	81.88% $\pm$ 2.0%
4	1-Stage Joint Baseline	Multi-Task Joint (CE+SupCon+SBS)	0.9594 $\pm$ 0.018	73.64% $\pm$ 0.9%	52.63% $\pm$ 2.9%	0.5026 $\pm$ 0.046	74.38% $\pm$ 3.2%
5	w/o Hierarchy Loss	$w_{hrc} = 0$ (Không ràng buộc)	0.9649 $\pm$ 0.022	73.46% $\pm$ 1.7%	52.72% $\pm$ 2.0%	0.5414 $\pm$ 0.077	72.40% $\pm$ 4.1% (-9.88 pp)

5.4.1. Khảo sát Quy Trình Huấn Luyện & Lịch Trình Ràng Buộc Phân Cấp

- **Định hình lại vai trò của Hierarchy Loss:** So sánh giữa **CystoHier** (Fine F1 0,5415, Consistency 82,28%) và biến thể **w/o Hierarchy Loss** (Fine F1 0,5414, Consistency 72,40%) cho thấy: Ràng buộc phân cấp không đóng vai trò làm tăng vọt Fine-F1 mà là một **bộ điều hòa tính nhất quán cấu trúc (*structural consistency regularizer*)**, nâng tính nhất quán phả hệ thêm +9,88 pp mà không làm suy giảm độ nhạy phân loại.

5.4.2. Bóc Tách Bảo Toàn Biểu Diễn Từng Giai Đoạn (Stage-wise Representation Preservation) Theo dõi sự biến chuyển hiệu năng qua từng giai đoạn huấn luyện tuần tự trên tập Validation nhằm chứng minh cơ chế cô lập tham số ngăn chặn hiện tượng trôi dạt biểu diễn (*Parameter-Isolated Representation Preservation*), đồng thời minh định rõ ranh giới với kết quả đánh giá chung cuộc trên tập Test độc lập:

Bảng 7: Bảng 5.4b: Tiến trình hiệu năng và cô lập tham số qua 3 giai đoạn huấn luyện trên tập Validation và kết quả chung cuộc trên tập Test

Giai Đoạn Huấn Luyện / Trạng Thái Đánh Giá	Thành Phần Cập Nhật	Binary AUROC	Binary F1	Coarse Acc (%)	Fine F1 (Supp)
A. Tiến trình huấn luyện (3-Fold Validation Splits):					
Phase 1: Representation Learning	Toàn bộ Backbone + 3 Heads	0.9571 $\pm$ 0.021	0.8960 $\pm$ 0.026	73.45% $\pm$ 1.56%	0.5395 $\pm$ 0.033
Phase 2: Coarse Alignment	Chỉ mở Coarse Head	0.9571 (Đồng bằng)	0.8960 (Đồng bằng)	73.57% $\pm$ 1.79%	0.5395 (Đồng bằng)
Phase 3: Fine Alignment	Chỉ mở Fine Head	0.9571 (Đồng bằng)	0.8960 (Đồng bằng)	73.57% (Đồng bằng)	0.5415 $\pm$ 0.036
B. Đánh giá chung cuộc (Independent Test Hold-out Split):					
Direct Head Prediction (Không hòa trộn)	Suy luận Post-hoc	0.9986 $\pm$ 0.0002	0.9811 $\pm$ 0.0036	81.18% $\pm$ 4.10%	0.6450 $\pm$ 0.1105
CystoHier Final (+ Blending $\lambda = 0.25$)	Suy luận Post-hoc	0.9986 $\pm$ 0.0002	0.9811 $\pm$ 0.0036	86.42% $\pm$ 3.52%	0.6450 $\pm$ 0.1105

5.4.3. Bóc Tách Đóng Góp Cận Biên Của Các Thành Phần Loss & Vị Trí Head

- **Đóng góp của Supervised Contrastive Loss ($\mathcal{L}_{supcon}$):** Loại bỏ SupCon ($w = 0$) làm Fine Macro-F1 sụt giảm mạnh nhất (−4,87 pp, từ 0,5415 $\rightarrow$ 0,4928) và Fine Accuracy giảm −3,28 pp.
- **Đóng góp của Smoothed Balanced Softmax:** Loại bỏ PP-SBS làm Tail Recall giảm −5,37 pp (từ 65,23% $\rightarrow$ 59,86%) và tính nhất quán Coarse-Fine giảm −4,22 pp.

- **Vị trí Classifier Head (Stage 4 vs Intermediate):** Đặt classifier heads tại các tầng trung gian (S2 → Bin, S3 → Coarse, S4 → Fine) làm Binary AUROC giảm −12,2 pp, Binary Specificity giảm −12,9 pp, và Fine Accuracy giảm −10,4 pp.
- **Cơ chế Hierarchical Marginalization Blending ($\lambda = 0,25$):** Tận dụng 75% xác suất từ phân lớp chi tiết giúp Coarse Accuracy tăng từ 81,18% (Coarse Head trực tiếp) lên **86,42%** trên tập Test độc lập (+5,24 pp [6,45% relative improvement]).

5.5. Kiểm Định Ngoại Kiểm Độc Lập Trên Bộ Dữ Liệu Lazo et al. (External Cohort)

Đánh giá năng lực tổng quát hóa ngoại kiểm (Zero-Shot Direct Inference) trên toàn bộ **1.754 ảnh nội soi / 23 bệnh nhân** của bộ dữ liệu quốc tế Lazo et al. (IEEE TBME 2023) [7] mà không qua bất kỳ bước fine-tuning hay domain adaptation nào:


Bảng 8: Bảng 5.5: Kết quả ngoại kiểm đối chuẩn trên tập dữ liệu độc lập Lazo et al. (1.754 ảnh / 23 bệnh nhân)

Nhóm Đánh Giá / Mô Hình	AUROC	Accuracy (%)	Sensitivity (%)	Specificity (%)	F1-Score	Balanced Acc (%)
Toàn bộ Ngoại kiểm (WLI + NBI, N=1.754 ảnh / 23 BN):						
Swin Baseline (Binary Only)	0.9503 ± 0.0170	84.80% ± 2.51%	80.16% ± 3.62%	96.30% ± 0.34%	0.8821 ± 0.0221	88.23% ± 1.70%
CystoHier (Proposed Direct)	0.9587 ± 0.0118	85.37% ± 2.05%	81.23% ± 3.15%	95.63% ± 1.55%	0.8875 ± 0.0179	88.43% ± 1.36%
Phân nhóm NBI Subgroup (N=321 ảnh, Ảnh sáng dải hẹp):						
Swin Baseline	0.9528 ± 0.0073	76.01% ± 4.35%	69.78% ± 6.35%	96.44% ± 2.27%	0.8151 ± 0.0404	83.11% ± 2.07%
CystoHier (Proposed Direct)	0.9414 ± 0.0114	81.00% ± 4.83%	75.47% ± 6.47%	99.11% ± 0.63%	0.8573 ± 0.0414	87.29% ± 2.97%

- **Phân tích theo Phân nhóm Bệnh học (Pathology Sensitivity):**
 - *High-Grade Carcinoma (HGC, N=469):* Độ nhạy đạt **89,48% ± 1,96%** (so với 88,56% Swin Baseline).
 - *Low-Grade Carcinoma (LGC, N=647):* Độ nhạy đạt **82,53% ± 4,99%** (so với 82,59% Swin Baseline).
 - *Non-Tumoral Lesions (NTL, N=134):* **CystoHier** tăng mạnh độ nhạy phát hiện các tổn thương viêm loét phẳng khó từ 39,05% lên **46,02% ± 4,57%** (tăng +6,97 pp), mang lại giá trị thực tiễn cao trong sàng lọc tổn thương bàng quang.
 - *Non-Suspicious / Healthy Tissue (NST, N=504):* Độ đặc hiệu đạt **95,63% ± 1,55%**.
- **Kiểm định Bootstrap Mức Bệnh Nhân (Patient-level 95% CI):**
 - AUROC ngoại kiểm: **0,9574** (KTC 95%: [0, 9312; 0, 9788]); Độ đặc hiệu: **96,20%** (KTC 95%: [0, 9381; 0, 9784]).

6. Thảo luận & Tính Khả Thi Lâm Sàng (Discussion)

6.1. Trực quan hóa Grad-CAM & Phân tích Độ Nhạy Ngưỡng



Hình 1: So sánh đối chuẩn bản đồ nhiệt Grad-CAM giữa mô hình Swin Baseline và CystoHier trên 5 phân lớp chẩn đoán có mặt nạ Ground-Truth. (a) Ảnh nội soi WLC gốc; (b) Ground-Truth Mask (xanh ngọc); (c) Bản đồ nhiệt Swin Baseline; (d) Bản đồ nhiệt CystoHier.

Bảng 9: Bảng 6.1: So sánh định lượng Grad-CAM IoU giữa Swin Baseline và CystoHier

#	Phân Lớp Chẩn Đoán	Nhóm Coarse	Nguồn Mẫu	Swin IoU (%)	CystoHier Conf.	CystoHier IoU (%)	Mức Nâng Cao (Δ)
1	LowGradePapillary	Ác tính	Test Hold-out	1.12%	0.979	37.78%	+36.66 pp
2	AirBubble	Dị vật	Test Hold-out	0.00%	1.000	24.60%	+24.60 pp
3	HighGradePapillary	Ác tính	Test Hold-out	5.56%	1.000	17.17%	+11.61 pp
4	UreteralOrifice	Mốc giải phẫu	Test Hold-out	16.44%	0.993	20.50%	+4.06 pp
5	ResectionScar	Mốc giải phẫu	Test Hold-out	1.87%	1.000	17.77%	+15.90 pp
TB	Trung Bình Toàn Bộ	—	—	5.00%	0.994	23.56%	+18.56 pp (4.71× rel.)

- **Phân tích định lượng Grad-CAM:** Đánh giá định lượng Grad-CAM IoU với ngưỡng cố định $T = 0,5$ cho thấy mô hình **CystoHier** đạt IoU trung bình **23,56% $\pm$ 7,3%** so với Swin Baseline (**5,00%**), tương ứng mức tăng **+18,56 percentage points (pp)**. Đặc biệt trên phân lớp tổn thương ác tính *LowGradePapillary*, IoU tăng từ 1,12% lên **37,78% (+36,66 pp)**. Mô hình đề xuất giảm thiểu kích hoạt giả tại viền đen camera và vùng lóa sáng, cho thấy sự tập trung cao hơn vào các vùng có mức độ tương đồng lớn hơn với Ground-Truth mask.
- **Phân tích Độ Nhạy Ngưỡng (Threshold Sensitivity):**
 - $T = 0,3$: Baseline IoU = 5,71% (Dice = 0,108) $\rightarrow$ CystoHier IoU = **14,89%** (Dice = 0,259, tăng 2,61 $\times$).
 - $T = 0,4$: Baseline IoU = 5,26% (Dice = 0,100) $\rightarrow$ CystoHier IoU = **17,85%** (Dice = 0,303, tăng 3,39 $\times$).
 - $T = 0,5$: Baseline IoU = 5,00% (Dice = 0,095) $\rightarrow$ CystoHier IoU = **23,56%** (Dice = 0,381, tăng 4,71 $\times$).
 - $T = 0,6$: Baseline IoU = 4,55% (Dice = 0,087) $\rightarrow$ CystoHier IoU = **22,47%** (Dice = 0,367, tăng 4,94 $\times$).

6.2. Hiệu năng suy luận thực tế trên thiết bị biên

Bảng 10: Bảng 6.2: Đánh giá độ trễ suy luận và thông lượng thực tế trên thiết bị biên Apple Silicon MPS

Chế Độ / Batch	Số Vòng Đo	Forward Model (ms/ảnh)	Thông Lượng Forward (FPS)	Pipeline End-to-End (ms)	Thông Lượng End-to-End (FPS)	Bộ Nhớ MPS
Batch = 1 (Đơn ảnh)	60	12.081 $\pm$ 0.95 ms	82.78 FPS	15.000 $\pm$ 1.12 ms	66.67 FPS	110.83 MiB
Batch = 8 (Mini-batch)	60	10.167 $\pm$ 0.42 ms	98.36 FPS	—	—	113.99 MiB
Batch = 32 (Thông lượng cao)	20	9.954 $\pm$ 0.38 ms	100.46 FPS	—	—	128.00 MiB

- **Tính khả thi lâm sàng:** Thông lượng suy luận toàn trình đo được là **66,67 FPS** (độ trễ 15,00 ms/ảnh), cho thấy mô hình có đủ thông lượng tính toán cho xử lý khung hình thời gian thực trong pipeline suy luận được đánh giá.

6.3. Giới hạn nghiên cứu & Hướng phát triển

1. **Thiên lệch chẩn đoán an toàn:** Các trường hợp chẩn đoán sai lệch giữa nhóm *Non-malignant* và *Malignant* (26/32 ảnh) chủ yếu do mô hình có xu hướng cảnh báo an toàn (*overcalling*) nhằm tránh bỏ sót tổn thương tiền ung thư. Xu hướng dự đoán thận trọng này có thể hữu ích trong tầm soát; tuy nhiên, giá trị lâm sàng thực tế cần được kiểm chứng trong các nghiên cứu tiền cứu.
2. **Cỡ mẫu ngoại kiểm hồi cứu:** Nghiên cứu hiện tại kiểm định trên 23 bệnh nhân của tập Lazo et al. Các nghiên cứu tiếp theo cần mở rộng sang thử nghiệm tiền cứu đa trung tâm và tích hợp mạng Temporal Video Transformer cho chuỗi video liên tục.

7. Kết luận (Conclusion)

CystoHier consistently improved fine-grained classification and hierarchical consistency over the evaluated baselines under patient-disjoint validation, while maintaining strong binary discrimination. Zero-shot evaluation on the independent Lazo cohort further demonstrated robust cross-dataset generalization, including under NBI imaging. The model also achieved real-time inference throughput on Apple Silicon. These results support

the feasibility of hierarchical long-tailed learning for cystoscopic image analysis, while prospective multicenter validation remains necessary before clinical deployment.

- [1] Lee TJ, Qiu L, Long J, *et al.* CystoDS: a multiclass endoscopy image dataset for artificial intelligence-assisted bladder cancer detection. *Scientific Data*. 2026. doi: 10.1038/s41597-026-06887-z.
- [2] Liu Z, Lin Y, Cao Y, *et al.* Swin Transformer: Hierarchical Vision Transformer using Shifted Windows. *Proceedings of ICCV*. 2021. doi: 10.1109/ICCV48922.2021.00986.
- [3] Ren J, Yu C, Ma X, Zhao H, Yi S. Balanced Meta-Softmax for Long-Tailed Visual Recognition. *NeurIPS*. 2020.
- [4] Khosla P, Teterwak P, Wang C, *et al.* Supervised Contrastive Learning. *NeurIPS*. 2020.
- [5] Shkolyar E, Jia X, Chang TC, *et al.* Augmented Bladder Tumor Detection Using Deep Learning. *European Urology*. 2019;76(6):714–718. doi: 10.1016/j.eururo.2019.08.032.
- [6] Wu S, Chen X, Pan J, *et al.* An Artificial Intelligence System for the Detection of Bladder Cancer via Cystoscopy: A Multicenter Diagnostic Study. *Journal of the National Cancer Institute*. 2022;114(2):220–227. doi: 10.1093/jnci/djab179.
- [7] Lazo Sanchez J, Rosa B, Cattellani M, *et al.* Semi-supervised Bladder Tissue Classification in Multi-Domain Endoscopic Images. *IEEE Transactions on Biomedical Engineering*. 2023;70(10):2822–2833. doi: 10.1109/TBME.2023.3265679.
- [8] Jia X, Shkolyar E, Laurie MA, *et al.* Tumor detection under cystoscopy with transformer-augmented deep learning algorithm. *Physics in Medicine & Biology*. 2023;68(16):165013. doi: 10.1088/1361-6560/ace499.
- [9] Abd El-Aziz AA, Mahmood MA, Abd El-Ghany S. EfficientNet-B3-Based Automated Deep Learning Framework for Multiclass Endoscopic Bladder Tissue Classification. *Diagnostics*. 2025;15(19):2515. doi: 10.3390/diagnostics15192515.
- [10] Wang Y, Liang H, Zhang Y, *et al.* Artificial intelligence diagnostics for bladder tumor identification and grade prediction depend on narrow band imaging cystoscopy. *iScience*. 2026;29(2):114309. doi: 10.1016/j.isci.2025.114309.
- [11] Zhang F, An J, Zhao L, *et al.* Artificial Intelligence-Powered Cystoscopy Diagnostic Support System: Clinical Application of Multiarchitecture Deep Learning Models. *Journal of Endourology*. 2026;40(8):925–934. doi: 10.1177/08927790261450807.
- [12] He K, Zhang X, Ren S, Sun J. Deep Residual Learning for Image Recognition. *Proceedings of CVPR*. 2016. doi: 10.1109/CVPR.2016.90.
- [13] Xie S, Girshick R, Dollár P, Tu Z, He K. Aggregated Residual Transformations for Deep Neural Networks. *Proceedings of CVPR*. 2017. doi: 10.1109/CVPR.2017.634.
- [14] Sun K, Xiao B, Liu D, Wang J. Deep High-Resolution Representation Learning for Human Pose Estimation. *Proceedings of CVPR*. 2019. doi: 10.1109/CVPR.2019.00584.
- [15] Tan M, Le QV. EfficientNet: Rethinking Model Scaling for Convolutional Neural Networks. *Proceedings of ICML*. 2019.
- [16] Liu Z, Mao H, Wu CY, Feichtenhofer C, Darrell T, Xie S. A ConvNet for the 2020s. *Proceedings of CVPR*. 2022. doi: 10.1109/CVPR52688.2022.01167.