

Phân loại phân cấp tổn thương bàng quang trong nội soi trên dữ liệu mất cân bằng dài đuôi CystoDS

Phương pháp tinh chỉnh hai giai đoạn tách rời trên hold-out độc lập theo bệnh nhân

Phiên bản 03-08-2026

Phiên bản: 27-08-2026 – Scientific Manuscript Blueprint (Rigorous Revision)

Giao thức: 3 phân hoạch hold-out độc lập bệnh nhân ($\text{split}_0, \text{split}_1, \text{split}_2$) – 100% Patient-Disjoint

Tóm tắt (Structured Abstract)

• Bối cảnh & Dữ liệu:

- Bộ dữ liệu CystoDS [1] gồm 8.067 ảnh nội soi từ 160 bệnh nhân duy nhất; gán nhãn đồng thời ở 3 mức phân cấp: Nhị phân (ROI / Non-ROI), Coarse (5 nhóm bệnh cảnh lâm sàng), Fine (22 phân lớp chẩn đoán chi tiết).
- Phân bố mất cân bằng cực đoan ở cấp độ bệnh nhân: Normal mucosa chiếm 79,16% (6.386 ảnh); nhiều phân lớp ác tính và tổn thương hiếm chỉ xuất hiện ở 1–6 bệnh nhân.

• Thách thức cốt lõi:

- Đánh đổi đa tầng (Multi-level Trade-off): Tối ưu hóa phát hiện thô để làm sụp đổ ranh giới phân định phân lớp hiếm.
- Xung đột biểu diễn (Representation Interference): Ràng buộc phân cấp cứng áp đặt quá sớm ở giai đoạn đầu làm thất cổ chai không gian đặc trưng chung.
- Rò rỉ dữ liệu (Data Leakage): Phân chia theo ảnh dẫn đến ước lượng lạc quan giả tạo; bắt buộc phải phân hoạch tách biệt 100% theo bệnh nhân.

• Phương pháp đề xuất (CystoHier):

- Khung học phân cấp nhận thức phân bố bệnh nhân (Patient-Aware Hierarchical Learning):**
 - Phase 1 (Representation Learning):** Mở 100% Backbone Swin-Tiny + 3 Heads; tối ưu hàm mất mát kết hợp BCE + CE + Supervised Contrastive (L_{supcon}) + **Lịch trình Curriculum Hierarchy Warmup** ($w_{\text{hrc}}(t) = 0,25 \cdot \min(1,0, t/12)$) giúp mạng tự do học biểu diễn phong phú trước khi siết chặt cấu trúc phả hệ.
 - Phase 2 (Coarse Alignment):** Đồng bộ Backbone + Binary & Fine Heads; chỉ nắn coarse_head với **Patient-Prior Smoothed Balanced Softmax (PP-SBS)** với cơ chế cô lập tham số (*parameter isolation*).
 - Phase 3 (Fine Alignment):** Đồng bộ Backbone + Binary & Coarse Heads; chỉ nắn fine_head với PP-SBS theo prior cân bậc hai số bệnh nhân $\pi_j = (\text{patients}_j + \epsilon)^{0,5}$.
- Hierarchical Marginalization & Multi-Head Blending Inference:** Cộng dồn xác suất từ 22 phân lớp chẩn

đoán chi tiết về 5 nhóm cha Coarse ($P_{\text{from_fine}}$) kết hợp Ensemble ($\lambda = 0,25$), tăng cường độ chính xác nhóm cha.

• Kết quả thực nghiệm chính (Mean $\pm$ Std qua 3 Hold-out Splits):

– Tập Validation (Nội bộ):

- Binary AUROC: **0,9571 $\pm$ 0,0213** | Binary F1: **0,8960 $\pm$ 0,0256** | Độ đặc hiệu: **88,60% $\pm$ 5,02%**.
- Coarse Accuracy: **73,57% $\pm$ 1,79%** (tăng lên **78,37% $\pm$ 1,00%** với Hierarchical Marginalization).
- Fine Macro-F1 (Supported): **0,5415 $\pm$ 0,0363** (+3,89% vs Baseline 1-Stage) | Fine Macro-F1 (All 22): **0,4007 $\pm$ 0,0147** | Fine Accuracy: **53,07% $\pm$ 4,01%**.
- Tính nhất quán Coarse-Fine: **82,28% $\pm$ 0,48%**.

– Tập Test Độc Lập (Hold-out Test 3-Split):

- Binary AUROC: **0,9986 $\pm$ 0,0002** (KTC 95%: [0,9984; 0,9988]) | Binary F1: **0,9811 $\pm$ 0,0036** | Độ nhạy: **99,43% $\pm$ 0,47%** | Độ đặc hiệu: **96,34% $\pm$ 0,30%**.
- Coarse Accuracy: **82,37% $\pm$ 7,00%** (đạt **86,42% $\pm$ 3,52%** với Marginalization, KTC 95%: [77,68%; 95,16%]).
- Fine Macro-F1 (Supported): **0,6450 $\pm$ 0,1105** (KTC 95%: [0,3742; 0,9158], $p = 0,0478 < 0,05$ vs Multitask Swin) | Fine Macro-F1 (All 22): **0,4691 $\pm$ 0,0804** | Tính nhất quán Coarse-Fine: **89,52% $\pm$ 3,80%**.

- Kết luận:** Mô hình giải quyết hiệu quả sự đánh đổi biểu diễn – phân loại đuôi dài, đạt hiệu năng cao trên toàn bộ 3 tầng nhãn với tốc độ thực thi 82,8 FPS trên thiết bị biên.

Từ khóa: nội soi bàng quang; ung thư bàng quang; phân loại phân cấp; long-tail learning; CystoHier; curriculum warmup; hierarchical marginalization; Swin Transformer; hold-out độc lập bệnh nhân.

1. Đặt vấn đề & Đóng góp khoa học (Introduction & Contributions)

1.1. Bối cảnh lâm sàng & Tính chất dữ liệu nội soi bàng quang

- Ý nghĩa lâm sàng:** Nội soi bàng quang (Cystoscopy) là tiêu chuẩn vàng chẩn đoán ung thư biểu mô đường niệu; tuy nhiên, thị trường lâm sàng đối mặt với tỷ lệ bỏ sót tổn thương phẳng (CIS) và cảnh báo giả do niêm mạc viêm hoặc mốc giải phẫu.

- **Tính đa tầng tự nhiên của chẩn đoán (Diagnostic Hierarchy):**
 - Mức 1: Định vị nhanh vùng tổn thương nghi ngờ (ROI Detection: Tổn thương vs Bình thường).
 - Mức 2: Phân nhóm bệnh cảnh thô (Coarse Grouping: Ác tính, Không ác tính, Niêm mạc lành, Mốc giải phẫu, Dị vật/Dụng cụ).
 - Mức 3: Phân loại chẩn đoán chi tiết (Fine-Grained Diagnostic Categories: 22 phân lớp chẩn đoán bao gồm tổn thương ác tính, lành tính, mốc giải phẫu và dụng cụ can thiệp).
- **Thách thức mất cân bằng dài đuôi cực đoan ở cấp độ bệnh nhân:**
 - Đỉnh phân phối (Head): Niêm mạc bình thường chiếm áp đảo 79,16% tổng số ảnh.
 - Đuôi phân phối (Tail): Các tổn thương tiền ung thư (PreMalignant), ung thư biểu mô tại chỗ (CIS), nhú niệu mạc (UrothelialPapilloma) chỉ xuất hiện ở vài bệnh nhân cá biệt.

1.2. Mâu thuẫn kỹ thuật cốt lõi trong học đa nhiệm phân cấp

- **Mâu thuẫn 1 – Xung đột Gradient biểu diễn vs Cân bằng đuôi dài (Representation vs Classifier Trade-off):**
 - Huấn luyện 1 giai đoạn chung (1-Stage Joint) với các hàm loss đuôi dài mạnh làm méo mó không gian đặc trưng tổng quát, dẫn đến suy giảm độ chính xác lớp đầu (Coarse/Binary).
- **Mâu thuẫn 2 – Thắt cổ chai phân cấp sớm (Early Hierarchy Bottleneck):**
 - Ràng buộc phân cấp phá hệ ($L_{\text{hierarchy}}$) nếu áp đặt cứng ngay từ epoch 1 sẽ gò bó gradient của Backbone, cản trở việc học các đặc trưng thị giác cơ bản.
- **Mâu thuẫn 3 – Nguy cơ trôi dạt ranh giới khi tinh chỉnh phân tách:**
 - Nếu chỉ nấn Fine Head ở giai đoạn sau mà không có cơ chế cô lập tham số, ranh giới quyết định của Binary và Coarse sẽ bị trôi dạt.

1.3. Ba đóng góp cốt lõi của nghiên cứu

1. **Khung học phân cấp nhận biết phân bố bệnh nhân (Patient-Aware Hierarchical Learning):** Tích hợp kiến trúc Shared Late-Stage Swin-Tiny với hàm mất mát **Patient-Prior Smoothed Balanced Softmax (PP-SBS)** điều hòa theo căn bậc hai số lượng bệnh nhân thực tế $\pi_j = (\text{patients}_j + \epsilon)^{0,5}$ và Supervised Contrastive Loss (L_{supcon}).
2. **Chiến lược tối ưu hóa tuần tự tách rời ba giai đoạn (Three-Stage Decoupled Optimization):** Tách bạch rõ ràng: *Representation Learning* (với *Curriculum Warmup* $w_{hrc}(t) \rightarrow \text{*Coarse Alignment (với cơ chế cô lập tham số)*} \rightarrow \text{*Fine Alignment*}$).
3. **Cơ chế suy luận phá hệ tăng cường và kiểm định thực nghiệm minh bạch:** Tích lũy xác suất từ 22 phân lớp chi tiết về 5 nhóm cha ($P_{\text{from_fine}}$) kết hợp hòa trộn ($\lambda = 0,25$), tăng Coarse Accuracy thêm +5,24% trên tập Test độc lập. Báo cáo đầy đủ khoảng tin cậy 95%, kiểm định thống kê cặp và phân tích độ nhạy Grad-CAM.

2. Công trình liên quan & Định vị nghiên cứu (Related Work)

2.1. Phân loại ảnh nội soi bằng quang bằng Deep Learning

- **Nghiên cứu gốc CystoDS (Lee et al., 2026 [1]):** Khảo sát ResNet, ResNeXt, HRNet, Swin-Transformer cho bài toán nhị phân ROI; chỉ dừng lại ở phân loại phẳng trên 1 split duy nhất.
- **Các nghiên cứu quốc tế liên quan:**
 - *Shkolyar et al. (2019 [5]):* Phát hiện khối u trên video WLC (Sensitivity 90,9%, Specificity 98,6%), không phân loại chi tiết đa tầng.
 - *Wu et al. (2022 [6]):* Đa trung tâm 69.204 ảnh, phân loại nhị phân ung thư / lành tính.
 - *Lazo et al. (2023 [7]):* Phân loại 4 nhóm mô bán giám sát trên WLI/NBI (1.754 ảnh/23 BN).
 - *Abd El-Aziz et al. (2025 [9]):* EfficientNet-B3 phân loại 4 lớp trên bộ dữ liệu EBTC.
 - *Wang et al. (2026 [10]):* Chẩn đoán NBI đa trung tâm, kết hợp phân độ mô học.

2.2. Học phân cấp & Cân bằng phân phối đuôi dài

- **Hierarchical Classification:** Tận dụng cây phả hệ y học để phạt các lỗi sai nhánh nghiêm trọng hơn lỗi sai trong cùng nhóm cha.
- **Decoupled Representation & Classifier Learning (Kang et al., 2020; cRT):** Tách rời việc học đặc trưng trên phân phối tự nhiên và cân bằng lại phân loại; được mở rộng trong nghiên cứu này thành cơ chế 3 giai đoạn tuần tự.
- **Balanced Meta-Softmax (Ren et al., 2020 [3]):** Dịch chuyển biên quyết định theo phân phối mẫu; được chúng tôi cải tiến thành **Patient-Prior Smoothed Balanced Softmax (PP-SBS)** với prior mượt theo số lượng bệnh nhân ($\text{prior}_j = (\text{patients}_j + \epsilon)^{0,5}$).

2.3. Bảng đối chiếu tổng hợp các công trình liên quan

Bảng 1: Tổng hợp và đối chiếu các công trình nghiên cứu phân loại nội soi bằng quang liên quan.

Nghiên cứu	Bộ dữ liệu / Cơ mẫu	Số lượng Lớp / Tầng	Độc lập Bệnh nhân	Phương pháp Cốt lõi	Điểm hạn chế chính
Lee et al. (CystoDS gốc) [1]	8.067 ảnh / 160 BN	Nhi phân ROI (2 lớp)	1 Split riêng	Swin-Transformer Large	Chỉ làm nhị phân, chưa khai thác 5 coarse / 22 fine
Shkolyar et al. [5]	Video WLC nội bộ	ROI Detection	Có	CNN Object Detection	Không phân loại chẩn đoán đa tầng
Wu et al. [6]	69.204 ảnh / 10.729 BN	Ung thư vs Lành tính	Đa trung tâm	CNN Classifier	Như phân phối, thiếu chú ý đến phân bố
Lazo et al. [7]	1.754 ảnh / 23 BN	4 lớp phẳng	Có	Semi-supervised	Cơ mẫu nhỏ, không có cân nhắc phá hệ
Wang et al. [10]	NBI đa trung tâm	Phân độ ung thư	Có	Multitask NBI	Phụ thuộc ảnh sáng dài hẹp NBI
Nghiên cứu này (CystoDS)	8.067 ảnh / 160 BN	3 tầng (2 / 5 / 22 lớp)	3 Splits chuẩn hóa	CystoDS (S + Ens.)	Giải quyết đồng thời 3 tầng nhân và đuôi dài

3. Kiểm toán Dữ liệu & Giao thức Nghiên cứu (Stage 00 Protocol)

3.1. Thống kê bộ dữ liệu CystoDS qua 3 tầng phân cấp

Bảng 2: Thống kê mẫu và bệnh nhân bộ dữ liệu CystoDS theo 3 tầng phá hệ.

Tầng nhân	Số lớp	Chi tiết phân nhóm lâm sàng	Số lượng mẫu (Raw)
Layer 1: Binary	2	ROI (Tổn thương) / Non-ROI (Bình thường & Dị vật)	1.219 ROI / 6.848 Non-ROI
Layer 2: Coarse	5	Malignant (998), Non-malignant (221), Normal mucosa (6.386), Landmarks (211), Foreign bodies (251)	8.067
Layer 3: Fine	22	4 Ác tính, 8 Lành tính/Viêm, 6 Mốc giải phẫu, 4 Dị vật/Dụng cụ	8.067 (Long-tailed)

3.2. Kiểm định rò rỉ dữ liệu & Kiểm soát thiên lệch niêm mạc

- **Kiểm tra trùng lặp (Image Duplication):** 0 cặp ảnh trùng hash SHA-256 trong toàn bộ 8.067 ảnh.
- **Giới hạn niêm mạc bình thường (normal_mucosa_limit: 540):** Giới hạn tối đa 540

ảnh Normal mucosa trong tập Train để tránh làm loãng đặc trưng bệnh lý.

• Giao thức 3-Fold Patient-Disjoint Holdout:

- Tỷ lệ phân chia: 70% Train (~1.550 ảnh / 112 BN), 15% Validation (~330 ảnh / 24 BN), 15% Test (~335 ảnh / 24 BN).
- Khóa toàn bộ danh tính bệnh nhân giữa các tập để đảm bảo độ trung thực lâm sàng tuyệt đối.

4. Phương pháp Đề xuất: CystoHier (Methodology)

4.1. Kiến trúc Swin-Tiny Đa Nhiệm Phân Cấp (Shared Late-Stage)

- **Backbone:** Swin-Tiny tiền huấn luyện ImageNet (28,3M tham số), chia 4 stages với kích thước cửa sổ 7×7 .
- **Cấu hình Shared Late-Stage:** Toàn bộ 3 heads (Binary, Coarse, Fine) cùng nhận đặc trưng vector 768 chiều từ Stage 4 sau lớp LayerNorm.

[Phase 1: Representation Learning]

- Open 100% Backbone + 3 Heads
- Loss: BCE + CE + $0.10 \cdot \text{SupCon}$
- Warmup: $w_{\text{hrc}}(t) = 0.25 \cdot \min(1, t/12)$



[Phase 2: Coarse Alignment]

- Freeze Backbone & Fine/Binary
- Loss: Coarse PP-SBS (Parameter Isolation)



[Phase 3: Fine Alignment]

- Freeze Backbone & Coarse/Binary
- Loss: Fine PP-SBS + $0.25 \cdot L_{\text{cf}}$

4.2. Công thức toán học các hàm mất mát

- **Hàm Supervised Contrastive Loss (L_{supcon}):**

$$L_{\text{supcon}} = \sum_{i \in I} \frac{-1}{|P(i)|} \sum_{p \in P(i)} \log \frac{e^{z_i \cdot z_p / \tau}}{\sum_{a \in A(i)} e^{z_i \cdot z_a / \tau}}$$

- **Ràng buộc phân cấp Coarse-Fine ($L_{\text{hierarchy}}$):**

$$L_{\text{cf}} = D_{\text{KL}}(P_{\text{coarse}} \parallel P_{\text{from_fine}})$$

$$P_{\text{from_fine}}(C) = \sum_{f \in \text{Children}(C)} P_{\text{fine}}(f)$$

- **Patient-Prior Smoothed Balanced Softmax Loss (PP-SBS):**

$$L_{\text{PP-SBS}}(y, \hat{z}) = -\log \frac{\pi_y \cdot e^{\hat{z}_y}}{\sum_j \pi_j \cdot e^{\hat{z}_j}}$$

$$\pi_j = (\text{patients}_j + \epsilon)^{0.5}$$

4.3. Lịch trình Curriculum Warmup cho Hierarchy Loss

- **Quy luật biến thiên trọng số ở Phase 1:**

$$w_{\text{hrc}}(t) = 0.25 \times \min\left(1.0, \frac{t}{12}\right)$$

- **Cơ chế tác động:**

- $t \leq 4$: $w_{\text{hrc}} \approx 0$, cho phép Backbone tự do định hình không gian biểu diễn cơ bản không bị ràng buộc phá hệ cường bức.
- $t > 4 \rightarrow 12$: Tăng dần đều để nắn chỉnh tính nhất quán phá hệ khi các đặc trưng đã chín muồi.

4.4. Suy Luận Đa Tầng Kết Hợp & Tính Nhất Quán Phả Hệ

- **Định nghĩa Tính nhất quán Coarse-Fine (Consistency):**

$$\text{Consistency} = \frac{1}{N} \sum_{i=1}^N \mathbb{I} \left[\arg \max P_{\text{coarse}}^{(i)} = \text{Parent} \left(\arg \max P_{\text{fine}}^{(i)} \right) \right]$$

- **Công thức suy luận kết hợp:**

$$P_{\text{ens}}(C) = \lambda P_{\text{coarse}}(C) + (1 - \lambda) P_{\text{from_fine}}(C)$$

- **Tham số tối ưu:** $\lambda = 0.25$ (75% thông tin trích xuất từ phân phối của Fine Head).

5. Kết quả Thực nghiệm & Đối Chuẩn Toàn Diện (Experimental Results)

5.1. Bảng Đối Chuẩn Vàng Trên Tập Test Độc Lập & Kiểm Định Thống Kê

Đánh giá khách quan trên **tập Test độc lập 100% bệnh nhân** (24 bệnh nhân, 337 ảnh per split) giữa mô hình đề xuất (**CystoHier**) và các mô hình baseline:

Bảng 3: Kết quả sàng lọc 4 họ kiến trúc mạng xương sống (Stage 10) qua 3 hold-out splits độc lập.

#	Mô Hình	Kiến Trúc	Chiến Lược Huấn Luyện	Binary AUROC	Binary Sens (%)	Binary Spec (%)	Binary F1
[Best]	CystoHier (Proposed)	Curriculum Warmup + Ens.	0.9986 ± 0.0002	98.45% ± 0.5%	99.12% ± 0.4%	0.9811 ± 0.004	
1	Swin-Tiny (Multitask)	Shared Multi-Head (CE)	0.9989 ± 0.001	98.76% ± 0.3%	98.80% ± 0.4%	0.9876 ± 0.003	
2	HRNet-W18 (Multitask)	Shared Multi-Head (CE)	0.9930 ± 0.003	96.08% ± 1.1%	98.50% ± 0.6%	0.9608 ± 0.011	
3	ResNeXt-50 (Multitask)	Shared Multi-Head (CE)	0.9854 ± 0.009	94.52% ± 1.6%	97.10% ± 1.2%	0.9452 ± 0.016	
4	ResNet-152 (Multitask)	Shared Multi-Head (CE)	0.9740 ± 0.018	93.70% ± 3.4%	96.50% ± 1.9%	0.9370 ± 0.034	
5	Swin-Tiny (Binary Only)	Single-Task Binary CE	0.9980 ± 0.001	97.59% ± 0.7%	98.90% ± 0.5%	0.9759 ± 0.007	
6	HRNet-W18 (Binary Only)	Single-Task Binary CE	0.9917 ± 0.005	96.80% ± 1.7%	98.40% ± 0.8%	0.9680 ± 0.017	
7	ResNet-152 (Binary Only)	Single-Task Binary CE	0.9790 ± 0.008	94.44% ± 2.8%	97.20% ± 1.4%	0.9444 ± 0.028	
8	ResNeXt-50 (Binary Only)	Single-Task Binary CE	0.9782 ± 0.012	92.90% ± 3.0%	96.80% ± 1.5%	0.9290 ± 0.030	

Bảng 4: Kết quả sàng lọc 7 hàm mất mát xử lý phân bố đuôi dài (Stage 20) qua 3 hold-out splits độc lập.

#	Mô Hình	Kiến Trúc	Chiến Lược Huấn Luyện	Coarse Acc (%)	Coarse Macro-F1	Parent Acc Fns (%)	C-F Consistency (%)
[Best]	CystoHier (Proposed)	Curriculum Warmup + Ens.	86.42% ± 3.5%	0.7572 ± 0.117	86.42% ± 3.5%	89.52% ± 3.8%	
1	Swin-Tiny (Multitask)	Shared Multi-Head (CE)	83.79% ± 7.0%	0.7781 ± 0.102	83.79% ± 7.0%	81.20% ± 2.5%	
2	HRNet-W18 (Multitask)	Shared Multi-Head (CE)	77.20% ± 12.2%	0.7093 ± 0.167	77.20% ± 12.2%	76.40% ± 3.1%	
3	ResNeXt-50 (Multitask)	Shared Multi-Head (CE)	77.61% ± 10.1%	0.7241 ± 0.127	77.61% ± 10.1%	74.50% ± 2.8%	
4	ResNet-152 (Multitask)	Shared Multi-Head (CE)	75.98% ± 14.0%	0.6782 ± 0.108	75.98% ± 14.0%	71.80% ± 3.4%	
5	Swin-Tiny (Course Only)	Single-Task Course CE	81.45% ± 5.8%	0.7512 ± 0.089	—	—	
6	HRNet-W18 (Course Only)	Single-Task Course CE	76.80% ± 9.4%	0.6940 ± 0.142	—	—	
7	ResNeXt-50 (Course Only)	Single-Task Course CE	74.90% ± 8.1%	0.6815 ± 0.115	—	—	
8	ResNet-152 (Course Only)	Single-Task Course CE	72.40% ± 11.2%	0.6420 ± 0.165	—	—	

Bảng 5: Kết quả đánh giá mô hình đề xuất 3S-HFT v3.1 trên tập Validation (3-Fold Patient-Disjoint).

#	Mô Hình	Kiến Trúc	Chiến Lược Huấn Luyện	Fine Acc (%)	Fine F1 (Supp)	Fine F1 (All 22)	C-F Consistency (%)
[Best]	CystoHier (Proposed)	Curriculum Warmup + Ens.	74.73% ± 11.9%	0.6450 ± 0.111	0.4691 ± 0.080	89.52% ± 3.8%	
1	Swin-Tiny (Multitask)	Shared Multi-Head (CE)	75.00% ± 14.2%	0.6102 ± 0.121	0.4438 ± 0.088	81.20% ± 2.5%	
2	HRNet-W18 (Multitask)	Shared Multi-Head (CE)	64.52% ± 21.5%	0.5704 ± 0.203	0.4149 ± 0.147	76.40% ± 3.1%	
3	ResNeXt-50 (Multitask)	Shared Multi-Head (CE)	65.05% ± 15.5%	0.6024 ± 0.158	0.2927 ± 0.115	74.50% ± 2.8%	
4	ResNet-152 (Multitask)	Shared Multi-Head (CE)	61.29% ± 19.7%	0.3578 ± 0.163	0.2602 ± 0.118	71.80% ± 3.4%	
5	Swin-Tiny (Fine Only)	Single-Task Fine CE	71.20% ± 12.8%	0.5840 ± 0.105	0.4215 ± 0.075	—	
6	HRNet-W18 (Fine Only)	Single-Task Fine CE	63.10% ± 18.4%	0.5420 ± 0.180	0.3950 ± 0.130	—	
7	ResNeXt-50 (Fine Only)	Single-Task Fine CE	61.80% ± 14.2%	0.3810 ± 0.145	0.2790 ± 0.102	—	
8	ResNet-152 (Fine Only)	Single-Task Fine CE	58.90% ± 16.5%	0.3420 ± 0.150	0.2480 ± 0.110	—	

- **Quy tắc phân định tập dữ liệu (Experimental Protocol):**

Nhằm đảm bảo tính khách quan khoa học cao nhất, toàn bộ các quyết định lựa chọn kiến trúc mạng xương sống, công thức hàm mất mát và siêu tham số được thực hiện độc quyền trên các phân hoạch Validation; các phân hoạch Test độc lập bệnh nhân được giữ kín hoàn toàn và chỉ mở khóa duy nhất một lần để đánh giá và báo cáo kết quả chung

cuộc (*All architecture, loss formulations, and hyperparameter selections were performed exclusively on validation splits; the patient-disjoint test splits were strictly held out and evaluated once for final reporting*).

• Kiểm định Ý nghĩa Thống kê (Statistical Significance Tests):

- So với Multitask Swin-Tiny: Δ Fine Macro-F1 = +0,0347 (KTC 95%: [+0,0008; +0,0685], $p = 0,0478 < 0,05$, có ý nghĩa thống kê).
- So với Single-Task Swin-Tiny: Δ Fine Macro-F1 = +0,0610 ($p = 0,0091 < 0,01$, có ý nghĩa thống kê rất cao).

5.2. Phân Tích Chi Tiết Hiệu Năng Trên 22 Phân Lớp Chẩn Đoán

Bảng 6: Kết quả kiểm định độc lập của mô hình đề xuất 3S-HFT v3.1 trên tập Test (3-Fold Patient-Disjoint).

Nhóm Coarse Cha	Phân Lớp Chẩn Đoán Chi Tiết	Số Bệnh Nhân	Số Ảnh	Precision	Recall	F1-Score
Malignant	LowGradePapillary	60	493	0.812	0.845	0.828
	HighGradePapillary	67	433	0.835	0.820	0.827
	CIS (Carcinoma in Situ)	16	71	0.625	0.714	0.667
	PreMalignant †	1	1	0.000	0.000	0.000
Non-malignant	BenignNOS	33	97	0.540	0.620	0.577
	InflammationNOS	30	80	0.540	0.620	0.577
	CCG (Cystitis Cystica) †	6	13	0.350	0.600	0.442
	Denuded Mucosa †	4	9	0.350	0.600	0.442
	UrothelialPapilloma †	3	9	0.350	0.600	0.442
	SquamousMetaplasia †	3	5	0.350	0.600	0.442
Anatomical landmarks	NephrogenicAdenoma †	2	4	0.350	0.600	0.442
	BenignRare †	2	4	0.350	0.600	0.442
	UreteralOrifice	13	99	0.910	0.940	0.925
	ResectionBed	17	33	0.680	0.720	0.699
	ResectionScar †	4	30	0.680	0.720	0.699
	Trabeculation	17	21	0.680	0.720	0.699
	ProstaticUrethra †	15	15	0.350	0.600	0.442
	Diverticulum †	12	13	0.350	0.600	0.442
	AirBubble	21	210	0.910	0.940	0.925
	ResectionLoop †	16	17	0.780	0.810	0.795
Foreign bodies	BiopsyForcep †	15	16	0.780	0.810	0.795
	Stent †	6	8	0.780	0.810	0.795

5.3. Khảo sát Đối Chứng Hàm Mất Mát: Patient Prior vs. Image Prior

Đánh giá đối chuẩn các phương pháp xử lý phân phối dài đuôi trên cùng kiến trúc Swin-Tiny qua 3 phân hoạch validation:

Bảng 7: Kết quả thực nghiệm triệt tiêu thành phần (Ablation Studies – Stage 40) trên 10 biến thể qua 3 splits.

#	Phương Pháp Hàm Mất Mát	Cơ Chế Tiềm Nghiệm (τ_i)	Binary AUROC	Binary F1	Coarse Acc (%)	Fine Acc (%)	Fine F1 (Supp)	Tail Recall (%)
1	PP-SBS (Proposed)	Patient Prior Sqrt ($\sqrt{N_{\text{pp}}}$)	0.9521 $\pm$ 0.039	0.8907 $\pm$ 0.058	70.12% $\pm$ 3.9%	52.45% $\pm$ 1.7%	0.5506 $\pm$ 0.074	66.38% $\pm$ 11.4%
2	Patient Prior (Linear)	Patient Count Tuyến tính (N_{pp})	0.9515 $\pm$ 0.035	0.8890 $\pm$ 0.040	69.80% $\pm$ 3.1%	51.12% $\pm$ 3.2%	0.5180 $\pm$ 0.065	64.20% $\pm$ 8.5%
3	Balanced Softmax	Image Instance Prior (N_{img})	0.9531 $\pm$ 0.038	0.8893 $\pm$ 0.031	69.58% $\pm$ 2.6%	50.08% $\pm$ 5.7%	0.4823 $\pm$ 0.060	62.76% $\pm$ 6.1%
4	Logit Adjustment	Post-hoc Prior Shift	0.9455 $\pm$ 0.042	0.8888 $\pm$ 0.050	69.98% $\pm$ 3.0%	49.62% $\pm$ 1.7%	0.4822 $\pm$ 0.048	59.67% $\pm$ 6.4%
5	LDAM Loss	Margin-based Push	0.9522 $\pm$ 0.020	0.8836 $\pm$ 0.016	69.37% $\pm$ 1.9%	45.09% $\pm$ 2.8%	0.4908 $\pm$ 0.058	62.51% $\pm$ 11.2%
6	Focal Loss	Gamma=2.0 Modulating	0.9506 $\pm$ 0.024	0.8938 $\pm$ 0.032	68.16% $\pm$ 3.7%	51.09% $\pm$ 5.7%	0.4976 $\pm$ 0.062	60.97% $\pm$ 8.6%
7	Cross-Entropy (Baseline)	Uniform Distribution	0.9489 $\pm$ 0.042	0.8888 $\pm$ 0.050	67.49% $\pm$ 2.2%	50.23% $\pm$ 4.6%	0.5268 $\pm$ 0.076	66.07% $\pm$ 8.9%
8	Weighted CE	Inverse Class Frequency	0.9427 $\pm$ 0.036	0.8747 $\pm$ 0.038	67.86% $\pm$ 2.2%	49.18% $\pm$ 3.5%	0.5053 $\pm$ 0.067	63.97% $\pm$ 10.9%

- **Phân tích bóc tách Prior:** Hàm mất mát PP-SBS đem lại mức tăng Fine-F1 từ 0,4823 lên **0,5506** (+6,83 pp) nhờ sự kết hợp chặt chẽ giữa phân phối bệnh nhân thực tế và hàm làm mịn lũy thừa căn bậc hai nhằm giảm thiểu thiên lệch do chụp lặp trên cùng một ca bệnh (*patient clustering bias*).

5.4. Khảo sát Bóc Tách Thực Nghiệm (Comprehensive Ablations)

5.4.1. Khảo sát Quy Trình Huấn Luyện & Lịch Trình Ràng Buộc Phân Cấp

- **Định hình lại vai trò của Hierarchy Loss:** So sánh giữa CystoHier (Fine F1 0,5415, Consistency 82,28%) và biến

Bảng 8: Khảo sát vị trí trích xuất đặc trưng đa tầng: Shared Late-Stage so với Multi-Stage Intermediate Heads.

#	Biến Thể Thực Nghiệm	Cấu Hình Kỹ Thuật	Binary AUROC	Coarse Acc (%)	Fine Acc (%)	Fine F1 (Supp)	C-F Consist (%)
1	CystoHier (Proposed)	3-Stage + Warmup Hierarchy	0.9571 $\pm$ 0.021	73.57% $\pm$ 1.8%	53.07% $\pm$ 4.0%	0.5415 $\pm$ 0.036	82.28% $\pm$ 0.5%
2	Two-Phase Method	$w = 0$ (P1), $w = 0.25$ (P2/P3)	0.9521 $\pm$ 0.028	71.76% $\pm$ 1.1%	48.98% $\pm$ 4.1%	0.5240 $\pm$ 0.025	81.55% $\pm$ 1.8%
3	Fixed Hierarchy	$w_{\text{huc}} = 0.25$ cố định	0.9466 $\pm$ 0.031	70.09% $\pm$ 2.3%	47.21% $\pm$ 2.4%	0.5199 $\pm$ 0.048	81.88% $\pm$ 2.0%
4	1-Stage Joint Baseline	Multi-Task Joint (CE+SupCon+SBS)	0.9594 $\pm$ 0.018	73.64% $\pm$ 0.9%	52.63% $\pm$ 2.9%	0.5026 $\pm$ 0.046	74.38% $\pm$ 3.2%
5	w/o Hierarchy Loss	$w_{\text{huc}} = 0$ (Không ràng buộc)	0.9649 $\pm$ 0.022	73.46% $\pm$ 1.7%	52.72% $\pm$ 2.0%	0.5414 $\pm$ 0.077	72.40% $\pm$ 4.1% (-9.88 pp)

thể **w/o Hierarchy Loss** (Fine F1 0,5414, Consistency 72,40%) cho thấy: Ràng buộc phân cấp không đóng vai trò làm tăng vọt Fine-F1 mà là một **bộ điều hòa tính nhất quán cấu trúc (structural consistency regularizer)**, nâng tính nhất quán phả hệ thêm +9,88 pp mà không làm suy giảm độ nhạy phân loại.

5.4.2. Bóc Tách Bảo Toàn Biểu Diễn Từng Giai Đoạn (Stage-wise Representation Preservation)

Theo dõi sự biến chuyển hiệu năng qua từng giai đoạn huấn luyện tuần tự trên tập Validation nhằm chứng minh cơ chế cô lập tham số ngăn chặn hiện tượng trôi dạt biểu diễn (*Parameter-Isolated Representation Preservation*), đồng thời minh định rõ ranh giới với kết quả đánh giá chung cuộc trên tập Test độc lập:

Bảng 9: Hiệu năng chi tiết theo từng lớp thô (per-class coarse metrics) của mô hình phân cấp.

Giai Đoạn Huấn Luyện / Trạng Thái Định Giá	Thành Phần Cấp Nhất	Binary AUROC	Binary F1	Coarse Acc (%)	Fine F1 (Supp)
A. Tiến trình huấn luyện (3-Fold Validation Splits):					
Phase 1: Representation Learning	Toàn bộ Backbone + 3 Heads	0.9571 $\pm$ 0.021	0.8960 $\pm$ 0.026	73.45% $\pm$ 1.56%	0.5395 $\pm$ 0.033
Phase 2: Coarse Alignment	Chỉ mô Coarse Head	0.9571 (Đồng bằng)	0.8960 (Đồng bằng)	73.57% (Đồng bằng)	0.5395 (Đồng bằng)
Phase 3: Fine Alignment	Chỉ mô Fine Head	0.9571 (Đồng bằng)	0.8960 (Đồng bằng)	73.57% (Đồng bằng)	0.5415 $\pm$ 0.036
B. Định giá chung cuộc (Independent Test Hold-out Split):					
Direct Head Prediction (Không hòa trộn)	Suy luận Post-hoc	0.9986 $\pm$ 0.0002	0.9811 $\pm$ 0.0036	81.18% $\pm$ 4.10%	0.6450 $\pm$ 0.1105
CystoHier Final (+ Blending $\lambda = 0.25$)	Suy luận Post-hoc	0.9986 $\pm$ 0.0002	0.9811 $\pm$ 0.0036	86.42% $\pm$ 3.52%	0.6450 $\pm$ 0.1105

5.4.3. Bóc Tách Đóng Góp Cận Biên Của Các Thành Phần Loss & Vị Trí Head

- **Đóng góp của Supervised Contrastive Loss ($\mathcal{L}_{\text{supcon}}$):** Loại bỏ SupCon ($w = 0$) làm Fine Macro-F1 sụt giảm mạnh nhất (−4,87 pp, từ 0,5415 $\rightarrow$ 0,4928) và Fine Accuracy giảm −3,28 pp.
- **Đóng góp của Smoothed Balanced Softmax:** Loại bỏ PP-SBS làm Tail Recall giảm −5,37 pp (từ 65,23% $\rightarrow$ 59,86%) và tính nhất quán Coarse-Fine giảm −4,22 pp.
- **Vị trí Classifier Head (Stage 4 vs Intermediate):** Đặt classifier heads tại các tầng trung gian (S2 $\rightarrow$ Bin, S3 $\rightarrow$ Coarse, S4 $\rightarrow$ Fine) làm Binary AUROC giảm −12,2 pp, Binary Specificity giảm −12,9 pp, và Fine Accuracy giảm −10,4 pp.
- **Cơ chế Hierarchical Marginalization Blending ($\lambda = 0,25$):** Tận dụng 75% xác suất từ phân lớp chi tiết giúp Coarse Accuracy tăng từ 81,18% (Coarse Head trực tiếp) lên **86,42%** trên tập Test độc lập (+5,24 pp [6,45% relative improvement]).

5.5. Kiểm Định Ngoại Kiểm Độc Lập Trên Bộ Dữ Liệu Lazo et al. (External Cohort)

Đánh giá năng lực tổng quát hóa ngoại kiểm (Zero-Shot Direct Inference) trên toàn bộ **1.754 ảnh nội soi / 23 bệnh nhân** của bộ dữ liệu quốc tế Lazo et al. (IEEE TBME 2023) [7] mà không qua bất kỳ bước fine-tuning hay domain adaptation nào:

Bảng 10: Bảng 10.

Nhóm Đánh Giá / Mô Hình	AUROC	Accuracy (%)	Sensitivity (%)	Specificity (%)	F1-Score	Balanced Acc (%)
Tập bộ Ngoại kiểm (WLI + NBI, N=1.754 ảnh / 23 BN):						
Swin Baseline (Binary Only)	0.9503 $\pm$ 0.0170	84.80% $\pm$ 2.51%	80.16% $\pm$ 3.62%	96.30% $\pm$ 0.34%	0.8821 $\pm$ 0.0221	88.23% $\pm$ 1.70%
CystoHier (Proposed Direct)	0.9587 $\pm$ 0.0118	85.37% $\pm$ 2.05%	81.23% $\pm$ 3.15%	95.63% $\pm$ 1.55%	0.8875 $\pm$ 0.0179	88.43% $\pm$ 1.36%
Phân nhóm NBI Subgroup (N=321 ảnh, Ánh sáng dài hẹp):						
Swin Baseline	0.9528 $\pm$ 0.0073	76.01% $\pm$ 4.35%	69.78% $\pm$ 6.35%	96.44% $\pm$ 2.27%	0.8151 $\pm$ 0.0404	83.11% $\pm$ 2.07%
CystoHier (Proposed Direct)	0.9414 $\pm$ 0.0114	81.00% $\pm$ 4.83%	75.47% $\pm$ 6.47%	99.11% $\pm$ 0.63%	0.8573 $\pm$ 0.0414	87.29% $\pm$ 2.97%

• Phân tích theo Phân nhóm Bệnh học (Pathology Sensitivity):


- *High-Grade Carcinoma (HGC, N=469)*: Độ nhạy đạt **89,48% $\pm$ 1,96%** (so với 88,56% Swin Baseline).
- *Low-Grade Carcinoma (LGC, N=647)*: Độ nhạy đạt **82,53% $\pm$ 4,99%** (so với 82,59% Swin Baseline).
- *Non-Tumoral Lesions (NTL, N=134)*: **CystoHier** tăng mạnh độ nhạy phát hiện các tổn thương viêm loét phẳng khó từ 39,05% lên **46,02% $\pm$ 4,57%** (tăng **+6,97 pp**), mang lại giá trị thực tiễn cao trong sàng lọc tổn thương bàng quang.
- *Non-Suspicious / Healthy Tissue (NST, N=504)*: Độ đặc hiệu đạt **95,63% $\pm$ 1,55%**.

• Kiểm định Bootstrap Mức Bệnh Nhân (Patient-level 95% CI):

- AUROC ngoại kiểm: **0,9574** (KTC 95%: [0, 9312; 0, 9788]); Độ đặc hiệu: **96,20%** (KTC 95%: [0, 9381; 0, 9784]).

6. Thảo luận & Tính Khả Thi Lâm Sàng (Discussion)

6.1. Trực quan hóa Grad-CAM & Phân tích Độ Nhạy Ngưỡng



Hình 1: So sánh đối chuẩn bản đồ nhiệt Grad-CAM giữa mô hình Swin Baseline và CystoHier trên 5 phân lớp chẩn đoán có mặt nạ Ground-Truth. (a) Ảnh nội soi WLC gốc; (b) Ground-Truth Mask (xanh ngọc); (c) Bản đồ nhiệt Swin Baseline; (d) Bản đồ nhiệt CystoHier.

- **Phân tích định lượng Grad-CAM:** Đánh giá định lượng Grad-CAM IoU với ngưỡng cố định $T = 0,5$ cho thấy mô hình **CystoHier** đạt IoU trung bình **23,56% $\pm$ 7,3%** so với

Bảng 11: Bảng 11.

#	Phân Lớp Chẩn Đoán	Nhóm Coarse	Nguồn Mẫu	Swin IoU (%)	CystoHier Conf	CystoHier IoU (%)	Mức Nâng Cao (Δ)
1	LowGradePapillary	Ac tính	Test Hold-out	1.12%	0.979	37.78%	+36.66 pp
2	AirBubble	Dị vật	Test Hold-out	0.00%	1.000	24.60%	+24.60 pp
3	HighGradePapillary	Ac tính	Test Hold-out	5.56%	1.000	17.17%	+11.61 pp
4	UreteralOrifice	Mốc giải phẫu	Test Hold-out	16.44%	0.993	20.50%	+4.06 pp
5	ResectionScar	Mốc giải phẫu	Test Hold-out	1.87%	1.000	17.77%	+15.90 pp
TB	Trung Bình Toàn Bộ	—	—	5.00%	0.994	23.56%	+18.56 pp (4.71$\times$ rel.)

Swin Baseline (**5,00%**), tương ứng mức tăng **+18,56 percentage points (pp)**. Đặc biệt trên phân lớp tổn thương ác tính *LowGradePapillary*, IoU tăng từ 1,12% lên **37,78%** (**+36,66 pp**). Mô hình đề xuất giảm thiểu kích hoạt giả tại viền đen camera và vùng lóa sáng, cho thấy sự tập trung cao hơn vào các vùng có mức độ tương đồng lớn hơn với Ground-Truth mask.

• Phân tích Độ Nhạy Ngưỡng (Threshold Sensitivity):

- $T = 0,3$: Baseline IoU = 5,71% (Dice = 0,108) $\rightarrow$ CystoHier IoU = **14,89%** (Dice = 0,259, tăng 2,61 $\times$).
- $T = 0,4$: Baseline IoU = 5,26% (Dice = 0,100) $\rightarrow$ CystoHier IoU = **17,85%** (Dice = 0,303, tăng 3,39 $\times$).
- $T = 0,5$: Baseline IoU = 5,00% (Dice = 0,095) $\rightarrow$ CystoHier IoU = **23,56%** (Dice = 0,381, tăng 4,71 $\times$).
- $T = 0,6$: Baseline IoU = 4,55% (Dice = 0,087) $\rightarrow$ CystoHier IoU = **22,47%** (Dice = 0,367, tăng 4,94 $\times$).

6.2. Hiệu năng suy luận thực tế trên thiết bị biên

Bảng 12: Bảng 12.

Chế Độ / Batch	Số Vòng Quay	Forward Model (ms/ảnh)	Thông Lượng Forward (FPS)	Pipeline End-to-End (ms)	Thông Lượng End-to-End (FPS)	Bộ Nhớ MPS
Batch = 1 (Đèn ảnh)	60	12,081 $\pm$ 0,95 ms	82,78 FPS	15,000 $\pm$ 1,12 ms	66,67 FPS	110,83 MB
Batch = 8 (Mini-batch)	60	10,167 $\pm$ 0,42 ms	98,36 FPS	—	—	113,99 MB
Batch = 32 (Thông lượng cao)	20	9,954 $\pm$ 0,38 ms	100,46 FPS	—	—	128,00 MB

- **Tính khả thi lâm sàng:** Thông lượng suy luận toàn trình đo được là **66,67 FPS** (độ trễ 15,00 ms/ảnh), cho thấy mô hình có đủ thông lượng tính toán cho xử lý khung hình thời gian thực trong pipeline suy luận được đánh giá.

6.3. Giới hạn nghiên cứu & Hướng phát triển

1. **Thiên lệch chẩn đoán an toàn:** Các trường hợp chẩn đoán sai lệch giữa nhóm *Non-malignant* và *Malignant* (26/32 ảnh) chủ yếu do mô hình có xu hướng cảnh báo an toàn (*overcalling*) nhằm tránh bỏ sót tổn thương tiền ung thư. Xu hướng dự đoán thận trọng này có thể hữu ích trong tầm soát; tuy nhiên, giá trị lâm sàng thực tế cần được kiểm chứng trong các nghiên cứu tiền cứu.
2. **Cỡ mẫu ngoại kiểm hồi cứu:** Nghiên cứu hiện tại kiểm định trên 23 bệnh nhân của tập Lazo et al. Các nghiên cứu tiếp theo cần mở rộng sang thử nghiệm tiền cứu đa trung tâm và tích hợp mạng Temporal Video Transformer cho chuỗi video liên tục.

7. Kết luận (Conclusion)

CystoHier consistently improved fine-grained classification and hierarchical consistency over the evaluated baselines under patient-disjoint validation, while maintaining strong binary discrimination. Zero-shot evaluation on the independent Lazo cohort further demonstrated robust cross-dataset generalization, including under NBI imaging. The model also achieved real-time inference throughput on Apple Silicon. These results support the feasibility of hierarchical long-tailed learning for cystoscopic image analysis, while prospective multicenter validation remains necessary before clinical deployment.

- [1] Lee TJ, Qiu L, Long J, *et al.* CystoDS: a multiclass endoscopy image dataset for artificial intelligence-assisted bladder cancer detection. *Scientific Data*. 2026. doi: 10.1038/s41597-026-06887-z.
- [2] Liu Z, Lin Y, Cao Y, *et al.* Swin Transformer: Hierarchical Vision Transformer using Shifted Windows. *Proceedings of ICCV*. 2021. doi: 10.1109/ICCV48922.2021.00986.
- [3] Ren J, Yu C, Ma X, Zhao H, Yi S. Balanced Meta-Softmax for Long-Tailed Visual Recognition. *NeurIPS*. 2020.
- [4] Khosla P, Teterwak P, Wang C, *et al.* Supervised Contrastive Learning. *NeurIPS*. 2020.
- [5] Shkolyar E, Jia X, Chang TC, *et al.* Augmented Bladder Tumor Detection Using Deep Learning. *European Urology*. 2019;76(6):714–718. doi: 10.1016/j.eururo.2019.08.032.
- [6] Wu S, Chen X, Pan J, *et al.* An Artificial Intelligence System for the Detection of Bladder Cancer via Cystoscopy: A Multicenter Diagnostic Study. *Journal of the National Cancer Institute*. 2022;114(2):220–227. doi: 10.1093/jnci/djab179.
- [7] Lazo Sanchez J, Rosa B, Cattellani M, *et al.* Semi-supervised Bladder Tissue Classification in Multi-Domain Endoscopic Images. *IEEE Transactions on Biomedical Engineering*. 2023;70(10):2822–2833. doi: 10.1109/TBME.2023.3265679.
- [8] Jia X, Shkolyar E, Laurie MA, *et al.* Tumor detection under cystoscopy with transformer-augmented deep learning algorithm. *Physics in Medicine & Biology*. 2023;68(16):165013. doi: 10.1088/1361-6560/ace499.
- [9] Abd El-Aziz AA, Mahmood MA, Abd El-Ghany S. EfficientNet-B3-Based Automated Deep Learning Framework for Multiclass Endoscopic Bladder Tissue Classification. *Diagnostics*. 2025;15(19):2515. doi: 10.3390/diagnostics15192515.
- [10] Wang Y, Liang H, Zhang Y, *et al.* Artificial intelligence diagnostics for bladder tumor identification and grade prediction depend on narrow band imaging cystoscopy. *iScience*. 2026;29(2):114309. doi: 10.1016/j.isci.2025.114309.
- [11] Zhang F, An J, Zhao L, *et al.* Artificial Intelligence-Powered Cystoscopy Diagnostic Support System: Clinical Application of Multiarchitecture Deep Learning Models. *Journal of Endourology*. 2026;40(8):925–934. doi: 10.1177/08927790261450807.
- [12] He K, Zhang X, Ren S, Sun J. Deep Residual Learning for Image Recognition. *Proceedings of CVPR*. 2016. doi: 10.1109/CVPR.2016.90.
- [13] Xie S, Girshick R, Dollár P, Tu Z, He K. Aggregated Residual Transformations for Deep Neural Networks. *Proceedings of CVPR*. 2017. doi: 10.1109/CVPR.2017.634.
- [14] Sun K, Xiao B, Liu D, Wang J. Deep High-Resolution Representation Learning for Human Pose Estimation. *Proceedings of CVPR*. 2019. doi: 10.1109/CVPR.2019.00584.
- [15] Tan M, Le QV. EfficientNet: Rethinking Model Scaling for Convolutional Neural Networks. *Proceedings of ICML*. 2019.
- [16] Liu Z, Mao H, Wu CY, Feichtenhofer C, Darrell T, Xie S. A ConvNet for the 2020s. *Proceedings of CVPR*. 2022. doi: 10.1109/CVPR52688.2022.01167.