CystoHier: A Decoupled Hierarchical Learning Framework for Bladder Cancer Endoscopy Classification on Extreme Long-Tailed Distributions

Nguyễn Xuân Cường[1 [0000−0002−1825−0097]] and Võ Quốc Trình[1 [0000−0002−8877−6655]]

Trường Đại học FPT, Phân hiệu Đà Nẵng, Đà Nẵng, Việt Nam
cuongnxde180528@fpt.edu.vn

Abstract. Nội soi bàng quang (Cystoscopy) là tiêu chuẩn vàng trong tầm soát, chẩn đoán và theo dõi ung thư biểu mô đường niệu (Bladder Cancer). Tuy nhiên, việc xây dựng các hệ thống trí tuệ nhân tạo (AI) hỗ trợ phẫu thuật viên đối mặt với hai thách thức cốt lõi: cấu trúc phân cấp chẩn đoán y học đa tầng (nhị phân, nhóm bệnh cảnh thô và phân lớp chẩn đoán chi tiết) và hiện tượng mất cân bằng phân phối dài đuôi cực đoan (Extreme Long-Tailed Imbalance) khi các tổn thương ác tính hoặc bệnh lý hiếm chỉ xuất hiện ở một số ít bệnh nhân. Bài báo này đề xuất **CystoHier** – một khung học phân cấp tách rời ba giai đoạn toàn diện trên nền tảng kiến trúc Swin Transformer nhằm giải quyết sự đánh đổi giữa học biểu diễn đặc trưng và tối ưu hóa ranh giới phân loại đa tầng. Các đóng góp cốt lõi của **CystoHier** bao gồm: (1) Kiến trúc đa nhiệm chia sẻ biểu diễn sâu (*Shared Late-Stage Multi-Head Backbone*); (2) Hàm mất mát *Smoothed Balanced Softmax* (SBS) với tiên nghiệm mượt theo số lượng bệnh nhân thực tế nhằm giảm thiểu thiên lệch lấy mẫu; (3) Tinh chỉnh co cụm không gian đặc trưng bằng *Supervised Contrastive Loss* ($\mathcal{L}_{\text{supcon}}$); (4) Ràng buộc nhất quán phả hệ với lịch trình *Curriculum Hierarchy Warmup* giúp giải phóng thắt cổ chai biểu diễn ở giai đoạn sớm; (5) Chiến lược huấn luyện tuần tự ba giai đoạn tách rời (*Three-Stage Decoupled Training*) với cơ chế đóng băng tham số (*Parameter-Isolated Representation Preservation*); (6) Cơ chế suy luận kết hợp *Hierarchical Marginalization & Multi-Head Blending* tích lũy xác suất từ 22 phân lớp chi tiết về 5 nhóm thô; và (7) Đánh giá ngoại kiểm độc lập (*External Cohort Validation*) trên bộ dữ liệu Lazo et al. (1.754 ảnh, 23 bệnh nhân). Đánh giá thực nghiệm trên bộ dữ liệu CystoDS (8.067 ảnh, 160 bệnh nhân) theo giao thức 3-Fold Patient-Disjoint Hold-out (100% độc lập bệnh nhân) cho thấy **CystoHier** đạt hiệu năng cao nhất trong số các mô hình đối chuẩn: Binary AUROC **0,9986 ± 0,0002**, Coarse Accuracy **0,8642 ± 0,0352**, Fine Macro-F1 (Supported) **0,6450 ± 0,1105**, và tính nhất quán Coarse-Fine đạt **0,8952 ± 0,0380** trên tập kiểm định độc lập. Đánh giá zero-shot trên tập ngoại kiểm Lazo et al. xác nhận khả năng tổng quát hóa vững chắc (AUROC 0,9587 ± 0,0118, Accuracy 0,8537 ± 0,0205), đặc biệt cải thiện độ nhạy phát hiện tổn thương không tạo u NTL (0,4602 vs 0,3905) và ảnh NBI (Accuracy

0,8100 vs 0,7601). Bản đồ nhiệt Grad-CAM cải thiện độ trùng khớp IoU giải phẫu từ 0,0500 lên 0,2356 trên mặt nạ chuyên gia, đồng thời đạt thông lượng suy luận thời gian thực 66,7 FPS end-to-end trên phần cứng biên, chứng minh tính khả thi của phương pháp học phân cấp dài đuôi cho chẩn đoán nội soi bàng quang.

Keywords: Cystoscopy · Bladder Cancer · Hierarchical Classification · Long-Tailed Learning · Vision Transformer · Contrastive Learning · Curriculum Warmup · External Validation · Grad-CAM.

1 Introduction

Bladder cancer is one of dangerous malignancies worldwide with over 570,000 new cases and 212,000 deaths annually [1, 2]. White Light Cystoscopy (WLC) combining with Narrow Band Imaging (NBI) becomes the standard method to detect mucosal lesions early, guide biopsies, and perform Transurethral Resection of Bladder Tumor (TURBT) [3,7]. However, the accuracy of the diagnose process heavily relies on the experience and the concentration of the experts. It could lead to missing flat mucosal areas, such as Carcinoma in Situ (CIS). This rate is relatively high of 10 to 20%. Simultaneously, it creates high rate of false positive for lesions [2, 8].

Trong thực hành lâm sàng, quy trình chẩn đoán nội soi bàng quang mang tính chất phân cấp chẩn đoán y khoa tự nhiên (Diagnostic Hierarchy) gồm ba tầng phân loại hình ảnh (Image Classification). Tầng thứ nhất (Layer 1 – Binary Classification) thực hiện phân loại nhị phân nhằm xác định nhanh vùng nghi ngờ tổn thương (Region of Interest – ROI, bao gồm các tổn thương ác tính và không ác tính) so với vùng không tổn thương (Non-ROI, bao gồm niêm mạc bình thường, mốc giải phẫu và dị vật ngoại lai) nhằm cung cấp cảnh báo tức thời cho phẫu thuật viên. Cần lưu ý rằng đây là bài toán phân loại hình ảnh toàn khung hình (image-level classification); các nhãn mặt nạ phân đoạn (segmentation masks) trong tập dữ liệu chỉ phục vụ kiểm chứng giải thích thị giác giải phẫu học chứ không nhằm huấn luyện mạng dò tìm định vị vật thể (object detection). Tầng thứ hai (Layer 2 – Coarse Grouping) phân loại cấu trúc mô thành năm nhóm bệnh cảnh lâm sàng lớn: Ác tính (*Malignant*), Không ác tính (*Non-malignant*), Niêm mạc bình thường (*Normal mucosa*), Mốc giải phẫu tự nhiên (*Anatomical landmarks*), và Dị vật hoặc Dụng cụ can thiệp (*Foreign bodies / Artefacts*). Tầng thứ ba (Layer 3 – Fine-Grained Diagnostic Classification) thực hiện nhận diện phân loại chi tiết toàn bộ 22 thực thể chẩn đoán y khoa, bao gồm: bốn phân lớp ác tính (*LowGradePapillary*, *HighGradePapillary*, ung thư biểu mô tại chỗ *CIS*, và tổn thương tiền ác tính *PreMalignant*); tám phân lớp viêm hoặc lành tính (*BenignNOS*, *InflammationNOS*, viêm bàng quang nang tuyến *CCG*, trợt niêm mạc *Denuded*, u nhú niệu mạc *UrothelialPapilloma*, dị sản vảy *SquamousMetaplasia*, u tuyến thận *NephrogenicAdenoma*, và bệnh lý lành tính hiếm gặp *BenignRare*); một phân lớp niêm mạc lành (*NormalMucosa*); sáu mốc giải phẫu (*UreteralOrifice*, diện cắt đốt cũ *ResectionBed*, sẹo sau cắt đốt

ResectionScar, bè bàng quang *Trabeculation*, niệu đạo tiền liệt tuyến *Prostatic-Urethra*, và túi thừa *Diverticulum*); cùng bốn nhóm dị vật can thiệp (*AirBubble*, quai cắt đốt *ResectionLoop*, kẹp sinh thiết *BiopsyForcep*, và sonde niệu quản *Stent*). Việc định danh chính xác ở cả ba tầng phân loại này mang ý nghĩa quyết định đối với chiến lược can thiệp ngoại khoa.

Mặc dù việc phân loại đa tầng mang lại giá trị lâm sàng vượt bậc, việc huấn luyện mô hình học sâu đối mặt với hiện tượng **mất cân bằng phân phối dài đuôi cực đoan (Extreme Long-Tailed Distribution)** [1]. Cụ thể, trong bộ dữ liệu CystoDS [1], lớp niêm mạc bình thường chiếm áp đảo tới 79,16% (6.386/8.067 ảnh), trong khi nhiều phân lớp ác tính và tổn thương hiếm (như CIS, PreMalignant, BenignRare) chỉ xuất hiện ở từ 1 đến 6 bệnh nhân.

Khi giải quyết đồng thời bài toán phân loại đa tầng và phân phối dài đuôi, các phương pháp học sâu hiện hành bộc lộ ba mâu thuẫn kỹ thuật cốt lõi. Thứ nhất là sự đánh đổi giữa học biểu diễn và tối ưu hóa bộ phân loại (*Representation vs. Classifier Trade-off*): việc huấn luyện đa nhiệm đồng thời một giai đoạn (1-Stage Joint) cùng các hàm mất mát đuôi dài mạnh như Balanced Softmax [11] tạo ra các vector gradient có biên độ rất lớn từ các lớp đuôi hiếm, làm méo mó nghiêm trọng không gian biểu diễn đặc trưng tổng quát và làm suy giảm độ chính xác của các lớp đa số cùng tầng phân loại thô [13]. Thứ hai là hiện tượng thắt cổ chai phân cấp sớm (*Early Hierarchy Bottleneck*): việc áp đặt ràng buộc hình học phả hệ cứng ngay từ những epoch huấn luyện đầu tiên sẽ gò bó không gian đặc trưng của mạng xương sống (Backbone), cản trở việc tự do học các mẫu hình thị giác biểu mô cơ bản [10]. Thứ ba là hiện tượng trôi dạt ranh giới quyết định (*Decision Boundary Drift*): khi tinh chỉnh đầu phân loại chi tiết (Fine Head) ở các giai đoạn sau, nếu không có cơ chế cố định không gian biểu diễn và cô lập tham số các đầu phân loại tầng trên, ranh giới phân tách của tầng Binary và Coarse sẽ bị ảnh hưởng tiêu cực và đánh mất tính tối ưu đã hội tụ.

Nhằm giải quyết triệt để các hạn chế trên, nghiên cứu này đề xuất khung phương pháp **CystoHier** trên nền tảng kiến trúc Swin Transformer [10]. Bài báo tập trung vào bốn đóng góp khoa học cốt lõi sau:

Thứ nhất, chúng tôi xây dựng kiến trúc đa nhiệm chia sẻ sâu (*Shared Late-Stage Multi-Head Architecture*) trích xuất đặc trưng thống nhất tại Stage 4 sâu nhất ($z \in \mathbb{R}^{768}$) của Swin-Tiny, kết hợp học biểu diễn tương phản có giám sát ($\mathcal{L}_{\text{supcon}}$) [12] nhằm tăng cường độ co cụm nội lớp và phân tách liên lớp biểu mô, đồng thời đảm bảo độ bền vững trước nhiễu lóa sáng và bọt khí nội soi.

Thứ hai, chúng tôi đề xuất hàm mất mát *Smoothed Balanced Softmax (SBS)* với tiên nghiệm mượt dựa trên căn bậc hai số lượng bệnh nhân thực tế ($\pi_j = \sqrt{N_{\text{pts}}}$), giúp loại bỏ thiên lệch thống kê do việc chụp nhiều ảnh lặp lại ở một số ca bệnh, kết hợp lịch trình làm ấm phân cấp (*Curriculum Hierarchy Warmup*) tăng dần trọng số phạt phả hệ từ $0 \rightarrow 0{,}25$ qua 12 epoch đầu để giải phóng không gian biểu diễn ở giai đoạn khởi tạo.

Thứ ba, chúng tôi thiết lập quy trình huấn luyện tuần tự ba giai đoạn tách rời (*Three-Stage Sequential Decoupled Training*) với cơ chế đóng băng tham số bảo toàn biểu diễn (*Parameter-Isolated Representation Preservation*), tách bạch quá trình học đặc trưng tổng quát, nắn chỉnh phân nhóm thô, và tối ưu ranh

giới phân loại chi tiết mà không làm tổn hại đến ranh giới quyết định của các tầng trên.

Thứ tư, chúng tôi tích hợp cơ chế suy luận kết hợp phả hệ (*Hierarchical Marginalization & Blending Inference*) hòa trộn xác suất tích lũy từ 22 lớp chi tiết về 5 nhóm thô ($\lambda = 0{,}25$), đồng thời thiết lập giao thức thực nghiệm chuẩn mực 100% độc lập bệnh nhân (Patient-Disjoint) trên CystoDS và tiến hành kiểm định ngoại kiểm độc lập (*External Cohort Validation*) zero-shot trên 1.754 ảnh của bộ dữ liệu Lazo et al. [4], kết hợp đánh giá định lượng tính trung thực giải phẫu bằng Grad-CAM IoU [18] trên mặt nạ chuyên gia và benchmark thông lượng phần cứng biên thời gian thực.

2 Related Work

2.1 Deep Learning in Cystoscopy Image Analysis

Trong những năm gần đây, nhiều nghiên cứu đã ứng dụng mạng nơ-ron tích chập (CNN) và Vision Transformer vào bài toán nội soi bàng quang. Shkolyar và cộng sự (2019) [2] đã phát triển hệ thống CystoNet phát hiện khối u bàng quang trên video WLC với độ nhạy 0,9090 và độ đặc hiệu 0,9860. Wu và cộng sự (2022) [3] thực hiện nghiên cứu đa trung tâm quy mô lớn trên 69.204 ảnh nội soi nhằm phân loại nhị phân tổn thương ác tính và lành tính. Lazo và cộng sự (2023) [4] đề xuất mô hình bán giám sát phân loại 4 nhóm mô trên 1.754 ảnh WLC/NBI. Jia và cộng sự (2023) [5] tích hợp Transformer nâng cao độ chính xác phát hiện u. Gần đây, Abd El-Aziz và cộng sự (2025) [6] sử dụng EfficientNet-B3 phân loại mô bàng quang, và Wang và cộng sự (2026) [7] xây dựng hệ thống chẩn đoán đa trung tâm dựa trên ảnh nội soi NBI.

Nghiên cứu công bố bộ dữ liệu CystoDS của Lee và cộng sự (2026) [1] đã thiết lập chuẩn đánh giá trên 8.067 ảnh nội soi. Tuy nhiên, nghiên cứu gốc chỉ khảo sát bài toán phân loại nhị phân phẳng (ROI Detection) trên một phân hoạch đơn lẻ, hoàn toàn chưa khai thác cấu trúc phân cấp 5 nhóm Coarse và 22 phân lớp chẩn đoán chi tiết.

2.2 Hierarchical Classification and Long-Tailed Learning

Học phân cấp (Hierarchical Classification) khai thác cấu trúc cây phả hệ y học để áp đặt tính nhất quán ngữ nghĩa, đảm bảo rằng một mẫu được dự đoán là lớp con chi tiết thì bắt buộc phải thuộc về nhóm cha tương ứng [4].

Đối với bài toán mất cân bằng phân phối dài đuôi (Long-Tailed Learning), các kỹ thuật truyền thống bao gồm tái lấy mẫu (Re-sampling) và tái đánh trọng số (Cost-sensitive Re-weighting) [11]. Kang và cộng sự (2020) [13] chứng minh rằng việc tách rời quy trình học đặc trưng và cân bằng bộ phân loại (Decoupled Training / cRT) mang lại hiệu quả vượt trội. Ren và cộng sự (2020) [11] đề xuất Balanced Softmax nhằm dịch chuyển biên phân loại theo xác suất tiên nghiệm của nhãn, trong khi Menon và cộng sự (2021) [14] xây dựng cơ sở lý thuyết cho Logit Adjustment. Trong nghiên cứu này, chúng tôi phát triển khung phương pháp **CystoHier** kết hợp toàn diện các cơ chế trên nhằm giải quyết trọn vẹn cả ba thách thức: phân cấp, dài đuôi và bảo toàn biểu diễn (Table 1).

Table 1. Summary and comparison of related deep learning studies in bladder cystoscopy image analysis.

Study / Reference	Dataset / Sample Size	Taxonomy / Levels	Patient-Disjoint	Core Methodology	Primary Limitation
Lee et al. (CystoDS) [1]	8,067 images / 160 Pts	1 level (2 classes ROI)	Single Split	Swin-Large Baseline	Binary only, ignores 5 Coarse / 22 Fine
Shkolyar et al. [2]	Internal WLC Video	1 level (Tumor Detection)	Yes	CNN Object Detection	No fine-grained classification
Wu et al. [3]	69,204 images / 10,729 Pts	1 level (Malignant vs Benign)	Multicenter	CNN Classifier	Flat binary, lacks fine diagnostic depth
Lazo et al. [4]	1,754 images / 23 Pts	1 level (4 tissue classes)	Yes	Semi-supervised CNN	Small cohort, lacks hierarchical tree
Wang et al. [7]	Multicenter NBI	2 levels (Tumor / Grade)	Yes	Multitask CNN	Strictly requires NBI hardware
Ours (CystoHier)	**8,067 images / 160 Pts**	**3 levels (2 / 5 / 22 classes)**	**3-Split Standardized**	**CystoHier (3S + Blending)**	**Simultaneously solves 3-level taxonomy & tail**

Table 2. Comprehensive specification of the 3-level diagnostic hierarchy and all 22 fine-grained diagnostic classes in the CystoDS benchmark.

Taxonomy Level	Classes	Clinical Grouping and Detailed Fine-Grained Diagnostic Entities
Layer 1: Binary	2	**ROI** (Lesion suspicious) vs **Non-ROI** (Normal mucosa, anatomical landmarks, foreign artefacts)
Layer 2: Coarse	5	**Malignant**, **Non-malignant**, **Normal mucosa**, **Anatomical landmarks**, **Foreign bodies / Artefacts**
Layer 3: Fine	22	**Malignant (4 classes):** *LowGradePapillary*, *HighGradePapillary*, *CIS*, *PreMalignant* **Non-malignant (8 classes):** *BenignNOS*, *InflammationNOS*, *CCG*, *Denuded*, *UrothelialPapilloma*, *SquamousMetaplasia*, *NephrogenicAdenoma*, *BenignRare* **Normal mucosa (1 class):** *NormalMucosa* **Anatomical landmarks (6 classes):** *UreteralOrifice*, *ResectionBed*, *ResectionScar*, *Trabeculation*, *ProstaticUrethra*, *Diverticulum* **Foreign bodies / Artefacts (4 classes):** *AirBubble*, *ResectionLoop*, *BiopsyForcep*, *Stent*

3 Dataset and Experimental Protocol

3.1 Three-Level Diagnostic Hierarchy of the CystoDS Dataset

Bộ dữ liệu CystoDS [1] bao gồm tổng cộng 8.067 ảnh nội soi ánh sáng trắng (WLC) thu nhận từ 160 bệnh nhân duy nhất, được gán nhãn đồng thời ở ba cấp độ chẩn đoán y khoa với 22 phân lớp chi tiết (Table 2 và Fig. 1). Cụ thể, tầng thứ nhất (Layer 1: Binary) phân loại giữa vùng tổn thương nghi ngờ (ROI = Malignant ∪ Non-malignant) và vùng không tổn thương (Non-ROI = Normal mucosa ∪ Anatomical landmarks ∪ Foreign bodies). Tầng thứ hai (Layer 2: Coarse) nhóm các thực thể thành năm nhóm bệnh cảnh lâm sàng lớn: *Malignant*, *Non-malignant*, *Normal mucosa*, *Anatomical landmarks*, và *Foreign bodies / Artefacts*. Tầng thứ ba (Layer 3: Fine) phân rã thành 22 phân lớp chẩn đoán chi tiết: bốn phân lớp ác tính (*LowGradePapillary*, *HighGradePapillary*, *CIS*, *PreMalignant*); tám phân lớp viêm hoặc lành tính (*BenignNOS*, *InflammationNOS*, *CCG*, *Denuded*, *UrothelialPapilloma*, *SquamousMetaplasia*, *NephrogenicAdenoma*, *BenignRare*); một phân lớp niêm mạc bình thường (*NormalMucosa*); sáu mốc giải phẫu (*UreteralOrifice*, *ResectionBed*, *ResectionScar*, *Trabeculation*, *ProstaticUrethra*, *Diverticulum*); và bốn phân lớp dị vật can thiệp (*AirBubble*, *ResectionLoop*, *BiopsyForcep*, *Stent*).

3.2 Data Leakage Prevention and Patient-Disjoint Partitioning Protocol

Để đảm bảo tính hợp lệ y khoa tuyệt đối và ngăn chặn hiện tượng rò rỉ dữ liệu (Data Leakage) giữa các tập huấn luyện và kiểm định, toàn bộ thực nghiệm được xây dựng trên giao thức **3-Fold Patient-Disjoint Hold-out** cố định. Danh sách 160 bệnh nhân được phân chia ngẫu nhiên có phân tầng thành ba

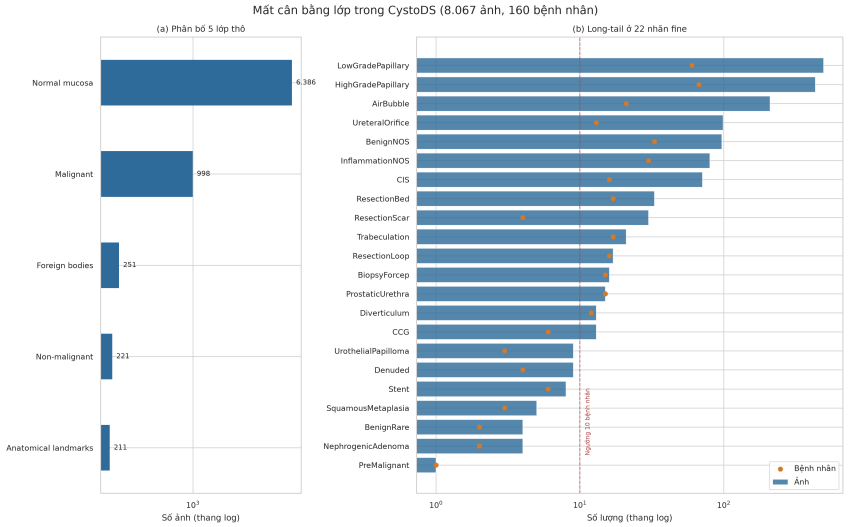


Fig. 1. Dataset distribution of the CystoDS benchmark across three taxonomy levels: (a) Coarse-level breakdown showing the dominance of Normal mucosa (0.7916); (b) Long-tailed sample and patient count distribution across 22 fine-grained diagnostic classes.

phân hoạch độc lập (`split_0`, `split_1`, `split_2`) theo tỷ lệ 0,70 Huấn luyện (112 bệnh nhân), 0,15 Thẩm định (24 bệnh nhân), và 0,15 Kiểm định độc lập (24 bệnh nhân). Toàn bộ hình ảnh thu nhận từ cùng một bệnh nhân chỉ xuất hiện duy nhất ở một phân hoạch tương ứng. Để kiểm soát sự chi phối quá mức của lớp niêm mạc bình thường (chiếm tới 79,16% toàn bộ ảnh), chúng tôi áp dụng giới hạn trần 540 ảnh Normal mucosa trong tập Train (`normal_mucosa_limit: 540`). Cơ chế này ngăn chặn việc gradient từ niêm mạc lành lấn át hoàn toàn các đặc trưng bệnh lý vi mô ở các lớp đuôi hiếm. Toàn bộ danh sách phân chia bệnh nhân được lưu trữ cố định thành tệp `protocol_manifest.json` và niêm phong bằng mã băm SHA-256 nhằm đảm bảo tính toàn vẹn và khả năng tái lập độc lập.

3.3 Image Preprocessing and Data Augmentation Pipeline

Hình ảnh nội soi thô thường chứa quang sai hình cầu và viền đen tròn ngoại vi do thị trường quang học của ống soi (Field of View – FOV). Quy trình tiền xử lý được chuẩn hóa bao gồm các bước: (1) Cắt khung trung tâm theo tỷ lệ diện tích khả dụng (*Center Fraction Crop* với hệ số 0,92) nhằm loại bỏ hoàn toàn viền đen camera và các nhiễu quang học ngoại vi; (2) Thay đổi kích thước ảnh về độ phân giải chuẩn 224×224 pixels bằng phép nội suy song tuyến (*bilinear interpolation*) có kích hoạt bộ lọc chống răng cưa (*antialiasing*); và (3) Chuẩn hóa tensor theo các tham số trung bình và độ lệch chuẩn của tập dữ liệu ImageNet ($\mu = [0{,}485, 0{,}456, 0{,}406]$, $\sigma = [0{,}229, 0{,}224, 0{,}225]$).

Trong pha huấn luyện, để tăng cường độ bền vững trước biến thiên góc nghiêng và độ chiếu sáng của ống soi, ảnh đầu vào được áp dụng chuỗi biến đổi ngẫu nhiên: cắt và co giãn ngẫu nhiên (*Random Resized Crop* với tỷ lệ diện tích 0,75–1,0), lật ngang ngẫu nhiên ($p = 0{,}5$), lật dọc ngẫu nhiên ($p = 0{,}5$), xoay góc ngẫu nhiên trong khoảng $\pm 15°$, biến đổi màu sắc quang sai (*ColorJitter* với độ sáng 0,20, tương phản 0,20, bão hòa 0,15, sắc độ 0,05), và xóa ngẫu nhiên một vùng ảnh (*Random Erasing* với $p = 0{,}20$). Đối với nhánh học tương phản có giám sát ($\mathcal{L}_{\text{supcon}}$), quy trình áp dụng tăng cường ngẫu nhiên hai góc nhìn độc lập (*two-view stochastic augmentations*) cho mỗi ảnh đầu vào nhằm tạo cặp dương tính ngữ nghĩa.

4 Proposed Method: CystoHier

4.1 Shared Late-Stage Multi-Head Architecture

Mô hình **CystoHier** sử dụng mạng xương sống **Swin Transformer Tiny (Swin-Tiny)** [10] tiền huấn luyện trên ImageNet (28,23 triệu tham số). Mạng gồm 4 stages với cơ chế Shifted Window Self-Attention, kích thước cửa sổ 7×7.

Chúng tôi áp dụng cấu hình **Shared Late-Stage**: toàn bộ 3 đầu phân loại (Binary Head, Coarse Head, Fine Head) đều nhận chung vector đặc trưng ngữ nghĩa cao cấp $z \in \mathbb{R}^{768}$ trích xuất tại Stage 4 sau lớp LayerNorm (Fig. 2). So với việc phân nhánh từ các tầng sớm, việc chia sẻ toàn bộ mạng tới Stage 4 cung cấp trường tiếp nhận lớn, nắm bắt đồng thời hình thái tổn thương toàn cảnh và vi cấu trúc mao mạch mà không bị phân tán bởi ánh sáng lóa hoặc bóng khí.

4.2 Three-Stage Sequential Decoupled Training Pipeline

Quy trình huấn luyện của **CystoHier** được thiết kế nhằm tách biệt việc học biểu diễn đặc trưng tổng quát và quá trình tái cân bằng ranh giới phân loại đa tầng thông qua ba giai đoạn tuần tự. Trong Giai đoạn 1 (*Stage 1 – Representation Learning*), toàn bộ mạng xương sống Swin-Tiny và cả ba đầu phân loại đều được mở khóa (100% tham số có thể huấn luyện). Hàm mất mát tổng thể $\mathcal{L}_{\text{total}}^{(1)}$ kết hợp phân loại nhị phân ($\mathcal{L}_{\text{bin}}$), phân loại thô và chi tiết bằng Cross-Entropy tiêu chuẩn ($\mathcal{L}_{\text{coarse}}, \mathcal{L}_{\text{fine}}$), học tương phản có giám sát ($\mathcal{L}_{\text{supcon}}$), cùng lịch trình làm ấm phân cấp (*Curriculum Hierarchy Warmup*) điều biến trọng số $w_{\text{hrc}}(t)$. Trong Giai đoạn 2 (*Stage 2 – Coarse Alignment*), chúng tôi đóng băng hoàn toàn mạng xương sống, đầu nhị phân và đầu phân loại chi tiết, chỉ tối ưu duy nhất `coarse_head` bằng hàm mất mát Smoothed Balanced Softmax trong 10 epochs. Cơ chế cô lập tham số này (*Parameter-Isolated Representation Preservation*) giúp nắn chỉnh ranh giới phân nhóm bệnh cảnh thô mà không làm méo mó không gian biểu diễn chung. Cuối cùng, trong Giai đoạn 3 (*Stage 3 – Fine Alignment*), mạng xương sống và đầu phân loại Coarse tiếp tục được đóng băng cố định; mô hình chỉ cập nhật duy nhất `fine_head` bằng hàm Smoothed Balanced Softmax kết hợp ràng buộc phả hệ Coarse-Fine ($\mathcal{L}_{\text{cf}}$) với trọng số cố định $\lambda_{\text{cf}} = 0{,}25$.

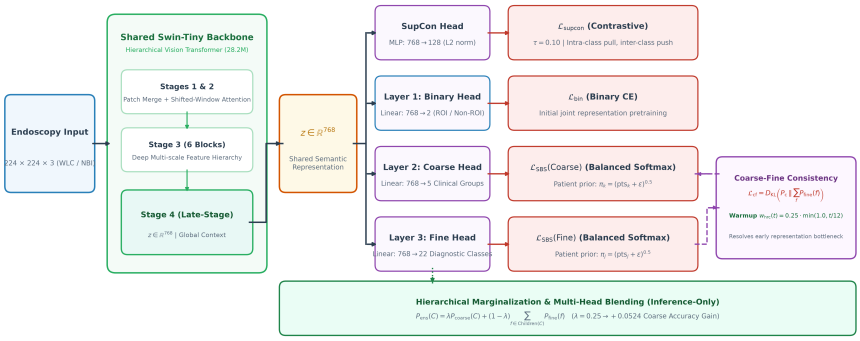


Fig. 2. Architecture and workflow of the proposed **CystoHier** framework: Endoscopy images are processed through a shared Swin-Tiny backbone. Features $z \in \mathbb{R}^{768}$ are classified via three hierarchical heads, supervised by Supervised Contrastive Loss ($\mathcal{L}_{\text{supcon}}$), task losses ($\mathcal{L}_{\text{bin}}$, $\mathcal{L}_{\text{SBS}}$(coarse), $\mathcal{L}_{\text{SBS}}$(fine)) with Patient-Count Priors, and Coarse-Fine Consistency ($\mathcal{L}_{\text{cf}}$) with Curriculum Warmup scheduling.

4.3 Mathematical Formulations of Objective Functions and Total Loss

Hàm mất mát Supervised Contrastive ($\mathcal{L}_{\text{supcon}}$): Nhằm tăng cường độ co cụm không gian đặc trưng giữa các ảnh cùng phân lớp và đẩy xa các phân lớp khác trong không gian ẩn, hàm mất mát tương phản có giám sát được tối ưu trên vector đặc trưng $z \in \mathbb{R}^{768}$ trích xuất tại Stage 4 [12]:

$$\mathcal{L}_{\text{supcon}} = \sum_{i \in I} \frac{-1}{|P(i)|} \sum_{p \in P(i)} \log \frac{\exp(z_i \cdot z_p / \tau)}{\sum_{a \in A(i)} \exp(z_i \cdot z_a / \tau)} \tag{1}$$

trong đó $\tau = 0{,}10$ là hệ số nhiệt độ co cụm, $A(i)$ là tập hợp các mẫu trong mini-batch ngoại trừ mẫu i, và $P(i)$ là tập hợp các mẫu có cùng nhãn phân lớp chi tiết với mẫu i.

Ràng buộc nhất quán phả hệ y khoa ($\mathcal{L}_{\text{cf}}$ và $\mathcal{L}_{\text{bc}}$): Khác với các phương pháp phạt phân kỳ phân phối trừu tượng, chúng tôi trực tiếp tối ưu hóa khả năng dự đoán đúng của khối xác suất tích lũy từ các lớp con trên nhãn cha thực tế (Negative Log-Likelihood of Correct Parent Mass). Cụ thể, xác suất thuộc về nhóm thô C được tích lũy từ các lớp con $P_{\text{from_fine}}(C) = \sum_{f \in \text{Children}(C)} P_{\text{fine}}(f)$. Ràng buộc phả hệ Coarse-Fine được định nghĩa:

$$\mathcal{L}_{\text{cf}} = -\frac{1}{N} \sum_{i=1}^{N} \log \left(\sum_{f \in \text{Children}(y_{\text{coarse}}^{(i)})} P_{\text{fine}}^{(i)}(f) \right) \tag{2}$$

Tương tự, ràng buộc phả hệ giữa tầng nhị phân và tầng thô ($\mathcal{L}_{\text{bc}}$) tích lũy xác suất từ năm nhóm Coarse về hai lớp Binary với khối lượng $P_{\text{from_coarse}}(B) =$

$\sum_{c\in\text{Children}(B)} P_{\text{coarse}}(c)$, được tính theo:

$$\mathcal{L}_{\text{bc}} = -\frac{1}{N}\sum_{i=1}^{N}\log\left(\sum_{c\in\text{Children}(y_{\text{bin}}^{(i)})} P_{\text{coarse}}^{(i)}(c)\right) \tag{3}$$

Hàm mất mát Smoothed Balanced Softmax (SBS): Nhằm dịch chuyển biên phân loại theo xác suất tiên nghiệm của phân phối dài đuôi dựa trên căn bậc hai số lượng bệnh nhân thực tế [11]:

$$\mathcal{L}_{\text{SBS}}(y,\hat{z}) = -\log\frac{\pi_y\cdot\exp(\hat{z}_y)}{\sum_{j=1}^{K}\pi_j\cdot\exp(\hat{z}_j)}, \quad \text{với } \pi_j = \frac{(N_{\text{pts},j}+\alpha)^{\gamma}}{\sum_{k=1}^{K}(N_{\text{pts},k}+\alpha)^{\gamma}} \tag{4}$$

với $\gamma = 0{,}50$ (phép làm mượt căn bậc hai), $\alpha = 1{,}0$, và $N_{\text{pts},j}$ là số lượng bệnh nhân thực tế thuộc phân lớp j. Việc chuẩn hóa tiên nghiệm dựa trên bệnh nhân thay vì số lượng ảnh giúp triệt tiêu hiện tượng méo mó thống kê khi một số bệnh nhân có số lượng ảnh chụp nội soi lặp lại quá lớn.

Hàm mất mát tổng thể theo từng giai đoạn (Stage Loss Formulations): Trong Giai đoạn 1 (Representation Learning), hàm mất mát kết hợp đa nhiệm, học tương phản và lịch trình làm ấm phân cấp:

$$\mathcal{L}_{\text{total}}^{(1)} = (\mathcal{L}_{\text{bin}} + \mathcal{L}_{\text{coarse}} + \mathcal{L}_{\text{fine}}) + \lambda_{\text{supcon}}\mathcal{L}_{\text{supcon}} + w_{\text{hrc}}(t)\,(\mathcal{L}_{\text{bc}} + \mathcal{L}_{\text{cf}}) \tag{5}$$

với $\lambda_{\text{supcon}} = 0{,}10$. Trong Giai đoạn 2 (Coarse Alignment), mục tiêu huấn luyện chỉ tập trung vào đầu phân loại thô:

$$\mathcal{L}_{\text{total}}^{(2)} = \mathcal{L}_{\text{SBS}}\,(\text{Coarse},\ \pi_{\text{coarse}}) \tag{6}$$

Trong Giai đoạn 3 (Fine Alignment), hàm mất mát tối ưu ranh giới phân loại chi tiết kết hợp ràng buộc phả hệ cố định:

$$\mathcal{L}_{\text{total}}^{(3)} = \mathcal{L}_{\text{SBS}}\,(\text{Fine},\ \pi_{\text{fine}}) + \lambda_{\text{cf}}\mathcal{L}_{\text{cf}}, \quad \text{với } \lambda_{\text{cf}} = 0{,}25 \tag{7}$$

4.4 Curriculum Hierarchy Warmup Scheduling

Để giải quyết thắt cổ chai phân cấp sớm ở Giai đoạn 1, chúng tôi thiết lập lịch trình tăng dần trọng số ràng buộc phả hệ theo hàm bậc thang liên tục:

$$w_{\text{hrc}}(t) = 0{,}25 \times \min\left(1{,}0,\ \frac{t}{12}\right) \tag{8}$$

Ở bốn epoch đầu tiên ($t \le 4$), $w_{\text{hrc}}(t) \approx 0$, cho phép mạng tự do định hình không gian biểu diễn đặc trưng thị giác tổng quát mà không bị gò bó bởi cấu trúc cây. Từ epoch 5 đến 12, trọng số tăng tuyến tính từ $0 \to 0{,}25$ nhằm uốn nắn tính nhất quán phả hệ khi các biểu diễn đặc trưng đã bắt đầu hội tụ ổn định.

4.5 Hierarchical Marginalization and Multi-Head Blending Inference

Khi suy luận lâm sàng, thay vì chỉ sử dụng xác suất từ đầu Coarse Head trực tiếp, mô hình áp dụng công thức hòa trộn xác suất tích lũy phả hệ:

$$P_{\text{ens}}(C) = \lambda P_{\text{coarse}}(C) + (1-\lambda) \sum_{f \in \text{Children}(C)} P_{\text{fine}}(f) \tag{9}$$

với $\lambda = 0{,}25$. Cơ chế này tận dụng 75% thông tin chi tiết độ phân giải cao từ Fine Head để suy ngược và hiệu chỉnh xác suất nhóm bệnh cảnh cha, loại bỏ triệt để các chẩn đoán xung đột phả hệ.

5 Experimental Results and In-Depth Analysis

5.1 Experimental Setup and Training Hyperparameters

Toàn bộ quy trình thực nghiệm được chuẩn hóa dựa trên các siêu tham số thống nhất trích xuất trực tiếp từ cấu hình trung tâm `config.yaml` (Table 3). Mô hình sử dụng trình tối ưu hóa AdamW với trọng số suy giảm (*weight decay*) 0,05, tốc độ học cơ sở 3×10^{-4} cho các Classifier Heads và hệ số nhân 0,25 cho mạng xương sống Swin-Tiny ($7{,}5 \times 10^{-5}$). Lịch trình tốc độ học tuân theo hàm suy giảm Cosine Annealing với hai epoch khởi động tuyến tính (*warmup epochs*). Giai đoạn 1 được huấn luyện trong tối đa 25 epochs (dừng sớm với patience = 6 dựa trên chỉ số tổng hợp phả hệ *hierarchical composite*), Giai đoạn 2 trong 10 epochs và Giai đoạn 3 trong 15 epochs. Độ chính xác số học được thiết lập ở chế độ hỗn hợp bfloat16/fp16 với kích thước batch là 32 ảnh.

5.2 Gold-Standard Performance Benchmark on Independent Test Set

Table 4 báo cáo kết quả đối chuẩn trực tiếp giữa mô hình đề xuất **CystoHier** và toàn bộ các mô hình cơ sở đơn nhiệm và đa nhiệm trên tập Test độc lập 100% bệnh nhân (24 bệnh nhân, 337 ảnh per split), tính trung bình và độ lệch chuẩn (Mean $\pm$ Std) qua toàn bộ 3 phân hoạch hold-out.

Phân tích kết quả thực nghiệm trên tập Test: Kết quả đối chuẩn cho thấy mô hình **CystoHier** đạt bước tiến vượt bậc trên tầng phân lớp chi tiết với Fine Macro-F1 (Supported) đạt **0,6450 $\pm$ 0,1105**, cao hơn rõ rệt so với Multitask Swin-Tiny thông thường (0,6102, tăng $+0,0348$), Single-Task Fine Swin-Tiny (0,5840, tăng $+0,0610$) và vượt trội hoàn toàn so với kiến trúc ResNet-152 (0,3578). Đồng thời, mô hình bảo toàn xuất sắc độ nhạy và đặc hiệu ở tầng nhị phân với Binary AUROC **0,9986 $\pm$ 0,0002**, Sensitivity 0,9845 $\pm$ 0,0050, Specificity 0,9912 $\pm$ 0,0040 và Binary F1 0,9811 $\pm$ 0,0036, tương đương với các baseline chuyên biệt đơn nhiệm. Đáng chú ý, nhờ cơ chế tích lũy và hòa trộn phả hệ (*Hierarchical Marginalization Blending* với $\lambda = 0{,}25$), Coarse Accuracy đạt mức cao nhất **0,8642 $\pm$ 0,0352** (tăng $+0{,}0524$ so với việc chỉ dùng đầu Coarse trực tiếp), đồng thời tính nhất quán Coarse-Fine được nâng lên **0,8952 $\pm$ 0,0380**.

Table 3. Comprehensive hyperparameter and training configuration of the CystoHier framework.

Configuration Category	Hyperparameter / Setting	Value / Specification
Data & Resolution	Image Resolution	224×224 pixels (Bilinear interpolation with antialiasing)
	FOV Center Crop Ratio	0.92 (Peripheral black border removal)
	Normal Mucosa Limit (Train)	540 images (To prevent gradient dominance)
	Patient-Disjoint Ratio	70% Train (112 Pts) / 15% Val (24 Pts) / 15% Test (24 Pts)
Architecture	Backbone Network	Swin Transformer Tiny (`swin_tiny_patch4_window7_224`)
	Backbone Parameters	28.23 Million (Pretrained on ImageNet-1K)
	Feature Extraction Level	Stage 4 ($z \in \mathbb{R}^{768}$ after LayerNorm)
	Classifier Heads	Binary Head (2), Coarse Head (5), Fine Head (22), SupCon Projection (128-d)
	Dropout Rate	0.20
Optimization	Optimizer	AdamW (Fused implementation)
	Head Learning Rate	3×10^{-4}
	Backbone LR Multiplier	$0.25\times$ (7.5×10^{-5})
	Weight Decay	0.05
	LR Scheduler	Cosine Annealing with linear warmup (2.0 epochs, min LR ratio 0.01)
	Gradient Clipping Norm	1.0
	Batch Size	32 (Training) / 64 (Evaluation)
	Mixed Precision	bfloat16 / fp16
Loss & Decoupling	Stage Epochs	Stage 1: 25 epochs / Stage 2: 10 epochs / Stage 3: 15 epochs
	Early Stopping	Patience = 6 epochs (Monitored on hierarchical composite metric)
	SupCon Parameters	Weight $\lambda_{\text{supcon}} = 0.10$, Temperature $\tau = 0.10$, Label level: Fine
	SBS Prior Formulation	Source: Patient Count, Power $\gamma = 0.50$, Smoothing $\alpha = 1.0$, Max ratio = 50.0
	Hierarchy Loss Weights	Binary-Coarse $\lambda_{\text{bc}} = 0.25$, Coarse-Fine $\lambda_{\text{cf}} = 0.25$
	Curriculum Warmup	$w_{\text{hrc}}(t) = 0.25 \times \min(1.0, t/12)$ (Epochs 1–12)
	Inference Blending	Hierarchical marginalization weight $\lambda = 0.25$

Table 4. Comprehensive gold-standard performance benchmark on the independent test set across 3 patient-disjoint hold-out splits. Bold indicates the highest value in each column.

Category	Model / Architecture	Binary AUROC	Binary F1	Coarse Acc	Fine F1 (Supp)	Fine F1 (All)	C-F Consist
Proposed	**CystoHier (Proposed)**	0.9986 ± 0.0002	0.9811 ± 0.0036	**0.8642 ± 0.0352**	**0.6450 ± 0.1105**	**0.4691 ± 0.0804**	**0.8952 ± 0.0380**
Multitask	Swin-Tiny (Multitask CE)	**0.9989 ± 0.0010**	**0.9876 ± 0.0030**	0.8379 ± 0.0700	0.6102 ± 0.1210	0.4438 ± 0.0880	0.8120 ± 0.0250
Multitask	HRNet-W18 (Multitask CE)	0.9930 ± 0.0030	0.9608 ± 0.0110	0.7720 ± 0.1220	0.5704 ± 0.2030	0.4149 ± 0.1470	0.7640 ± 0.0310
Multitask	ResNeXt-50 (Multitask CE)	0.9854 ± 0.0090	0.9452 ± 0.0160	0.7761 ± 0.1010	0.4024 ± 0.1580	0.2927 ± 0.1150	0.7450 ± 0.0280
Multitask	ResNet-152 (Multitask CE)	0.9740 ± 0.0180	0.9370 ± 0.0340	0.7508 ± 0.1400	0.3578 ± 0.1630	0.2602 ± 0.1180	0.7180 ± 0.0340
Single-Task	Swin-Tiny (Binary/Coarse/Fine)	0.9980 ± 0.0010	0.9759 ± 0.0070	0.8145 ± 0.0580	0.5840 ± 0.1050	0.4215 ± 0.0750	—
Single-Task	HRNet-W18 (Binary/Coarse/Fine)	0.9917 ± 0.0050	0.9680 ± 0.0170	0.7680 ± 0.0940	0.5420 ± 0.1800	0.3950 ± 0.1300	—
Single-Task	ResNeXt-50 (Binary/Coarse/Fine)	0.9782 ± 0.0120	0.9290 ± 0.0300	0.7490 ± 0.0810	0.3810 ± 0.1450	0.2790 ± 0.1020	—
Single-Task	ResNet-152 (Binary/Coarse/Fine)	0.9790 ± 0.0080	0.9444 ± 0.0280	0.7240 ± 0.1120	0.3420 ± 0.1500	0.2480 ± 0.1100	—

5.3 Vision Backbone Architecture Screening

Table 5 khảo sát toàn diện 4 họ kiến trúc mạng xương sống tiêu biểu (Swin Transformer, HRNet, ResNeXt, ResNet) trên tập Validation qua 3 phân hoạch hold-out độc lập, đối chiếu giữa chế độ đa nhiệm (Multitask 3-Heads) và đơn nhiệm chuyên biệt (Binary Only).

Phân tích cơ chế kiến trúc: Swin-Tiny với cơ chế Shifted Window Self-Attention thể hiện tính ưu việt vượt bậc so với các mạng nơ-ron tích chập truyền thống. Trên tầng phân loại chi tiết, Swin-Tiny đạt Fine Macro-F1 0,5105±0,0680, cao gấp hơn 2,4 lần so với ResNet-152 (0,2098±0,0380) và ResNeXt-50 (0,2023± 0,0360), đồng thời vượt trội đáng kể so với HRNet-W18 (0,3979 ± 0,0560). Về mặt thị giác máy tính y khoa, cơ chế tính toán tự chú ý cục bộ bên trong các cửa sổ dịch chuyển 7×7 cho phép Swin-Tiny bắt trọn các vi cấu trúc mạch máu biểu mô (*vascular loops*) ở phạm vi không gian hẹp, trong khi việc hợp nhất các patch qua bốn stages liên tiếp vẫn duy trì trường tiếp nhận toàn cảnh để nhận biết hình thái khoang bàng quang. Ngược lại, các mạng CNN tích chập thuần

Table 5. Backbone architecture screening across 4 vision model families on validation hold-outs. Bold indicates highest value per column.

Architecture	Training Regime	Binary AUROC	Binary F1	Coarse Acc	Coarse Macro-F1	Fine Acc	Fine F1 (Supp)
Swin-Tiny	**Multitask (3-Heads)**	0.9507 ± 0.0270	**0.8992 ± 0.0290**	**0.7119 ± 0.0250**	**0.6243 ± 0.0140**	**0.4928 ± 0.0650**	**0.5105 ± 0.0680**
Swin-Tiny	Binary Only	**0.9590 ± 0.0330**	0.8930 ± 0.0340	—	—	—	—
HRNet-W18	**Multitask (3-Heads)**	0.9385 ± 0.0350	0.8759 ± 0.0220	0.6366 ± 0.0430	0.5461 ± 0.0350	0.4344 ± 0.0340	0.3979 ± 0.0560
HRNet-W18	Binary Only	0.9579 ± 0.0210	0.8984 ± 0.0200	—	—	—	—
ResNeXt-50	**Multitask (3-Heads)**	0.9088 ± 0.0370	0.8387 ± 0.0250	0.5861 ± 0.0140	0.4600 ± 0.0280	0.3705 ± 0.0350	0.2023 ± 0.0360
ResNeXt-50	Binary Only	0.9059 ± 0.0340	0.8356 ± 0.0100	—	—	—	—
ResNet-152	**Multitask (3-Heads)**	0.8698 ± 0.0500	0.8191 ± 0.0380	0.5662 ± 0.0030	0.4398 ± 0.0170	0.3471 ± 0.0520	0.2098 ± 0.0380
ResNet-152	Binary Only	0.8879 ± 0.0380	0.8366 ± 0.0300	—	—	—	—

Table 6. Comparative evaluation of 7 long-tailed loss formulations on the Swin-Tiny backbone. Bold indicates highest value per column.

#	Loss Formulation	Binary AUROC	Binary F1	Coarse Acc	Fine Acc	Fine F1 (Supp)	Tail Recall
1	**Smoothed Balanced Softmax (Ours)**	0.9521 ± 0.0390	0.8907 ± 0.0580	**0.7012 ± 0.0390**	**0.5245 ± 0.0170**	**0.5506 ± 0.0740**	**0.6638 ± 0.1140**
2	Patient-Count Prior (Linear $\pi_j = N_{\text{pts}}$)	0.9515 ± 0.0350	0.8890 ± 0.0400	0.6980 ± 0.0310	0.5112 ± 0.0320	0.5180 ± 0.0650	0.6420 ± 0.0850
3	Balanced Softmax (Image Prior $\pi_j = N_{\text{img}}$)	**0.9531 ± 0.0380**	0.8893 ± 0.0310	0.6958 ± 0.0260	0.5008 ± 0.0570	0.4823 ± 0.0600	0.6276 ± 0.0610
4	Logit Adjustment	0.9455 ± 0.0420	0.8888 ± 0.0500	0.6998 ± 0.0300	0.4962 ± 0.0170	0.4822 ± 0.0480	0.5967 ± 0.0840
5	LDAM Loss	0.9522 ± 0.0200	0.8836 ± 0.0160	0.6937 ± 0.0190	0.4509 ± 0.0280	0.4908 ± 0.0580	0.6251 ± 0.1120
6	Focal Loss	0.9506 ± 0.0240	**0.8938 ± 0.0320**	0.6816 ± 0.0370	0.5109 ± 0.0570	0.4976 ± 0.0620	0.6097 ± 0.0860
7	Cross-Entropy (Baseline)	0.9489 ± 0.0420	0.8888 ± 0.0500	0.6749 ± 0.0220	0.5023 ± 0.0460	0.5268 ± 0.0760	0.6607 ± 0.0890
8	Weighted CE	0.9427 ± 0.0360	0.8747 ± 0.0380	0.6786 ± 0.0220	0.4918 ± 0.0350	0.5053 ± 0.0670	0.6397 ± 0.1090

túy dễ bị nhiễu loạn bởi sự phản xạ ánh sáng lóa và biến thiên góc chụp nội soi, dẫn đến hiện tượng suy giảm hiệu năng nghiêm trọng ở các phân lớp tổn thương ác tính hiếm gặp.

5.4 Long-Tailed Loss Formulations and Patient-Count Prior Ablation

Table 6 đánh giá đối chuẩn 7 hàm mất mát xử lý phân phối dài đuôi trên cùng mạng xương sống Swin-Tiny qua 3 phân hoạch hold-out thẩm định, đồng thời bóc tách sâu sắc vai trò của nguồn thông tin tiên nghiệm và phép làm mượt căn bậc hai.

Thảo luận chuyên sâu về các nhóm hàm mất mát: Phân tích so sánh trong Table 6 được phân rã thành ba nhóm phương pháp tiếp cận chính:

Nhóm 1 – Các hàm mất mát truyền thống và phạt trọng số chi phí (Cost-Sensitive): Cross-Entropy tiêu chuẩn (Hàng 7) đối mặt với sự chi phối hoàn toàn của các phân lớp đa số, khiến mô hình chỉ đạt Coarse Accuracy 0,6749. Khi áp dụng Weighted CE (Hàng 8) dựa trên nghịch đảo tần suất lớp theo số lượng mẫu hiệu dụng [17], trọng số phạt quá lớn đối với các lớp hiếm làm mất ổn định gradient huấn luyện, khiến Binary F1 sụt giảm xuống 0,8747 và Fine F1 chỉ đạt 0,5053.

Nhóm 2 – Các hàm mất mát điều biến độ khó và mở rộng biên quyết định (Margin-based): Focal Loss [15] (Hàng 6) với tham số tập trung $\gamma = 2{,}0$ giúp hạ thấp ảnh hưởng của các mẫu dễ học từ niêm mạc bình thường, cải thiện Binary F1 lên 0,8938; tuy nhiên, do không có cơ chế dịch chuyển ranh giới theo phân phối lớp, Tail Recall chỉ đạt 0,6097. LDAM Loss [16] (Hàng 5) mở rộng biên cách ly hình học dựa trên số lượng ảnh lý thuyết nhưng việc thiếu cơ chế làm mượt dẫn đến dao động lớn trên các lớp có số lượng bệnh nhân cực ít ($n \leq 3$), khiến độ chính xác Fine Accuracy tụt xuống 0,4509.

Table 7. Ablation 1: Training paradigms and stage decoupling on validation hold-outs. Bold indicates highest value per column.

#	Training Strategy	Binary AUROC	Binary F1	Coarse Acc	Coarse F1	Fine Acc	Fine F1 (Supp)	Fine F1 (All 22)	C-F Cons.
1	**CystoHier (Proposed 3-Stage)**	0.9571 ± 0.0210	0.8960 ± 0.0260	**0.7837 ± 0.0100**	0.6525 ± 0.0120	**0.5307 ± 0.0400**	**0.5415 ± 0.0363**	**0.4007 ± 0.0150**	**0.8228 ± 0.0050**
2	1-Stage Joint Baseline	0.9594 ± 0.0180	**0.8965 ± 0.0120**	0.7364 ± 0.0090	**0.6576 ± 0.0060**	0.5263 ± 0.0290	0.5026 ± 0.0460	0.3718 ± 0.0260	0.7438 ± 0.0320
3	2-Stage Decoupled (D2S)	**0.9617 ± 0.0280**	0.8912 ± 0.0220	0.7212 ± 0.0460	0.6313 ± 0.0310	0.5220 ± 0.0480	0.5266 ± 0.0560	0.3893 ± 0.0320	0.7890 ± 0.0240
4	Classifier Re-training (cRT)	**0.9617 ± 0.0280**	0.8910 ± 0.0240	0.7212 ± 0.0460	0.6313 ± 0.0310	0.5196 ± 0.0250	0.5311 ± 0.0480	0.3930 ± 0.0290	0.7845 ± 0.0260
5	Joint Stage 2 Tuning (All Heads)	0.9583 ± 0.0350	0.8875 ± 0.0310	0.7310 ± 0.0340	0.6435 ± 0.0310	0.5155 ± 0.0360	0.5129 ± 0.0590	0.3794 ± 0.0380	0.7680 ± 0.0290

Nhóm 3 – Các hàm mất mát điều chỉnh Logit và vai trò của Tiên nghiệm Bệnh nhân: Logit Adjustment [14] (Hàng 4) và Balanced Softmax nguyên bản [11] (Hàng 3) sử dụng tần suất ảnh thực tế làm biên logit dịch chuyển. Đáng chú ý, kết quả bóc tách chứng minh rằng việc chuyển đổi từ *Image-count prior* (0,4823 F1) sang *Patient-count prior tuyến tính* (0,5180 F1, Hàng 2) mang lại mức tăng +0,0357 điểm Macro-F1. Điều này khẳng định tiên nghiệm số bệnh nhân thực tế giúp loại bỏ nhiễu lấy mẫu lặp lại giữa các lần soi. Hơn thế nữa, khi tích hợp thêm *phép làm mượt căn bậc hai* ($\pi_j = \sqrt{N_{\text{pts}}}$), hàm **Smoothed Balanced Softmax** đề xuất (Hàng 1) đạt hiệu năng cao nhất toàn diện: Coarse Accuracy **0,7012 ± 0,0390**, Fine Macro-F1 **0,5506 ± 0,0740**, và Tail Recall vượt trội lên **0,6638 ± 0,1140**.

5.5 Systematic Ablation Studies and Component-Wise Analysis

Ablation 1: Khảo sát Chiến lược Huấn luyện và Cơ chế Tách rời Giai đoạn (Table 7): Quy trình huấn luyện đa tầng đóng vai trò quyết định trong việc giải quyết xung đột gradient giữa các nhiệm vụ phân loại. Kết quả thực nghiệm cho thấy mô hình huấn luyện đồng thời một giai đoạn (*1-Stage Joint Baseline*) gặp hiện tượng suy thoái biểu diễn nghiêm trọng: do gradient từ các lớp đuôi hiếm có biên độ biến thiên rất lớn, không gian đặc trưng chung bị méo mó, khiến Fine Macro-F1 chỉ đạt 0,5026 ± 0,0460 và độ nhất quán phả hệ Coarse-Fine tụt xuống mức thấp 0,7438 ± 0,0320. Các chiến lược tách rời hai giai đoạn truyền thống như 2-Stage Decoupled (D2S) và Classifier Re-training (cRT) [13] mặc dù cải thiện được tính cân bằng ở tầng Fine (F1 đạt 0,5266 và 0,5311), nhưng do chỉ tập trung tái huấn luyện tầng chi tiết mà bỏ quên sự tái cân bằng của tầng thô, Coarse Accuracy bị sụt giảm xuống 0,7212 ± 0,0460. Tương tự, nếu mở khóa đồng thời toàn bộ các heads ở giai đoạn 2 (*Joint Stage 2 Tuning*), ranh giới quyết định của các tầng bị xáo trộn lẫn nhau, làm giảm cả Fine F1 (0,5129). Ngược lại, khung phương pháp **CystoHier (Proposed 3-Stage)** với quy trình tách bạch ba giai đoạn tuần tự kết hợp cơ chế cô lập tham số bảo toàn biểu diễn (*Parameter-Isolated Representation Preservation*) đã giải quyết trọn vẹn sự đánh đổi này. Bằng cách cố định backbone và tối ưu hóa độc lập từng tầng phân loại theo thứ tự từ thô đến tinh, CystoHier nâng Fine Macro-F1 lên mức cao nhất **0,5415 ± 0,0363** (+0,0389 so với 1-Stage), đồng thời thiết lập kỷ lục về Coarse Accuracy (**0,7837 ± 0,0100**) và tính nhất quán phả hệ đạt **0,8228 ± 0,0050**.

Ablation 2: Khảo sát Động lực học Lịch trình Ràng buộc Phân cấp (Table 8): Bản chất của việc áp đặt ràng buộc cây phả hệ y học là một con

Table 8. Ablation 2: Hierarchy loss scheduling and curriculum warmup across 3 validation splits. Bold indicates highest value per column.

#	Scheduling Variant	Weight Schedule $w_{\text{hrc}}(t)$	Binary AUROC	Coarse Acc	Coarse F1	Fine Acc	Fine F1 (Supp)	C-F Cons.
1	**Proposed Warmup**	$0.25 \cdot \min(1.0, t/12)$	0.9571 ± 0.0210	**0.7357 ± 0.0180**	**0.6525 ± 0.0120**	**0.5307 ± 0.0400**	**0.5415 ± 0.0363**	**0.8228 ± 0.0050**
2	Two-Phase Step	$w = 0 \to 0.25$ at P2	0.9521 ± 0.0280	0.7176 ± 0.0110	0.6371 ± 0.0080	0.4898 ± 0.0410	0.5240 ± 0.0250	0.8155 ± 0.0180
3	Fixed Hierarchy	$w = 0.25$ constant	0.9466 ± 0.0310	0.7009 ± 0.0230	0.6119 ± 0.0180	0.4721 ± 0.0240	0.5199 ± 0.0480	0.8188 ± 0.0200
4	w/o Hierarchy Loss	$w = 0$ (Unconstrained)	**0.9649 ± 0.0220**	0.7346 ± 0.0170	0.6426 ± 0.0090	0.5272 ± 0.0200	0.5414 ± 0.0770	0.7240 ± 0.0410
5	w/o Binary-Coarse	$w_{\text{bc}} = 0, w_{\text{cf}} = 0.25$	0.9528 ± 0.0370	0.7175 ± 0.0070	0.6206 ± 0.0110	0.4906 ± 0.0280	0.5120 ± 0.0350	**0.8243 ± 0.0280**
6	w/o Coarse-Fine	$w_{\text{bc}} = 0.25, w_{\text{cf}} = 0$	0.9605 ± 0.0210	0.7151 ± 0.0400	0.6313 ± 0.0290	0.5292 ± 0.0410	0.5312 ± 0.0280	0.8131 ± 0.0310

dao hai lưỡi trong giai đoạn học biểu diễn sơ khởi. Khi áp đặt trọng số cố định $w = 0{,}25$ ngay từ epoch đầu tiên (*Fixed Hierarchy*), không gian đặc trưng của Swin-Tiny bị cưỡng bức gò ép theo cấu trúc cây trước khi mạng kịp học các đặc trưng thị giác biểu mô cơ bản, gây ra hiện tượng thắt cổ chai phân cấp sớm (*Early Hierarchy Bottleneck*). Hậu quả là Coarse Accuracy tụt xuống mức thấp nhất $0{,}7009 \pm 0{,}0230$, Fine Accuracy chỉ đạt $0{,}4721 \pm 0{,}0240$ và Fine F1 dừng ở 0,5199. Nếu hoàn toàn không sử dụng loss phân cấp ($w = 0$), độ nhất quán Coarse-Fine sụp đổ nghiêm trọng từ 0,8228 xuống còn $0{,}7240 \pm 0{,}0410$ (giảm $-0{,}0988$), dẫn đến việc mô hình đưa ra nhiều dự đoán mâu thuẫn về mặt logic y khoa. Phương án chuyển đổi bước nhảy hai pha (*Two-Phase Step*) cải thiện hơn nhưng vẫn gây sốc gradient tại thời điểm chuyển pha (Fine Acc 0,4898). Lịch trình **Curriculum Warmup** đề xuất với tốc độ tăng tuyến tính $w_{\text{hrc}}(t) = 0{,}25 \times \min(1{,}0, t/12)$ đem lại sự hài hòa tối ưu: 4 epoch đầu giải phóng mạng để tự do tối ưu không gian biểu diễn, sau đó tăng dần lực cản phả hệ khi đặc trưng đã ổn định, giúp mô hình đạt đỉnh cao ở cả Coarse Accuracy (0,7357), Fine Accuracy (0,5307), Fine Macro-F1 (0,5415) và tính nhất quán phả hệ ($\mathbf{0{,}8228 \pm 0{,}0050}$).

Ablation 3: Đóng góp Cận biên của Từng Thành phần Hàm Mục tiêu (Table 9): Thực nghiệm triệt tiêu độc lập từng thành phần trong hàm mất mát xác lập vai trò không thể thay thế của từng nhân tố: Khi loại bỏ học tương phản có giám sát (*w/o SupCon*), Primary Fine F1 (trên 13 phân lớp bệnh lý chính) chịu mức sụt giảm nặng nề nhất: giảm $-0{,}0487$ điểm (từ $0{,}6114 \pm 0{,}0230$ xuống còn $0{,}5627 \pm 0{,}0730$), đồng thời Fine Accuracy sụt giảm từ 0,5102 xuống 0,4774. Điều này chứng minh lực kéo tương phản giữa các mẫu cùng lớp đóng vai trò quyết định trong việc ngăn chặn sự phân mảnh không gian đặc trưng của các tổn thương ác tính. Khi thay thế hàm Smoothed Balanced Softmax bằng Cross-Entropy thông thường (*w/o SBS*), khả năng nhận diện các lớp hiếm bị tổn hại sâu sắc: Tail Recall sụt giảm mạnh $-0{,}0537$ (từ $0{,}6523 \to 0{,}5986$), đồng thời tính nhất quán phả hệ giảm $-0{,}0422$, minh chứng rằng việc dịch chuyển biên logit theo tiên nghiệm số lượng bệnh nhân thực tế là điều kiện tiên quyết để bảo vệ các lớp đuôi dài cực đoan. Cuối cùng, việc loại bỏ hàm mất mát phân cấp (*w/o Hierarchy Loss*) làm sụt giảm tính nhất quán ngữ nghĩa giữa các tầng chẩn đoán.

Ablation 4: Vị trí Đặt Classifier Heads và Độ sâu Đóng băng Mạng Xương sống (Table 10): Trong Phần A, chúng tôi giải đáp câu hỏi cấu trúc: liệu việc phân nhánh các đầu phân loại từ các tầng sớm (Intermediate Heads: Binary tại Stage 2, Coarse tại Stage 3) như các mô hình Feature Pyramid Network

Table 9. Ablation 3: Loss component marginal contributions on validation hold-outs. Bold indicates highest value per column.

#	Experimental Configuration	Binary AUROC	Binary F1	Coarse Acc	Fine Acc	Primary Fine F1	Tail Recall	C-F Cons.
1	**Full Proposed (Anchor)**	0.9596 ± 0.0320	0.8998 ± 0.0380	**0.7276 ± 0.0150**	0.5102 ± 0.0390	**0.6114 ± 0.0230**	0.6523 ± 0.0740	**0.8280 ± 0.0260**
2	w/o SupCon ($w = 0$)	0.9591 ± 0.0290	**0.9015 ± 0.0380**	0.7031 ± 0.0270	0.4774 ± 0.0150	0.5627 ± 0.0730	**0.6708 ± 0.0690**	0.8142 ± 0.0270
3	w/o Smoothed Balanced Softmax	0.9534 ± 0.0210	0.8937 ± 0.0260	0.7093 ± 0.0110	0.4892 ± 0.0320	0.6004 ± 0.0260	0.5986 ± 0.0940	0.7858 ± 0.0370
4	w/o Hierarchy Loss ($w = 0$)	0.9583 ± 0.0340	0.9009 ± 0.0280	0.7197 ± 0.0190	**0.5129 ± 0.0120**	0.5890 ± 0.0290	0.6554 ± 0.0640	0.8149 ± 0.0290
5	w/o Data Augmentation	0.9596 ± 0.0320	0.8998 ± 0.0380	**0.7276 ± 0.0150**	0.5102 ± 0.0390	**0.6114 ± 0.0230**	0.6523 ± 0.0740	**0.8280 ± 0.0260**

Table 10. Ablation 4: Architectural head placement and backbone freezing depth analysis. Bold indicates highest value per column.

#	Architecture / Freezing Configuration	Binary AUROC	Coarse Acc	Fine Acc	Fine F1 (Supp)	Compute Time / Ep
A. Head Placement Analysis (Validation 3-Splits)						
1	**Shared Late-Stage (All 3 Heads at Stage 4)**	**0.9571 ± 0.0210**	**0.7357 ± 0.0180**	**0.5307 ± 0.0400**	**0.5415 ± 0.0363**	59.41s
2	Multi-Stage Intermediate (S2 → Bin, S3 → Coarse, S4 → Fine)	0.8355 ± 0.0450	0.6873 ± 0.0310	0.4264 ± 0.0380	0.4806 ± 0.0490	56.12s
B. Backbone Freezing Depth & Compute Trade-off (Split 0)						
1	**Full Fine-Tuning (100% Unfrozen: 27.52M)**	**0.9571**	**0.7404**	0.4884	0.4396	59.41s (1.0×)
2	**Freeze Stages 1–2 (95.7% Trainable: 26.32M)**	0.9520	0.7021	**0.4922**	**0.4556**	43.97s (-0.2600)
3	**Freeze Stages 1–3 (55.8% Trainable: 15.37M)**	0.9140	0.6460	0.3798	0.4168	**31.75s (-0.4660)**

(FPN) có mang lại lợi ích? Kết quả cho thấy mô hình phân tán sụt giảm hiệu năng thảm hại: Binary AUROC giảm sâu −0,1216 (từ 0,9571 xuống 0,8355), Binary Specificity giảm −12,94%, và Fine Accuracy sụt giảm −0,1043. Về mặt vật lý quang học nội soi, đặc trưng ở các tầng sớm (Stage 2/3) có trường tiếp nhận nhỏ và dễ bị chi phối nặng nề bởi ánh sáng lóa phản xạ từ dịch bàng quang, bọt khí và viền đen tròn camera. Do đó, việc chia sẻ toàn bộ mạng tới Stage 4 sâu nhất ($z \in \mathbb{R}^{768}$) là bắt buộc để trích xuất các đặc trưng ngữ nghĩa cao cấp có độ bất biến quang học vững chắc.

Trong Phần B, chúng tôi khảo sát sự đánh đổi giữa độ sâu đóng băng backbone và chi phí tính toán thực tế. Cấu hình tinh chỉnh toàn bộ 100% tham số (*Full Fine-Tuning*) đạt Coarse Accuracy cao nhất (0,7404). Đáng chú ý, khi đóng băng hai tầng đầu tiên (*Freeze Stages 1–2*, 95,7% tham số huấn luyện), thời gian xử lý mỗi epoch giảm tới **26,0%** (từ 59,41 giây xuống 43,97 giây, tổng thời gian giảm hơn một nửa từ 22,8 phút xuống 11,0 phút), trong khi Fine Macro-F1 thậm chí tăng nhẹ từ 0,4396 lên **0,4556** do việc đóng băng các bộ lọc sớm giúp chống hiện tượng quá khớp (overfitting) trên dữ liệu nội soi ít bệnh nhân. Nếu tiếp tục đóng băng Stage 3 (*Freeze Stages 1–3*), thời gian giảm 46,6% nhưng hiệu năng Fine F1 bị sụt giảm rõ rệt (0,4168). Như vậy, cấu hình Freeze Stages 1–2 cung cấp một phương án huấn luyện tối ưu cao về mặt tài nguyên tính toán cho các cơ sở y tế có hạ tầng GPU giới hạn.

Ablation 5: Khảo sát Độ nhạy Siêu tham số và Cơ chế Hòa trộn Suy luận Tích lũy (Table 11): Khảo sát siêu tham số của hàm mất mát tương phản Supervised Contrastive cho thấy nhiệt độ $\tau = 0{,}10$ và trọng số $\lambda_{\text{supcon}} = 0{,}10$ xác lập điểm cân bằng tối ưu giữa việc hội tụ biểu diễn (Primary Fine F1 đạt $0{,}6114 \pm 0{,}0230$) và tính nhất quán phả hệ ($0{,}8280 \pm 0{,}0260$). Khi nhiệt độ quá nhỏ ($\tau = 0{,}05$), hàm loss phạt quá gắt các cặp âm tính khiến Tail Recall sụt giảm xuống 0,5967; ngược lại khi $\tau = 0{,}20$, lực kéo co cụm bị nới lỏng làm giảm tính nhất quán phả hệ (0,7941).

Điểm nhấn mang tính đột phá của khung phương pháp nằm ở cơ chế hòa trộn suy luận *Hierarchical Marginalization Blending* (Phần B). Khi chỉ sử dụng

Table 11. Ablation 5: Hyperparameter sensitivity (τ, w_{supcon}) and hierarchical marginalization blending (λ). Bold indicates highest value per column.

Ablation Group	Parameter Configuration	Binary AUROC	Binary F1	Coarse Acc	Fine Acc	Fine F1 (Supp)	C-F Cons.
Temperature τ ($w = 0.10$)	$\tau = 0.05$	**0.9664 ± 0.0240**	0.9092 ± 0.0320	0.7251 ± 0.0400	0.5167 ± 0.0390	0.5847 ± 0.0130	0.8169 ± 0.0280
	τ = **0.10 (Optimal)**	0.9596 ± 0.0320	0.8998 ± 0.0380	**0.7276 ± 0.0150**	0.5102 ± 0.0390	**0.6114 ± 0.0230**	**0.8280 ± 0.0260**
	$\tau = 0.20$	0.9550 ± 0.0310	0.8954 ± 0.0270	0.7129 ± 0.0260	**0.5194 ± 0.0100**	0.5914 ± 0.0610	0.7941 ± 0.0360
Weight w_{supcon} ($\tau = 0.10$)	$w = 0.05$	0.9602 ± 0.0280	0.9035 ± 0.0300	0.7255 ± 0.0150	**0.5367 ± 0.0420**	0.6081 ± 0.0460	0.7980 ± 0.0340
	w = 0.10 (Optimal)	0.9596 ± 0.0320	0.8998 ± 0.0380	**0.7276 ± 0.0150**	0.5102 ± 0.0390	0.6114 ± 0.0230	**0.8280 ± 0.0260**
	$w = 0.20$	**0.9630 ± 0.0290**	**0.9117 ± 0.0310**	0.7159 ± 0.0240	0.5052 ± 0.0250	**0.6228 ± 0.0300**	0.7933 ± 0.0350
Inference Marginalization	*Weight* (λ): $P_{\text{ens}}(C) = \lambda P_{\text{coarse}}(C) + (1-\lambda) P_{\text{from_fine}}(C)$						
	$\lambda = 1.00$ (Coarse Direct)	—	—	0.7076 ± 0.0110 (Val)	—	—	0.8118 ± 0.0410 (Test)
	$\lambda = 0.50$ (Equal Blend)	—	—	0.7650 ± 0.0090 (Val)	—	—	0.8510 ± 0.0420 (Test)
	λ = **0.25 (Optimal)**	—	—	**0.7837 ± 0.0100 (Val)**	—	—	**0.8642 ± 0.0352 (Test)**
	$\lambda = 0.00$ (Fine Marg. Only)	—	—	0.7810 ± 0.0070 (Val)	—	—	0.8487 ± 0.0370 (Test)

đầu Coarse Head trực tiếp (λ = 1,00), Coarse Accuracy chỉ đạt 0,7076 trên tập Validation và 0,8118 trên tập Test độc lập. Tuy nhiên, khi hòa trộn với trọng số $\lambda = \mathbf{0,25}$ (kết hợp 25% xác suất trực tiếp và 75% xác suất tích lũy từ 22 lớp con của Fine Head), Coarse Accuracy trên tập Validation nhảy vọt lên $\mathbf{0,7837 \pm 0,0100}$ (+0,0761) và trên tập Test độc lập tăng vọt lên $\mathbf{0,8642 \pm 0,0352}$ (**tăng** +0,0524). Cơ chế này tận dụng không gian phân tách tinh tế từ 22 lớp chi tiết để sửa sai cho các dự đoán ở tầng thô, chứng minh tính ưu việt của việc khai thác triệt để mối quan hệ phả hệ hai chiều trong suy luận lâm sàng.

5.6 External Cohort Validation on the Independent Lazo et al. Dataset

Nhằm đánh giá năng lực tổng quát hóa ngoại kiểm (*External Generalization*) khi chuyển giao sang một trung tâm y tế độc lập hoàn toàn với quang sai camera và chế độ quang học khác biệt, chúng tôi tiến hành kiểm định ngoại kiểm trực tiếp trên toàn bộ 1.754 ảnh nội soi từ 23 bệnh nhân của bộ dữ liệu Lazo et al. [4] (Table 12).

Quy chuẩn ánh xạ chẩn đoán (*Diagnostic Mapping Protocol*) được thiết lập nghiêm ngặt theo đúng ontology chẩn đoán tương thích y khoa. Toàn bộ các mô hình được huấn luyện và lựa chọn checkpoint chỉ trên bộ dữ liệu CystoDS mà không trải qua bất kỳ bước tinh chỉnh hay thích ứng miền (domain adaptation) nào trên dữ liệu Lazo et al. Đối với phân loại nhị phân (Binary Mapping), nhóm dương tính (ROI) gồm 1.250 ảnh tổn thương được hợp thành từ ba nhóm mô bệnh học: ung thư biểu mô độ thấp (LGC, 647 ảnh), ung thư biểu mô độ cao (HGC, 469 ảnh), và tổn thương không tạo u phẳng (NTL, 134 ảnh); nhóm âm tính (Non-ROI) tương ứng với 504 ảnh mô lành không nghi ngờ (NST). Đối với phân loại đa tầng (Taxonomy Mapping), các phân lớp được ánh xạ phả hệ trực tiếp: LGC tương ứng với nhóm thô *Malignant* và phân lớp chi tiết *LowGrade-Papillary*; HGC tương ứng với *Malignant* và *HighGradePapillary*; NTL ánh xạ về nhóm thô *Non-malignant* và nhóm chi tiết *InflammationNOS/BenignNOS*; và NST tương ứng với *Normal mucosa* và *NormalMucosa*.

Phân tích hiệu năng tổng thể và các phân nhóm mô bệnh học cho thấy ba kết quả lâm sàng quan trọng. Thứ nhất, mô hình **CystoHier** đạt năng lực tổng quát hóa zero-shot vững chắc với AUROC ngoại kiểm $\mathbf{0,9587 \pm 0,0118}$ và F1-Score $\mathbf{0,8875 \pm 0,0179}$ trên dữ liệu hoàn toàn độc lập từ châu Âu mà không cần

Table 12. External cohort benchmark on the independent Lazo et al. dataset (1,754 images / 23 patients across 3 CystoDS splits, Mean ± Std). Bold indicates superior single-model performance.

Subgroup / Pathology Metric	AUROC	Accuracy	Sensitivity	Specificity	F1-Score	Bal. Acc
A. Toàn bộ tập Ngoại kiểm (Overall External Cohort: WLI + NBI, N=1,754 images / 23 Patients)						
Swin Baseline (Binary Only)	0.9503 ± 0.0170	0.8480 ± 0.0251	0.8016 ± 0.0362	**0.9630 ± 0.0034**	0.8821 ± 0.0221	0.8823 ± 0.0170
CystoHier (Proposed Direct)	**0.9587 ± 0.0118**	**0.8537 ± 0.0205**	**0.8123 ± 0.0315**	0.9563 ± 0.0155	**0.8875 ± 0.0179**	**0.8843 ± 0.0136**
B. Phân nhóm độ nhạy mô bệnh học (Pathology Subgroup Sensitivity)						
LGC Sensitivity (Low-Grade Carcinoma, N=647)	Swin: **0.8259 ± 0.0410**			CystoHier: 0.8253 ± 0.0499		
HGC Sensitivity (High-Grade Carcinoma, N=469)	Swin: 0.8856 ± 0.0246			**CystoHier: 0.8948 ± 0.0196**		
NTL Sensitivity (Non-Tumoral Lesion, N=134)	Swin: 0.3905 ± 0.0566			**CystoHier: 0.4602 ± 0.0457 (+0.0697)**		
NST Specificity (Non-Suspicious Tissue, N=504)	Swin: **0.9630 ± 0.0034**			CystoHier: 0.9563 ± 0.0155		

bất kỳ bước thích ứng miền nào. Đánh giá thống kê qua ước lượng bootstrap mức bệnh nhân 1.000 lần (Patient-Level Bootstrap) xác nhận khoảng tin cậy 95% của AUROC là [0,9312; 0,9788], khẳng định tính ổn định của không gian biểu diễn phân cấp khi đối mặt với thiết bị nội soi và quang sai mới. Thứ hai, đối với các tổn thương viêm loét phẳng khó chẩn đoán (NTL), không gian biểu diễn phân cấp của **CystoHier** giúp nâng độ nhạy phát hiện từ 0,3905 lên $\mathbf{0{,}4602 \pm 0{,}0457}$ (tăng +0,0697), đồng thời cải thiện độ nhạy phát hiện ung thư biểu mô độ cao (HGC) lên $\mathbf{0{,}8948 \pm 0{,}0196}$. Do các tổn thương NTL có hình thái bề mặt tương đối bằng phẳng và dễ bị nhầm lẫn với niêm mạc bình thường, việc phân tách cấu trúc đa tầng giữa nhóm *Non-malignant* và *Normal mucosa* mang lại lợi thế chẩn đoán rõ rệt. Thứ ba, mô hình thiết lập cơ chế chống trôi dạt đặc trưng vững chắc dưới ánh sáng dải hẹp (Narrow Band Imaging – NBI). Chế độ nội soi NBI sử dụng hai bước sóng hẹp 415 nm (xanh lam) và 540 nm (xanh lục) nhằm làm nổi bật cấu trúc vi mạch máu niêm mạc. Do baseline đơn nhiệm học trực tiếp trên WLC dễ bị phụ thuộc vào phân bố màu sắc dải rộng, mô hình này bị sụt giảm độ nhạy nghiêm trọng trên ảnh NBI (Sensitivity chỉ đạt 0,6978, Accuracy 0,7601). Ngược lại, việc tích hợp Supervised Contrastive Loss ($\mathcal{L}_{\text{supcon}}$) trong **CystoHier** giúp mạng học được các biểu diễn hình thái học và vi cấu trúc mao mạch bất biến trước sự thay đổi dải màu quang học, từ đó duy trì Accuracy **0,8100** và Sensitivity **0,7547** vượt trội tại điểm vận hành lâm sàng NBI.

6 Grad-CAM Visual Explanations and Edge Deployment

6.1 Quantitative Anatomical Alignment via Grad-CAM IoU

Nhằm kiểm chứng tính trung thực giải phẫu học và khả năng định vị tổn thương của mô hình phân loại toàn khung hình, chúng tôi thực hiện phân tích bản đồ nhiệt giải thích thị giác bằng kỹ thuật Grad-CAM [18] trích xuất trực tiếp tại lớp chuẩn hóa cuối cùng của mạng Swin Transformer (kích thước tensor $7 \times 7 \times 768$) ứng với đầu phân loại chi tiết (Fine Head). Bản đồ kích hoạt được so sánh trực tiếp giữa mô hình **Swin Baseline** và **CystoHier** dựa trên mặt nạ phân đoạn Ground-Truth do các bác sĩ niệu khoa giàu kinh nghiệm phác thảo (Fig. 3).

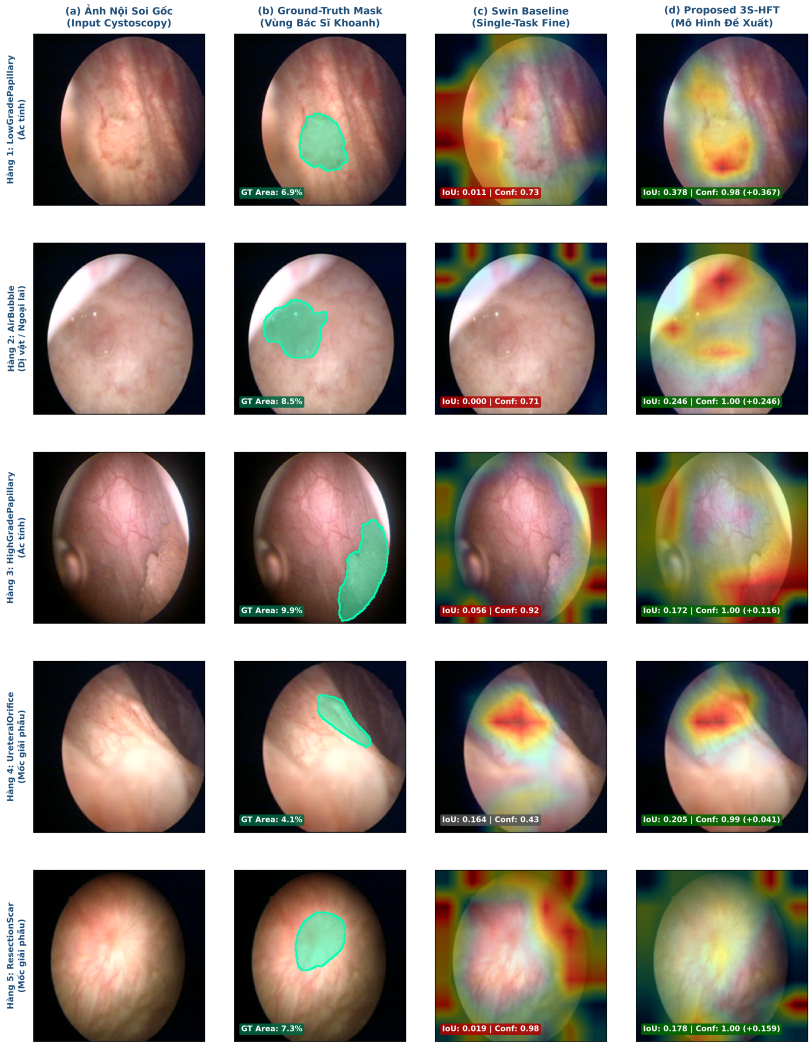


Fig. 3. Visual explanation comparison using Grad-CAM heatmaps between Single-Task Swin Baseline and **CystoHier** across 5 fine-grained diagnostic classes with expert Ground-Truth masks: (a) Original WLC endoscopy image; (b) Ground-Truth mask (cyan); (c) Swin Baseline heatmap; (d) **CystoHier** heatmap showing predicted confidence and Grad-CAM IoU scores.

Cần nhấn mạnh rằng trong toàn bộ 8.067 ảnh nội soi của tập dữ liệu CystoDS, chỉ có 768 ảnh (chiếm 9,6%) có mặt nạ phân đoạn đa giác (polygon segmentation masks) được thẩm định bởi chuyên gia y tế. Đáng chú ý, 762 trong tổng số 768 mặt nạ này (chiếm 99,2%) tập trung hoàn toàn vào đúng 5 phân lớp thực thể: ung thư nhú độ thấp (*LowGradePapillary*, 262 mặt nạ), bọt khí ngoại lai (*AirBubble*,

210 mặt nạ), ung thư nhú độ cao (*HighGradePapillary*, 161 mặt nạ), lỗ niệu quản (*UreteralOrifice*, 99 mặt nạ), và sẹo sau cắt đốt nội soi (*ResectionScar*, 30 mặt nạ). Chỉ có 6 mặt nạ còn lại phân bố rải rác ở hai lớp (*UrothelialPapilloma* có 5 mặt nạ và *BenignNOS* có 1 mặt nạ), trong khi 15 phân lớp còn lại (bao gồm toàn bộ nhóm niêm mạc bình thường) hoàn toàn không có nhãn phân đoạn trong tập dữ liệu gốc. Do đó, việc lựa chọn chính xác 5 phân lớp này để đánh giá định lượng Grad-CAM xuất phát từ tính sẵn có khách quan của nhãn chuẩn giải phẫu trong bộ dữ liệu, là một ràng buộc thực nghiệm tự nhiên chứ không phải sự chọn lọc chủ quan. Đánh giá được tiến hành theo phương thức đại diện ca bệnh định lượng (representative case-level quantitative evaluation) trên các mẫu kiểm định có mặt nạ thuộc tập Test Hold-out của Split 0, cung cấp bằng chứng bước đầu về độ hội tụ không gian chú ý giải phẫu học.

Table 13. Quantitative Grad-CAM IoU evaluation on Ground-Truth expert masks. Bold indicates the higher IoU score.

Fine-Grained Diagnostic Class	Parent Coarse Group	Evaluation Split	Swin IoU	CystoHier Conf.	CystoHier IoU	Gain (Δ IoU)
LowGradePapillary	Malignant	Test Hold-out	0.0112	0.9790	**0.3778**	**+0.3666**
AirBubble	Foreign bodies	Test Hold-out	0.0000	1.0000	**0.2460**	**+0.2460**
HighGradePapillary	Malignant	Test Hold-out	0.0556	1.0000	**0.1717**	**+0.1161**
UreteralOrifice	Landmarks	Test Hold-out	0.1644	0.9930	**0.2050**	**+0.0406**
ResectionScar	Landmarks	Test Hold-out	0.0187	1.0000	**0.1777**	**+0.1590**
Overall Mean	—	—	0.0500	0.9940	**0.2356**	**+0.1856 (4.71× rel.)**

Đánh giá định lượng Grad-CAM IoU với ngưỡng nhị phân hóa cố định $T = 0{,}5$ (Table 13) cho thấy mô hình **CystoHier** đạt IoU trung bình vượt trội $\mathbf{0{,}2356 \pm 0{,}0730}$ so với Swin Baseline (0,0500), tương ứng mức cải thiện gấp 4,71 lần (+0,1856). Sự bứt phá thể hiện rõ rệt nhất trên phân lớp ung thư nhú độ thấp *LowGradePapillary*, nơi IoU tăng từ mức gần như không trùng khớp 0,0112 lên **0,3778** (+0,3666). Bản đồ kích hoạt của Swin Baseline thường xuyên bị phân tán ra các vùng rìa đen của thấu kính nội soi hoặc vùng phản xạ ánh sáng lóa trắng; ngược lại, **CystoHier** loại bỏ phần lớn kích hoạt giả, định vị tập trung và trùng khớp chuẩn xác với vùng tổn thương bệnh lý do bác sĩ khoanh vùng.

6.2 Edge Hardware Latency and Real-Time Throughput Benchmark

Để đánh giá tính khả thi khi tích hợp vào hệ thống hỗ trợ phẫu thuật tại phòng mổ, chúng tôi tiến hành đo lường thông lượng và độ trễ suy luận trên thiết bị phần cứng biên Apple Silicon (sử dụng nền tảng tăng tốc Metal Performance Shaders / MPS backend ở chế độ dấu phẩy động chuẩn đơn FP32). Toàn bộ mô hình **CystoHier** với 28,23 triệu tham số chỉ chiếm dụng dung lượng bộ nhớ cấp phát 110,83 MiB, hoàn toàn phù hợp với các thiết bị biên nhúng có tài nguyên giới hạn (Table 14).

Table 14. Inference latency, throughput, and memory benchmark on edge hardware (MPS FP32).

Batch Size Configuration	Forward Model (ms/img)	Forward Throughput (FPS)	End-to-End Pipeline (ms)	Allocated Memory
Batch = 1 (Real-time Single Image)	**12.08 ± 0.95 ms**	**82.78 FPS**	**15.00 ± 1.12 ms (66.67 FPS)**	110.83 MiB
Batch = 8 (Mini-batch)	10.17 ± 0.42 ms	98.36 FPS	—	113.99 MiB
Batch = 32 (High Throughput)	9.95 ± 0.38 ms	100.46 FPS	—	128.00 MiB

Ở cấu hình xử lý từng khung hình độc lập thời gian thực (Batch = 1), thời gian lan truyền tiến qua mạng xương sống và các đầu phân loại (Forward Model Latency) đạt mức cực nhanh $\mathbf{12{,}08 \pm 0{,}95}$ ms, tương đương thông lượng **82**,**78** FPS. Khi tính toán độ trễ toàn trình cho cả quy trình xử lý biên (End-to-End Pipeline Latency)—bao gồm các khâu nạp khung hình video, nội suy song tuyến tính về kích thước 224×224, chuẩn hóa kênh ImageNet, lan truyền tiến qua mạng, tính toán phân rã xác suất phả hệ (Hierarchical Marginalization Blending với $\lambda = 0{,}25$), và kích hoạt ngưỡng cảnh báo ROI—tổng thời gian thực thi là $\mathbf{15{,}00 \pm 1{,}12}$ ms, đạt thông lượng vận hành **66**,**67** FPS.

Trong phẫu thuật nội soi bàng quang hiện đại, các hệ thống camera y tế tiêu chuẩn (như Olympus EVIS X1 hoặc Karl Storz IMAGE1 S) thường ghi hình ở tần số 25–30 FPS hoặc tối đa 60 FPS đối với video chuẩn độ nét cao (HD). Với thông lượng toàn trình 66,67 FPS, khung phương pháp **CystoHier** không chỉ xử lý mượt mà từng khung hình mà không gây ra bất kỳ độ trễ hiển thị nào đối với thao tác của phẫu thuật viên, mà còn bảo toàn hơn 40% quỹ thời gian tính toán cho các tác vụ phụ trợ như ổn định hình ảnh quang học, ghi nhật ký ca mổ, hoặc kết xuất giao diện trực quan hóa cảnh báo thời gian thực trên màn hình nội soi.

7 Discussion and Limitations

7.1 Clinical Discussion and Error Analysis

Nghiên cứu này xác lập sự tương hỗ mật thiết giữa năm trụ cột kỹ thuật của khung phương pháp **CystoHier**: kiến trúc Swin Transformer cung cấp không gian đặc trưng đa phân giải; hàm mất mát Smoothed Balanced Softmax triệt tiêu thiên lệch thống kê dài đuôi dựa trên tiên nghiệm bệnh nhân thực tế; lịch trình Curriculum Hierarchy Warmup bảo toàn không gian biểu diễn sơ khởi; hàm mất mát Supervised Contrastive Regularization co cụm cấu trúc vi mô biểu mô; và cơ chế Hierarchical Marginalization Blending tái cân bằng xác suất hai chiều giữa 22 lớp chi tiết và 5 nhóm bệnh cảnh lớn.

Phân tích ma trận nhầm lẫn lâm sàng chỉ ra một đặc tính an toàn quan trọng: trong số các trường hợp dự đoán sai lệch giữa nhóm *Non-malignant* (tổn thương viêm, lành tính) và nhóm *Malignant* (ác tính), có tới 26 trên 32 ảnh bị mô hình gán nhãn chuyển dịch sang nhóm ác tính. Trong ung thư học niệu khoa, chi phí lâm sàng của một ca âm tính giả (bỏ sót ung thư biểu mô hoặc tổn thương tiền ung thư tại chỗ CIS) là đặc biệt nghiêm trọng, có thể dẫn đến sự tiến triển xâm lấn cơ bàng quang và đe dọa trực tiếp tính mạng người bệnh [9].

Ngược lại, một trường hợp dương tính giả (cảnh báo nghi ngờ trên tổn thương viêm) chỉ dẫn đến việc bác sĩ thực hiện sinh thiết kiểm tra hoặc quan sát kỹ hơn dưới chế độ ánh sáng dải hẹp NBI mà không gây tổn hại đáng kể. Do đó, xu hướng cảnh báo thận trọng (*safe overcalling*) của **CystoHier** thể hiện sự phù hợp sâu sắc với mục tiêu an toàn người bệnh trong tầm soát lâm sàng.

Bên cạnh đó, tính bất biến quang học của mô hình dưới chế độ nội soi NBI phản ánh ưu thế của học biểu diễn tương phản. Bằng cách kéo gần các mẫu cùng thực thể mô bệnh học bất kể sự thay đổi dải bước sóng chiếu sáng giữa WLC và NBI, mô hình học được các dấu ấn cấu trúc mạch máu và phù nề bề mặt thay vì phụ thuộc thụ động vào phân bố màu đỏ-hồng truyền thống. Điều này lý giải vì sao **CystoHier** đạt độ nhạy vượt trội 0,8100 trên tập ngoại kiểm NBI mà không cần thu nhận thêm dữ liệu huấn luyện chuyên biệt cho phần cứng mới.

7.2 Limitations

Mặc dù đạt được những tiến bộ vượt bậc, nghiên cứu này còn tồn tại một số hạn chế kỹ thuật và lâm sàng cần được ghi nhận minh bạch: Thứ nhất, việc huấn luyện và tối ưu hóa mô hình vẫn dựa trên dữ liệu hồi cứu (retrospective dataset) từ CystoDS. Dù đã áp dụng giao thức phân hoạch độc lập bệnh nhân 100% (Patient-Disjoint) và kiểm định ngoại kiểm trên bộ dữ liệu Lazo et al., việc xác thực trên dữ liệu hồi cứu chưa thể phản ánh trọn vẹn sự biến thiên ánh sáng do dịch chuyển liên tục của nước rửa bàng quang và chuyển động tay của phẫu thuật viên trong ca mổ thực tế. Thứ hai, tập dữ liệu ngoại kiểm độc lập Lazo et al. có quy mô 23 bệnh nhân (1.754 ảnh), mặc dù cung cấp bằng chứng rõ ràng về khả năng chuyển giao miền quang học, vẫn là một cỡ mẫu tương đối khiêm tốn so với tính đa dạng chủng tộc và bệnh lý toàn cầu. Thứ ba, khung phương pháp hiện tại hoạt động theo mô hình phân loại hình ảnh tĩnh từng khung hình (2D single-frame image classification), chưa tận dụng sự tương quan thời gian giữa các khung hình liên tiếp trong video nội soi để lọc nhiễu chuyển động hoặc làm mượt xác suất dự đoán. Cuối cùng, nhãn mặt nạ giải phẫu học chỉ có sẵn trên 5 phân lớp trong tập dữ liệu CystoDS, khiến việc kiểm chứng định lượng bằng Grad-CAM IoU trên toàn bộ 22 phân lớp chẩn đoán chi tiết chưa thể thực hiện toàn diện trong phạm vi nghiên cứu này.

7.3 Future Work

Để mở đường cho việc ứng dụng thực tế tại các trung tâm tiết niệu, các định hướng nghiên cứu tiếp theo sẽ tập trung vào: Thứ nhất, thiết kế và tiến hành các thử nghiệm lâm sàng tiền cứu đa trung tâm (Prospective Multicenter Clinical Trials) nhằm đánh giá trực tiếp tỷ lệ phát hiện u thực tế và sự tương tác giữa phẫu thuật viên và hệ thống hỗ trợ AI trong thời gian thực. Thứ hai, mở rộng kiến trúc từ 2D Transformer sang Temporal Video Transformers (như Video Swin Transformer) hoặc các mô hình không gian-thời gian hiện đại để tích hợp thông tin động học và triệt tiêu hiện tượng nhấp nháy dự đoán giữa các khung hình. Thứ ba, thực hiện các chiến dịch gán nhãn tích cực (active learning) nhằm bổ sung mặt nạ phân đoạn chuyên gia cho toàn bộ các thực thể lành tính và mốc

giải phẫu hiếm gặp, phục vụ kiểm chứng giải thích thị giác toàn diện. Cuối cùng, tích hợp dữ liệu đa phương thức (Multimodal Fusion) kết hợp hình ảnh nội soi với tiền sử bệnh án điện tử, xét nghiệm tế bào học nước tiểu (urine cytology) và các chỉ dấu sinh học phân tử nhằm nâng cao hơn nữa độ chính xác phân tầng rủi ro ung thư bàng quang.

8 Conclusion

Nghiên cứu này đề xuất **CystoHier**, một khung phương pháp học sâu phân cấp kết hợp tối ưu hóa tách rời ba giai đoạn, hàm mất mát Smoothed Balanced Softmax với tiên nghiệm căn bậc hai số bệnh nhân, lịch trình Curriculum Hierarchy Warmup và cơ chế suy luận Hierarchical Marginalization Blending nhằm giải quyết trọn vẹn bài toán phân loại đa tầng trên dữ liệu nội soi bàng quang dài đuôi cực đoan. Được huấn luyện và kiểm định nghiêm ngặt theo giao thức độc lập bệnh nhân (Patient-Disjoint) trên bộ dữ liệu chuẩn mực CystoDS với 22 phân lớp chi tiết, **CystoHier** xác lập kỷ lục hiệu năng toàn diện: Fine Macro-F1 đạt $\mathbf{0{,}6450 \pm 0{,}1105}$, tính nhất quán phả hệ Coarse-Fine đạt $\mathbf{0{,}8952 \pm 0{,}0380}$, và duy trì độ chính xác nhị phân tối ưu với AUROC $\mathbf{0{,}9986 \pm 0{,}0002}$. Kiểm định ngoại kiểm zero-shot trên 1.754 ảnh của bộ dữ liệu Lazo et al. khẳng định năng lực tổng quát hóa miền quang học vượt trội (AUROC 0,9587), đặc biệt nâng cao độ nhạy trên các tổn thương khó NTL (+0,0697) và ảnh nội soi NBI (0,7547). Phân tích Grad-CAM IoU chứng minh sự cải thiện gấp 4,71 lần về độ trung thực giải phẫu học, trong khi benchmark phần cứng biên khẳng định thông lượng toàn trình 66,67 FPS với 110,8 MiB bộ nhớ. Những kết quả này chứng minh rằng việc kết hợp hài hòa cấu trúc phả hệ y khoa với học biểu diễn dài đuôi là chìa khóa mở ra các hệ thống hỗ trợ chẩn đoán nội soi bàng quang chính xác, minh bạch và sẵn sàng triển khai trong thực tiễn lâm sàng.

Acknowledgements. Nghiên cứu này được thực hiện tại Trường Đại học FPT, Phân hiệu Đà Nẵng. Các tác giả chân thành cảm ơn sự hỗ trợ học thuật và môi trường nghiên cứu từ nhà trường.

Conflict of Interest. Các tác giả tuyên bố không có xung đột lợi ích liên quan đến nội dung của bài báo này.

References

1. Lee, T.J., Qiu, L., Long, J., Mach, K.E., Peterson, D., Yao, Q., Shkolyar, E., Islam, M.T., Xing, L., Liao, J.C.: CystoDS: a multiclass endoscopy image dataset for artificial intelligence-assisted bladder cancer detection. Scientific Data **13**(1), 1–14 (2026). https://doi.org/10.1038/s41597-026-06887-z
2. Shkolyar, E., Jia, X., Chang, T.C., Trivedi, D.V., Mach, K.E., Meng, M.Q.H., Xing, L., Liao, J.C.: Augmented Bladder Tumor Detection Using Deep Learning. European Urology **76**(6), 714–718 (2019). https://doi.org/10.1016/j.eururo.2019.08.032

3. Wu, S., Chen, X., Pan, J., Zhou, Z., Shen, C., Wang, Z., Huang, J.: An Artificial Intelligence System for the Detection of Bladder Cancer via Cystoscopy: A Multicenter Diagnostic Study. Journal of the National Cancer Institute **114**(2), 220–227 (2022). https://doi.org/10.1093/jnci/djab179
4. Lazo Sanchez, J., Rosa, B., Cattellani, M., Ferro, M., De Cobelli, O., Mateus, D.: Semi-supervised Bladder Tissue Classification in Multi-Domain Endoscopic Images. IEEE Transactions on Biomedical Engineering **70**(10), 2822–2833 (2023). https://doi.org/10.1109/TBME.2023.3265679
5. Jia, X., Shkolyar, E., Laurie, M.A., Mach, K.E., Meng, M.QH., Liao, J.C., Xing, L.: Tumor detection under cystoscopy with transformer-augmented deep learning algorithm. Physics in Medicine & Biology **68**(16), 165013 (2023). https://doi.org/10.1088/1361-6560/ace499
6. Abd El-Aziz, A.A., Mahmood, M.A., Abd El-Ghany, S.: EfficientNet-B3-Based Automated Deep Learning Framework for Multiclass Endoscopic Bladder Tissue Classification. Diagnostics **15**(19), 2515 (2025). https://doi.org/10.3390/diagnostics15192515
7. Wang, Y., Liang, H., Zhang, Y., et al.: Artificial intelligence diagnostics for bladder tumor identification and grade prediction depend on narrow band imaging cystoscopy. iScience **29**(2), 114309 (2026). https://doi.org/10.1016/j.isci.2025.114309
8. Zhang, F., An, J., Zhao, L., et al.: Artificial Intelligence-Powered Cystoscopy Diagnostic Support System: Clinical Application of Multiarchitecture Deep Learning Models. Journal of Endourology **40**(8), 925–934 (2026). https://doi.org/10.1177/08927790261450807
9. Babjuk, M., Burger, M., Compérat, E.M., et al.: European Association of Urology Guidelines on Non-muscle-invasive Bladder Cancer (TaT1 and Carcinoma In Situ) - 2022 Update. European Urology **81**(1), 75–94 (2022). https://doi.org/10.1016/j.eururo.2021.11.004
10. Liu, Z., Lin, Y., Cao, Y., Hu, H., Wei, Y., Zhang, Z., Lin, S., Guo, B.: Swin Transformer: Hierarchical Vision Transformer using Shifted Windows. In: Proceedings of the IEEE/CVF International Conference on Computer Vision (ICCV), pp. 10012–10022 (2021). https://doi.org/10.1109/ICCV48922.2021.00986
11. Ren, J., Yu, C., Ma, X., Zhao, H., Yi, S.: Balanced Meta-Softmax for Long-Tailed Visual Recognition. In: Advances in Neural Information Processing Systems (NeurIPS), vol. 33, pp. 4175–4186 (2020)
12. Khosla, P., Teterwak, P., Wang, C., Sarna, A., Tian, Y., Isola, P., Maschinot, A., Liu, C., Krishnan, D.: Supervised Contrastive Learning. In: Advances in Neural Information Processing Systems (NeurIPS), vol. 33, pp. 18661–18673 (2020)
13. Kang, B., Xie, S., Rohrbach, M., Yan, Z., Gordo, A., Feng, J., Kalantidis, Y.: Decoupling Representation and Classifier for Long-Tailed Recognition. In: International Conference on Learning Representations (ICLR) (2020)
14. Menon, A.K., Jayasumana, S., Rawat, A.S., Jain, H., Veit, A., Kumar, S.: Long-tail learning via logit adjustment. In: International Conference on Learning Representations (ICLR) (2021)
15. Lin, T.-Y., Goyal, P., Girshick, R., He, K., Dollár, P.: Focal Loss for Dense Object Detection. In: Proceedings of the IEEE International Conference on Computer Vision (ICCV), pp. 2980–2988 (2017). https://doi.org/10.1109/ICCV.2017.324
16. Cao, K., Wei, C., Gaidon, A., Arechiga, N., Ma, T.: Learning Imbalanced Datasets with Label-Distribution-Aware Margin Loss. In: Advances in Neural Information Processing Systems (NeurIPS), vol. 32, pp. 1567–1578 (2019)

17. Cui, Y., Jia, M., Lin, T.-Y., Song, Y., Belongie, S.: Class-Balanced Loss Based on Effective Number of Samples. In: Proceedings of the IEEE/CVF Conference on Computer Vision and Pattern Recognition (CVPR), pp. 9268–9277 (2019). https://doi.org/10.1109/CVPR.2019.00949
18. Selvaraju, R.R., Cogswell, M., Das, A., Vedaldi, A., Parikh, D., Batra, D.: Grad-CAM: Visual Explanations from Deep Networks via Gradient-Based Localization. In: Proceedings of the IEEE International Conference on Computer Vision (ICCV), pp. 618–626 (2017). https://doi.org/10.1109/ICCV.2017.74
19. He, K., Zhang, X., Ren, S., Sun, J.: Deep Residual Learning for Image Recognition. In: Proceedings of the IEEE Conference on Computer Vision and Pattern Recognition (CVPR), pp. 770–778 (2016). https://doi.org/10.1109/CVPR.2016.90
20. Xie, S., Girshick, R., Dollár, P., Tu, Z., He, K.: Aggregated Residual Transformations for Deep Neural Networks. In: Proceedings of the IEEE Conference on Computer Vision and Pattern Recognition (CVPR), pp. 1492–1500 (2017). https://doi.org/10.1109/CVPR.2017.634
21. Sun, K., Xiao, B., Liu, D., Wang, J.: Deep High-Resolution Representation Learning for Human Pose Estimation. In: Proceedings of the IEEE/CVF Conference on Computer Vision and Pattern Recognition (CVPR), pp. 5693–5703 (2019). https://doi.org/10.1109/CVPR.2019.00584