

CystoHier: A Decoupled Hierarchical Learning Framework for Bladder Cancer Endoscopy Classification on Extreme Long-Tailed Distributions

Nguyễn Xuân Cường¹[0000–0002–1825–0097] and Võ Quốc
Trình¹[0000–0002–8877–6655]

Trường Đại học FPT, Phân hiệu Đà Nẵng, Đà Nẵng, Việt Nam
cuongnxde180528@fpt.edu.vn

Abstract. Nội soi bàng quang (Cystoscopy) là tiêu chuẩn vàng trong tầm soát, chẩn đoán và theo dõi ung thư biểu mô đường niệu (Bladder Cancer). Tuy nhiên, việc xây dựng các hệ thống trí tuệ nhân tạo (AI) hỗ trợ phẫu thuật viên đối mặt với hai thách thức cốt lõi: cấu trúc phân cấp chẩn đoán y học đa tầng (nhị phân, nhóm bệnh cảnh thô và phân lớp chẩn đoán chi tiết) và hiện tượng mất cân bằng phân phối dài đuôi cực đoan (Extreme Long-Tailed Imbalance) khi các tổn thương ác tính hoặc bệnh lý hiếm chỉ xuất hiện ở một số ít bệnh nhân. Bài báo này đề xuất **CystoHier** – một khung học phân cấp tách rời ba giai đoạn toàn diện trên nền tảng kiến trúc Swin Transformer nhằm giải quyết sự đánh đổi giữa học biểu diễn đặc trưng và tối ưu hóa ranh giới phân loại đa tầng. Các đóng góp cốt lõi của **CystoHier** bao gồm: (1) Kiến trúc đa nhiệm chia sẻ biểu diễn sâu (*Shared Late-Stage Multi-Head Backbone*); (2) Hàm mất mát *Smoothed Balanced Softmax* (SBS) với tiên nghiệm mượt theo số lượng bệnh nhân thực tế nhằm giảm thiểu thiên lệch lấy mẫu; (3) Tinh chỉnh co cụm không gian đặc trưng bằng *Supervised Contrastive Loss* ($\mathcal{L}_{\text{supcon}}$); (4) Ràng buộc nhất quán phủ hệ với lịch trình *Curriculum Hierarchy Warmup* giúp giải phóng thắt cổ chai biểu diễn ở giai đoạn sớm; (5) Chiến lược huấn luyện tuần tự ba giai đoạn tách rời (*Three-Stage Decoupled Training*) với cơ chế đóng băng tham số (*Parameter-Isolated Representation Preservation*); (6) Cơ chế suy luận kết hợp *Hierarchical Marginalization & Multi-Head Blending* tích lũy xác suất từ 22 phân lớp chi tiết về 5 nhóm thô; và (7) Đánh giá ngoại kiểm độc lập (*External Cohort Validation*) trên bộ dữ liệu Lazo et al. (1.754 ảnh, 23 bệnh nhân). Đánh giá thực nghiệm trên bộ dữ liệu CystoDS (8.067 ảnh, 160 bệnh nhân) theo giao thức 3-Fold Patient-Disjoint Hold-out (100% độc lập bệnh nhân) cho thấy **CystoHier** đạt hiệu năng cao nhất trong số các mô hình đối chuẩn: Binary AUROC **0,9986 $\pm$ 0,0002**, Coarse Accuracy **0,8642 $\pm$ 0,0352**, Fine Macro-F1 (Supported) **0,6450 $\pm$ 0,1105**, và tính nhất quán Coarse-Fine đạt **0,8952 $\pm$ 0,0380** trên tập kiểm định độc lập. Đánh giá zero-shot trên tập ngoại kiểm Lazo et al. xác nhận khả năng tổng quát hóa vững chắc (AUROC 0,9587 $\pm$ 0,0118, Accuracy 0,8537 $\pm$ 0,0205), đặc biệt cải thiện độ nhạy phát hiện tổn thương không tạo u NTL (0,4602 vs 0,3905) và ảnh NBI (Accuracy

0,8100 vs 0,7601). Bản đồ nhiệt Grad-CAM cải thiện độ trùng khớp IoU giải phẫu từ 0,0500 lên 0,2356 trên mặt nạ chuyên gia, đồng thời đạt thông lượng suy luận thời gian thực 66,7 FPS end-to-end trên phần cứng biên, chứng minh tính khả thi của phương pháp học phân cấp dài đuôi cho chẩn đoán nội soi bàng quang.

Keywords: Cystoscopy · Bladder Cancer · Hierarchical Classification
 · Long-Tailed Learning · Vision Transformer · Contrastive Learning
 · Curriculum Warmup · External Validation · Grad-CAM.

1 Introduction

Ung thư bàng quang (Bladder Cancer) là một trong mười bệnh lý ác tính phổ biến nhất trên toàn cầu, với hơn 570.000 ca mắc mới và 212.000 ca tử vong mỗi năm [1, 2]. Nội soi bàng quang ánh sáng trắng (White Light Cystoscopy – WLC) kết hợp nội soi dải tần hẹp (Narrow Band Imaging – NBI) là phương pháp tiêu chuẩn vàng giúp phẫu thuật viên phát hiện sớm tổn thương niêm mạc, định hướng sinh thiết và thực hiện phẫu thuật cắt đốt u nội soi qua niệu đạo (Transurethral Resection of Bladder Tumor – TURBT) [3, 7]. Tuy nhiên, quy trình chẩn đoán qua nội soi phụ thuộc lớn vào kinh nghiệm và sự tập trung của bác sĩ, dễ dẫn đến tỷ lệ bỏ sót các tổn thương phẳng như ung thư biểu mô tại chỗ (Carcinoma in Situ – CIS) lên tới 10–20%, đồng thời tạo ra tỷ lệ dương tính giả cao do niêm mạc viêm mạn tính hoặc các mốc giải phẫu tự nhiên [2, 8].

Trong thực hành lâm sàng, quy trình chẩn đoán nội soi bàng quang mang tính **phân cấp tự nhiên (Diagnostic Hierarchy)** gồm 3 mức độ:

1. **Layer 1 – Binary Detection:** Xác định nhanh vùng nghi ngờ tổn thương (Region of Interest – ROI) so với vùng bình thường hoặc dị vật (Non-ROI) để cảnh báo tức thời cho phẫu thuật viên.
2. **Layer 2 – Coarse Grouping:** Phân loại thành 5 nhóm bệnh cảnh lâm sàng lớn: Ác tính (*Malignant*), Không ác tính (*Non-malignant*), Niêm mạc bình thường (*Normal mucosa*), Mốc giải phẫu (*Anatomical landmarks*), và Dị vật/Dụng cụ can thiệp (*Foreign bodies/Artefacts*).
3. **Layer 3 – Fine-Grained Diagnostic Classification:** Nhận diện chính xác 22 phân lớp chẩn đoán chi tiết (gồm các dạng tổn thương ác tính như *HighGradePapillary*, *LowGradePapillary*, *CIS*; dạng viêm/lành tính; các mốc giải phẫu và dị vật can thiệp) nhằm phục vụ quyết định can thiệp phẫu thuật chính xác.

Mặc dù việc phân loại đa tầng mang lại giá trị lâm sàng vượt bậc, việc huấn luyện mô hình học sâu đối mặt với hiện tượng **mất cân bằng phân phối dài đuôi cực đoan (Extreme Long-Tailed Distribution)** [1]. Cụ thể, trong bộ dữ liệu CystoDS [1], lớp niêm mạc bình thường chiếm áp đảo tới 79,16% (6.386/8.067 ảnh), trong khi nhiều phân lớp ác tính và tổn thương hiểm (như CIS, PreMalignant, BenignRare) chỉ xuất hiện ở từ 1 đến 6 bệnh nhân.

Khi giải quyết bài toán này, các phương pháp hiện hành bộc lộ ba mâu thuẫn kỹ thuật cốt lõi:

- **Representation vs. Classifier Trade-off:** Huấn luyện đa nhiệm một giai đoạn đồng thời (1-Stage Joint) với các hàm mất mát đuôi dài mạnh (như Balanced Softmax [10]) tạo ra gradient lớn từ các lớp đuôi, làm méo mó không gian đặc trưng tổng quát và làm suy giảm độ chính xác của các lớp đa số và lớp thô [12].
- **Early Hierarchy Bottleneck:** Việc áp đặt ràng buộc phả hệ cứng ($L_{\text{hierarchy}}$) ngay từ những epoch đầu tiên gò bó không gian biểu diễn của mạng xương sống (Backbone), cản trở việc học các đặc trưng thị giác biểu mô cơ bản [9].
- **Decision Boundary Drift:** Khi tinh chỉnh đầu phân loại chi tiết (Fine Head) ở giai đoạn sau, nếu không có cơ chế cố định biểu diễn và cô lập tham số các đầu phân loại tầng trên, ranh giới quyết định của tầng Binary và Coarse sẽ bị ảnh hưởng tiêu cực.

Nhằm giải quyết các hạn chế trên, nghiên cứu này đề xuất khung phương pháp **CystoHier** trên nền tảng kiến trúc Swin Transformer [9]. Bài báo đóng góp các giá trị khoa học cốt lõi sau:

1. **Shared Late-Stage Multi-Head Architecture:** Thiết kế trích xuất đặc trưng chung ở Stage 4 sâu nhất (vector $z \in \mathbb{R}^{768}$) cung cấp trường tiếp nhận toàn cảnh và độ bền vững trước nhiễu loạn nội soi.
2. **Smoothed Balanced Softmax Loss with Patient-Count Prior:** Đề xuất công thức điều hòa logit dựa trên căn bậc hai số lượng bệnh nhân thực tế ($\pi_j = \text{patients}_j^{0,5}$), giảm thiểu sai số do phân bố ảnh lặp lại ở cấp bệnh nhân.
3. **Supervised Contrastive Regularization:** Tích hợp $\mathcal{L}_{\text{supcon}}$ giúp co cụm các tổn thương cùng phân lớp chi tiết và tách biệt ranh giới biểu mô trong không gian ẩn.
4. **Curriculum Hierarchy Warmup Schedule:** Cơ chế tăng dần trọng số ràng buộc phả hệ từ $0 \rightarrow 0,25$ trong 12 epochs đầu, giải phóng không gian đặc trưng ở giai đoạn khởi tạo.
5. **Three-Stage Sequential Decoupled Training:** Tách bạch: *Representation Learning* $\rightarrow$ *Coarse Alignment* $\rightarrow$ *Fine Alignment* với cơ chế cô lập tham số bảo toàn biểu diễn (*Parameter-Isolated Representation Preservation*).
6. **Hierarchical Marginalization & Blending Inference:** Tích lũy xác suất từ 22 lớp con chi tiết về 5 nhóm cha kết hợp hòa trộn ($\lambda = 0,25$), tăng Coarse Accuracy thêm +0,0524 trên tập Test độc lập.
7. **Comprehensive Backbone & Loss Benchmarking:** Sàng lọc hệ thống 4 họ kiến trúc mạng thị giác và 7 hàm mất mát xử lý phân phối dài đuôi qua 3 phân hoạch hold-out 100% độc lập bệnh nhân.
8. **Independent External Cohort Validation:** Khảo sát trực tiếp mô hình trên toàn bộ 1.754 ảnh / 23 bệnh nhân của bộ dữ liệu Lazo et al. [4] nhằm kiểm chứng năng lực tổng quát hóa zero-shot.

Table 1. Summary and comparison of related deep learning studies in bladder cystoscopy image analysis.

Study / Reference	Dataset / Sample Size	Taxonomy / Levels	Patient-Diagnostic	Core Methodology	Primary Limitation
Lee et al. (CystoDS) [1]	8,067 images / 160 Pts	1 level (2 classes ROI)	Single Split	SwiN-Large Baseline	Binary only, ignores 5 Coarse / 22 Fine
Shkolyar et al. [2]	Internal WLC Video	1 level (Tumor Detection)	Yes	CNN Object Detection	No fine-grained classification
Wu et al. [3]	69,204 images / 10,729 Pts	1 level (Malignant vs Benign)	Multicenter	CNN Classifier	Flat binary, lacks fine diagnostic depth
Lazo et al. [4]	1,754 images / 23 Pts	1 level (4 tissue classes)	Yes	Semi-supervised CNN	Small cohort, lacks hierarchical tree
Wang et al. [7]	Multicenter NBI	2 levels (Tumor / Grade)	Yes	Multitask CNN	Strictly requires NBI hardware
Ours (CystoHier)	8,067 images / 160 Pts	3 levels (2 / 5 / 22 classes)	3-Split Standardized CystoHier (3S + Blending)	Simultaneously solves 3-level taxonomy & tail	

2 Related Work

2.1 Deep Learning in Cystoscopy Image Analysis

Trong những năm gần đây, nhiều nghiên cứu đã ứng dụng mạng nơ-ron tích chập (CNN) và Vision Transformer vào bài toán nội soi bàng quang. Shkolyar và cộng sự (2019) [2] đã phát triển hệ thống CystoNet phát hiện khối u bàng quang trên video WLC với độ nhạy 0,9090 và độ đặc hiệu 0,9860. Wu và cộng sự (2022) [3] thực hiện nghiên cứu đa trung tâm quy mô lớn trên 69.204 ảnh nội soi nhằm phân loại nhị phân tổn thương ác tính và lành tính. Lazo và cộng sự (2023) [4] đề xuất mô hình bán giám sát phân loại 4 nhóm mô trên 1.754 ảnh WLC/NBI. Jia và cộng sự (2023) [5] tích hợp Transformer nâng cao độ chính xác phát hiện u. Gần đây, Abd El-Aziz và cộng sự (2025) [6] sử dụng EfficientNet-B3 phân loại mô bàng quang, và Wang và cộng sự (2026) [7] xây dựng hệ thống chẩn đoán đa trung tâm dựa trên ảnh nội soi NBI.

Nghiên cứu công bố bộ dữ liệu CystoDS của Lee và cộng sự (2026) [1] đã thiết lập chuẩn đánh giá trên 8.067 ảnh nội soi. Tuy nhiên, nghiên cứu gốc chỉ khảo sát bài toán phân loại nhị phân phẳng (ROI Detection) trên một phân hoạch đơn lẻ, hoàn toàn chưa khai thác cấu trúc phân cấp 5 nhóm Coarse và 22 phân lớp chẩn đoán chi tiết.

2.2 Hierarchical Classification and Long-Tailed Learning

Học phân cấp (Hierarchical Classification) khai thác cấu trúc cây phả hệ y học để áp đặt tính nhất quán ngữ nghĩa, đảm bảo rằng một mẫu được dự đoán là lớp con chi tiết thì bắt buộc phải thuộc về nhóm cha tương ứng [4].

Đối với bài toán mất cân bằng phân phối dài đuôi (Long-Tailed Learning), các kỹ thuật truyền thống bao gồm tái lấy mẫu (Re-sampling) và tái đánh trọng số (Cost-sensitive Re-weighting) [10]. Kang và cộng sự (2020) [12] chứng minh rằng việc tách rời quy trình học đặc trưng và cân bằng bộ phân loại (Decoupled Training / cRT) mang lại hiệu quả vượt trội. Ren và cộng sự (2020) [10] đề xuất Balanced Softmax nhằm dịch chuyển biên phân loại theo xác suất tiên nghiệm của nhân, trong khi Menon và cộng sự (2021) [13] xây dựng cơ sở lý thuyết cho Logit Adjustment. Trong nghiên cứu này, chúng tôi phát triển khung phương pháp **CystoHier** kết hợp toàn diện các cơ chế trên nhằm giải quyết trọn vẹn cả ba thách thức: phân cấp, dài đuôi và bảo toàn biểu diễn (Table 1).

Table 2. Comprehensive specification of the 3-level diagnostic hierarchy and all 22 fine-grained diagnostic classes in the CystoDS benchmark.

Taxonomy Level Classes Clinical Grouping and Detailed Fine-Grained Diagnostic Entities		
Layer 1: Binary	2	ROI (Lesion suspicious) vs Non-ROI (Normal mucosa, anatomical landmarks, foreign artefacts)
Layer 2: Coarse	5	Malignant, Non-malignant, Normal mucosa, Anatomical landmarks, Foreign bodies / Artefacts
Layer 3: Fine	22	Malignant (4 classes): <i>LowGradePapillary, HighGradePapillary, CIS, PreMalignant</i> Non-malignant (8 classes): <i>BenignNOS, InflammationNOS, CCG, Denuded, UrothelialPapilloma, SquamousMetaplasia, NephrogenicAdenoma, BenignRare</i> Normal mucosa (1 class): <i>NormalMucosa</i> Anatomical landmarks (6 classes): <i>UreteralOrifice, ResectionBed, ResectionScar, Trabeculation, ProstaticUrethra, Diverticulum</i> Foreign bodies / Artefacts (4 classes): <i>AirBubble, ResectionLoop, BiopsyForcep, Stent</i>

3 Dataset and Experimental Protocol

3.1 Three-Level Diagnostic Hierarchy of the CystoDS Dataset

Bộ dữ liệu CystoDS [1] bao gồm tổng cộng 8.067 ảnh nội soi WLC thu nhận từ 160 bệnh nhân duy nhất, được gắn nhãn đồng thời ở 3 cấp độ chẩn đoán y khoa với 22 phân lớp chi tiết (Table 2):

- **Layer 1 (Binary – 2 classes):** Vùng tổn thương (*ROI*: Malignant + Non-malignant) và vùng không tổn thương (*Non-ROI*: Normal mucosa + Landmarks + Foreign bodies).
- **Layer 2 (Coarse – 5 groups):** *Malignant, Non-malignant, Normal mucosa, Anatomical landmarks, và Foreign bodies / Artefacts.*
- **Layer 3 (Fine – 22 diagnostic classes):** 4 phân lớp ác tính, 8 phân lớp viêm/không ác tính, 1 niêm mạc bình thường, 6 mốc giải phẫu, và 4 dị vật/dụng cụ can thiệp.

3.2 Data Leakage Prevention and Patient-Disjoint Partitioning Protocol

Để đảm bảo tính hợp lệ y khoa tuyệt đối và ngăn chặn hiện tượng rò rỉ dữ liệu (Data Leakage), toàn bộ các thực nghiệm được thiết kế theo giao thức **3-Fold Patient-Disjoint Hold-out** cố định:

- **Phân chia 100% theo danh tính bệnh nhân (Patient-Disjoint):** 160 bệnh nhân được phân chia ngẫu nhiên có phân tầng thành 3 phân hoạch độc lập (*split_0, split_1, split_2*) theo tỷ lệ 0,70 Huấn luyện (112 bệnh nhân), 0,15 Thẩm định (24 bệnh nhân), và 0,15 Kiểm định độc lập (24 bệnh nhân). Mọi ảnh của một bệnh nhân chỉ xuất hiện duy nhất ở một tập split.
- **Kiểm soát thiên lệch niêm mạc bình thường:** Áp dụng giới hạn tối đa 540 ảnh Normal mucosa trong tập Train (*normal_mucosa_limit: 540*) nhằm tránh hiện tượng gradient của niêm mạc lạnh lấn át hoàn toàn các đặc trưng bệnh lý chi tiết.
- **Kiểm định toàn vẹn:** Toàn bộ danh sách phân hoạch được xuất thành *protocol_manifest.json* và niêm phong bằng mã băm SHA-256 nhằm đảm bảo khả năng tái lập độc lập.




Fig. 1. Dataset distribution of the CystoDS benchmark across three taxonomy levels: (a) Coarse-level breakdown showing the dominance of Normal mucosa (0.7916); (b) Long-tailed sample and patient count distribution across 22 fine-grained diagnostic classes.

4 Proposed Method: CystoHier

4.1 Shared Late-Stage Multi-Head Architecture

Mô hình **CystoHier** sử dụng mạng xương sống **Swin Transformer Tiny** (**Swin-Tiny**) [9] tiền huấn luyện trên ImageNet (28,23 triệu tham số). Mạng gồm 4 stages với cơ chế Shifted Window Self-Attention, kích thước cửa sổ 7×7 .

Chúng tôi áp dụng cấu hình **Shared Late-Stage**: toàn bộ 3 đầu phân loại (Binary Head, Coarse Head, Fine Head) đều nhận chung vector đặc trưng ngữ nghĩa cao cấp $z \in \mathbb{R}^{768}$ trích xuất tại Stage 4 sau lớp LayerNorm (Fig. 2). So với việc phân nhánh từ các tầng sớm, việc chia sẻ toàn bộ mạng tới Stage 4 cung cấp trường tiếp nhận lớn, nắm bắt đồng thời hình thái tổn thương toàn cảnh và vi cấu trúc mao mạch mà không bị phân tán bởi ánh sáng lóa hoặc bóng khí.

4.2 Three-Stage Sequential Decoupled Training Pipeline

Quy trình huấn luyện của **CystoHier** được thiết kế nhằm tách biệt học biểu diễn và cân bằng bộ phân loại:

1. **Stage 1 – Representation Learning:** Mở khóa toàn bộ 100% Backbone và 3 đầu phân loại. Tối ưu hàm mất mát tổng thể $\mathcal{L}_{\text{total}}^{(1)}$ kết hợp Binary BCE, Coarse/Fine Cross-Entropy, Supervised Contrastive Loss ($\mathcal{L}_{\text{supcon}}$) và **Lịch trình Curriculum Hierarchy Warmup** ($w_{\text{hrc}}(t)$).




Fig. 2. Architecture and workflow of the proposed **CystoHier** framework: Endoscopy images are processed through a shared Swin-Tiny backbone. Features $z \in \mathbb{R}^{768}$ are classified via three hierarchical heads, supervised by Supervised Contrastive Loss ($\mathcal{L}_{\text{supcon}}$), task losses ($\mathcal{L}_{\text{bin}}$, $\mathcal{L}_{\text{SBS}}$ (coarse), $\mathcal{L}_{\text{SBS}}$ (fine)) with Patient-Count Priors, and Coarse-Fine Consistency ($\mathcal{L}_{\text{cf}}$) with Curriculum Warmup scheduling.

2. **Stage 2 – Coarse Alignment:** Đóng băng toàn bộ Backbone, Binary Head và Fine Head. Chỉ cập nhật `coarse_head` bằng hàm Smoothed Balanced Softmax trong 10 epochs. Quy trình này bảo toàn không gian biểu diễn thông qua cơ chế đóng băng tham số (*Parameter-Isolated Representation Preservation*) đồng thời nắn chỉnh ranh giới phân nhóm thô.
3. **Stage 3 – Fine Alignment:** Đóng băng toàn bộ Backbone, Binary Head và Coarse Head. Chỉ cập nhật `fine_head` bằng hàm Smoothed Balanced Softmax kết hợp ràng buộc phả hệ Coarse-Fine ($\mathcal{L}_{\text{cf}}$) với trọng số 0,25.

4.3 Mathematical Formulations of Objective Functions and Total Loss

Hàm mất mát Supervised Contrastive ($\mathcal{L}_{\text{supcon}}$): Tăng cường độ co cụm không gian đặc trưng giữa các ảnh cùng phân lớp và đẩy xa các phân lớp khác [11]:

$$\mathcal{L}_{\text{supcon}} = \sum_{i \in I} \frac{-1}{|P(i)|} \sum_{p \in P(i)} \log \frac{\exp(z_i \cdot z_p / \tau)}{\sum_{a \in A(i)} \exp(z_i \cdot z_a / \tau)} \quad (1)$$

trong đó $\tau = 0,10$ là nhiệt độ co cụm, $P(i)$ là tập các mẫu cùng lớp với mẫu i trong mini-batch.

Ràng buộc phả hệ Coarse-Fine ($\mathcal{L}_{\text{cf}}$): Phạt sự phân kỳ Kullback-Leibler giữa phân phối xác suất dự đoán của Coarse Head (P_{coarse}) và xác suất tích lũy từ các lớp con của Fine Head ($P_{\text{from_fine}}$):

$$\mathcal{L}_{\text{cf}} = D_{\text{KL}}(P_{\text{coarse}} \parallel P_{\text{from_fine}}), \quad \text{với } P_{\text{from_fine}}(C) = \sum_{f \in \text{Children}(C)} P_{\text{fine}}(f) \quad (2)$$

Hàm mất mát Smoothed Balanced Softmax (SBS): Cân bằng biên phân loại theo phân phối dài đuôi dựa trên tiên nghiệm mượt theo số lượng bệnh nhân thực tế [10]:

$$\mathcal{L}_{\text{SBS}}(y, \hat{z}) = -\log \frac{\pi_y \cdot \exp(\hat{z}_y)}{\sum_{j=1}^K \pi_j \cdot \exp(\hat{z}_j)}, \quad \text{với } \pi_j = (\text{patients}_j + \epsilon)^{0,5} \quad (3)$$

Việc sử dụng tiên nghiệm căn bậc hai số bệnh nhân thay vì số lượng ảnh giúp giảm thiểu hiện tượng méo mó thống kê do một số bệnh nhân chụp quá nhiều ảnh lặp lại.

Hàm mất mát tổng thể theo từng giai đoạn (Total Stage Loss Formulations):

– *Giai đoạn 1 (Representation Learning):*

$$\mathcal{L}_{\text{total}}^{(1)} = (\mathcal{L}_{\text{bin}} + \mathcal{L}_{\text{coarse}} + \mathcal{L}_{\text{fine}}) + \lambda_{\text{supcon}} \mathcal{L}_{\text{supcon}} + w_{\text{hrc}}(t) \mathcal{L}_{\text{cf}} \quad (4)$$

với $\lambda_{\text{supcon}} = 0,10$, $\mathcal{L}_{\text{bin}}$ là Binary Cross-Entropy, $\mathcal{L}_{\text{coarse}}$ và $\mathcal{L}_{\text{fine}}$ là Cross-Entropy tiêu chuẩn.

– *Giai đoạn 2 (Coarse Alignment):*

$$\mathcal{L}_{\text{total}}^{(2)} = \mathcal{L}_{\text{SBS}}(\text{Coarse}, \pi_{\text{coarse}}) \quad (5)$$

– *Giai đoạn 3 (Fine Alignment):*

$$\mathcal{L}_{\text{total}}^{(3)} = \mathcal{L}_{\text{SBS}}(\text{Fine}, \pi_{\text{fine}}) + \lambda_{\text{cf}} \mathcal{L}_{\text{cf}}, \quad \text{với } \lambda_{\text{cf}} = 0,25 \quad (6)$$

4.4 Curriculum Hierarchy Warmup Scheduling

Để giải quyết thắt cổ chai phân cấp sớm ở Giai đoạn 1, chúng tôi thiết lập lịch trình tăng dần trọng số ràng buộc phủ hệ:

$$w_{\text{hrc}}(t) = 0,25 \times \min \left(1,0, \frac{t}{12} \right) \quad (7)$$

Ở các epoch đầu ($t \leq 4$), $w_{\text{hrc}} \approx 0$, cho phép mạng tự do định hình không gian biểu diễn tổng quát phong phú. Từ epoch $5 \rightarrow 12$, trọng số tăng tuyến tính tới 0,25 để uốn nắn tính nhất quán phủ hệ khi đặc trưng đã hội tụ ổn định.

4.5 Hierarchical Marginalization and Multi-Head Blending Inference

Khi suy luận lâm sàng, thay vì chỉ sử dụng đầu Coarse Head trực tiếp, mô hình áp dụng công thức hòa trộn xác suất:

$$P_{\text{ens}}(C) = \lambda P_{\text{coarse}}(C) + (1 - \lambda) \sum_{f \in \text{Children}(C)} P_{\text{fine}}(f) \quad (8)$$

với $\lambda = 0,25$. Cơ chế này tận dụng 75% thông tin phân giải cao từ Fine Head để suy ngược và hiệu chỉnh xác suất nhóm cha, giảm thiểu các phán đoán mâu thuẫn về cấu trúc.

Table 3. Comprehensive gold-standard performance benchmark on the independent test set across 3 patient-disjoint hold-out splits. Bold indicates the highest value in each column.

Category	Model / Architecture	Binary AUROC	Binary F1	Coarse Acc	Fine F1 (Supp)	Fine F1 (All)	C-F Consist
Proposed	CystoHier (Proposed)	0.9986 $\pm$ 0.0002	0.9811 $\pm$ 0.0036	0.8642 $\pm$ 0.0352	0.6450 $\pm$ 0.1105	0.4691 $\pm$ 0.0804	0.8952 $\pm$ 0.0380
Multitask	Swin-Tiny (Multitask CE)	0.9989 $\pm$ 0.0010	0.9876 $\pm$ 0.0030	0.8379 $\pm$ 0.0700	0.6102 $\pm$ 0.1210	0.4438 $\pm$ 0.0880	0.8120 $\pm$ 0.0250
Multitask	HRNet-W18 (Multitask CE)	0.9930 $\pm$ 0.0030	0.9608 $\pm$ 0.0110	0.7720 $\pm$ 0.1220	0.5704 $\pm$ 0.2030	0.4149 $\pm$ 0.1470	0.7640 $\pm$ 0.0310
Multitask	ResNeXt-50 (Multitask CE)	0.9854 $\pm$ 0.0090	0.9452 $\pm$ 0.0160	0.7761 $\pm$ 0.1010	0.4024 $\pm$ 0.1580	0.2927 $\pm$ 0.1150	0.7450 $\pm$ 0.0280
Multitask	ResNet-152 (Multitask CE)	0.9740 $\pm$ 0.0180	0.9370 $\pm$ 0.0340	0.7508 $\pm$ 0.1400	0.3578 $\pm$ 0.1630	0.2602 $\pm$ 0.1180	0.7180 $\pm$ 0.0340
Single-Task	Swin-Tiny (Binary/Coarse/Fine)	0.9980 $\pm$ 0.0010	0.9759 $\pm$ 0.0070	0.8145 $\pm$ 0.0580	0.5840 $\pm$ 0.1050	0.4215 $\pm$ 0.0750	—
Single-Task	HRNet-W18 (Binary/Coarse/Fine)	0.9917 $\pm$ 0.0050	0.9680 $\pm$ 0.0170	0.7680 $\pm$ 0.0940	0.5420 $\pm$ 0.1800	0.3950 $\pm$ 0.1300	—
Single-Task	ResNeXt-50 (Binary/Coarse/Fine)	0.9782 $\pm$ 0.0120	0.9290 $\pm$ 0.0300	0.7490 $\pm$ 0.0810	0.3810 $\pm$ 0.1450	0.2790 $\pm$ 0.1020	—
Single-Task	ResNet-152 (Binary/Coarse/Fine)	0.9790 $\pm$ 0.0080	0.9444 $\pm$ 0.0280	0.7240 $\pm$ 0.1120	0.3420 $\pm$ 0.1500	0.2480 $\pm$ 0.1100	—

5 Experimental Results and In-Depth Analysis

5.1 Gold-Standard Performance Benchmark on Independent Test Set

Table 3 báo cáo kết quả đối chuẩn trực tiếp giữa mô hình đề xuất **CystoHier** và toàn bộ các mô hình cơ sở đơn nhiệm và đa nhiệm trên tập Test độc lập 100% bệnh nhân (24 bệnh nhân, 337 ảnh per split), tính trung bình và độ lệch chuẩn (Mean $\pm$ Std) qua toàn bộ 3 phân hoạch hold-out.

Phân tích kết quả chính:

- Cải thiện rõ nét trên tầng phân lớp chi tiết: CystoHier** đạt Fine Macro-F1 (Supported) = **0,6450 $\pm$ 0,1105**, cao hơn so với Multitask Swin-Tiny (0,6102, tăng +0,0348) và Single-Task Fine Swin-Tiny (0,5840, tăng +0,0610), và vượt trội so với ResNet-152 (0,3578).
- Duy trì độ nhạy và đặc hiệu nhị phân vững chắc:** Đạt Binary AUROC 0,9986 $\pm$ 0,0002, Độ nhạy 0,9845 $\pm$ 0,0050, Độ đặc hiệu 0,9912 $\pm$ 0,0040, và Binary F1 0,9811 $\pm$ 0,0036, tương đương với baseline chuyên biệt đơn nhiệm.
- Nâng cao tính nhất quán phủ hệ (0,8952):** Nhờ cơ chế Hierarchical Marginalization ($\lambda = 0,25$), Coarse Accuracy đạt **0,8642 $\pm$ 0,0352** (tăng +0,0524 so với Coarse Head trực tiếp), đồng thời tính nhất quán Coarse-Fine đạt 0,8952 $\pm$ 0,0380.

5.2 Vision Backbone Architecture Screening

Table 4 khảo sát 4 họ kiến trúc mạng xương sống tiêu biểu (Swin Transformer, HRNet, ResNeXt, ResNet) trên tập Validation qua 3 phân hoạch hold-out độc lập.

Phân tích cơ chế: Swin-Tiny với cơ chế Shifted Window Self-Attention thể hiện tính ưu việt rõ rệt so với các mạng CNN truyền thống. Trên Fine Head, Swin-Tiny đạt Macro-F1 0,5105, cao hơn hẳn so với ResNet-152 (0,2098) và HRNet-W18 (0,3979). Cơ chế cửa sổ trượt cho phép mạng vừa thu nhận các đặc trưng cấu trúc mạch máu vi mô (*vascular loops*) ở phạm vi cục bộ, vừa duy trì trường tiếp nhận rộng để định vị toàn thể khoang bàng quang.

Table 4. Backbone architecture screening across 4 vision model families on validation hold-outs. Bold indicates highest value per column.

Architecture	Training Regime	Binary AUROC	Binary F1	Coarse Acc	Coarse Macro-F1	Fine Acc	Fine F1 (Supp)
Swin-Tiny	Multitask (3-Heads)	0.9507 $\pm$ 0.0270	0.8992 $\pm$ 0.0290	0.7119 $\pm$ 0.0250	0.6243 $\pm$ 0.0140	0.4928 $\pm$ 0.0650	0.5105 $\pm$ 0.0680
Swin-Tiny	Binary Only	0.9590 $\pm$ 0.0330	0.8930 $\pm$ 0.0340	—	—	—	—
HRNet-W18	Multitask (3-Heads)	0.9385 $\pm$ 0.0350	0.8759 $\pm$ 0.0220	0.6366 $\pm$ 0.0430	0.5461 $\pm$ 0.0350	0.4344 $\pm$ 0.0340	0.3979 $\pm$ 0.0560
HRNet-W18	Binary Only	0.9579 $\pm$ 0.0210	0.8984 $\pm$ 0.0200	—	—	—	—
ResNeXt-50	Multitask (3-Heads)	0.9088 $\pm$ 0.0370	0.8387 $\pm$ 0.0250	0.5861 $\pm$ 0.0140	0.4600 $\pm$ 0.0280	0.3705 $\pm$ 0.0350	0.2023 $\pm$ 0.0360
ResNet-152	Multitask (3-Heads)	0.8698 $\pm$ 0.0500	0.8191 $\pm$ 0.0380	0.5662 $\pm$ 0.0030	0.4398 $\pm$ 0.0170	0.3471 $\pm$ 0.0520	0.2098 $\pm$ 0.0380

Table 5. Comparative evaluation of 7 long-tailed loss formulations on the Swin-Tiny backbone. Bold indicates highest value per column.

# Loss Formulation	Binary AUROC	Binary F1	Coarse Acc	Fine Acc	Fine F1 (Supp)	Tail Recall
1 Smoothed Balanced Softmax (Ours)	0.9521 $\pm$ 0.0390	0.8907 $\pm$ 0.0580	0.7012 $\pm$ 0.0390	0.5245 $\pm$ 0.0170	0.5506 $\pm$ 0.0740	0.6638 $\pm$ 0.1140
2 Patient-Count Prior (Linear $\pi_j = N_{pts}$)	0.9515 $\pm$ 0.0350	0.8890 $\pm$ 0.0400	0.6980 $\pm$ 0.0310	0.5112 $\pm$ 0.0320	0.5180 $\pm$ 0.0650	0.6420 $\pm$ 0.0850
3 Balanced Softmax (Image Prior $\pi_j = N_{img}$)	0.9531 $\pm$ 0.0380	0.8893 $\pm$ 0.0310	0.6958 $\pm$ 0.0260	0.5008 $\pm$ 0.0570	0.4823 $\pm$ 0.0600	0.6276 $\pm$ 0.0610
4 Logit Adjustment	0.9455 $\pm$ 0.0420	0.8888 $\pm$ 0.0500	0.6998 $\pm$ 0.0300	0.4962 $\pm$ 0.0170	0.4822 $\pm$ 0.0480	0.5967 $\pm$ 0.0840
5 LDAM Loss	0.9522 $\pm$ 0.0200	0.8836 $\pm$ 0.0160	0.6937 $\pm$ 0.0190	0.4509 $\pm$ 0.0280	0.4908 $\pm$ 0.0580	0.6251 $\pm$ 0.1120
6 Focal Loss	0.9506 $\pm$ 0.0240	0.8938 $\pm$ 0.0320	0.6816 $\pm$ 0.0370	0.5109 $\pm$ 0.0570	0.4976 $\pm$ 0.0620	0.6097 $\pm$ 0.0860
7 Cross-Entropy (Baseline)	0.9489 $\pm$ 0.0420	0.8888 $\pm$ 0.0500	0.6749 $\pm$ 0.0220	0.5023 $\pm$ 0.0460	0.5268 $\pm$ 0.0760	0.6607 $\pm$ 0.0890
8 Weighted CE	0.9427 $\pm$ 0.0360	0.8747 $\pm$ 0.0380	0.6786 $\pm$ 0.0220	0.4918 $\pm$ 0.0350	0.5053 $\pm$ 0.0670	0.6397 $\pm$ 0.1090

5.3 Long-Tailed Loss Formulations and Patient-Count Prior Ablation

Table 5 đánh giá đối chuẩn 7 phương pháp loss trên cùng backbone Swin-Tiny qua 3-Fold Validation, đồng thời bóc tách vai trò độc lập giữa việc sử dụng tiên nghiệm số lượng bệnh nhân (*patient-count prior*) và phép làm mượt căn bậc hai.

Phân tích bóc tách Prior: So sánh giữa hàng 1, 2 và 3 trong Table 5 chứng minh rõ ràng:

- Việc chuyển từ *Image-count prior* (0,4823) sang *Patient-count prior tuyến tính* (0,5180) mang lại mức tăng +0,0357 F1-Score, chứng minh việc tính toán xác suất tiên nghiệm dựa trên bệnh nhân thực tế giúp loại bỏ nhiễu lấy mẫu lặp lại.
- Khi áp dụng thêm *phép làm mượt căn bậc hai* ($\pi_j = \sqrt{N_{pts}}$), F1-Score tiếp tục tăng lên mức cao nhất **0,5506 $\pm$ 0,0740** và Tail Recall đạt **0,6638 $\pm$ 0,1140**.

5.4 Systematic Ablation Studies and Component-Wise Analysis

Ablation 1: Training Paradigms & Stage Decoupling (Table 6): So sánh giữa các quy trình huấn luyện cho thấy mô hình 1-Stage Joint Baseline gặp hiện tượng xung đột gradient nghiêm trọng giữa đầu phân loại đuôi và không gian đặc trưng tổng quát (Fine F1 chỉ đạt 0,5026, C-F Consistency 0,7438). Mô hình **CystoHier (Proposed 3-Stage)** với cơ chế tách rời tuần tự và bảo toàn tham số nâng Fine F1 lên **0,5415 $\pm$ 0,0363** (+0,0389 vs 1-Stage) và tăng mạnh Coarse Accuracy lên **0,7837 $\pm$ 0,0100** (trên tập Validation) cùng C-F Consistency đạt **0,8228 $\pm$ 0,0050**.

Ablation 2: Hierarchy Loss Scheduling & Curriculum Warmup (Table 7): So sánh giữa các chiến lược lên lịch trọng số phân cấp khẳng định ưu việt của **Curriculum Warmup** ($w_{hrc}(t)$). Khi áp đặt trọng số cố định $w = 0,25$

Table 6. Ablation 1: Training paradigms and stage decoupling on validation hold-outs. Bold indicates highest value per column.

# Training Strategy	Binary AUROC	Binary F1	Coarse Acc	Coarse F1	Fine Acc	Fine F1 (Supp)	Fine F1 (All 22)	C-F Cons.
1 CystoHier (Proposed 3-Stage)	0.9571 $\pm$ 0.0210	0.8960 $\pm$ 0.0260	0.7837 $\pm$ 0.0100	0.6525 $\pm$ 0.0120	0.5307 $\pm$ 0.0400	0.5415 $\pm$ 0.0363	0.4007 $\pm$ 0.0150	0.8228 $\pm$ 0.0050
2 1-Stage Joint Baseline	0.9594 $\pm$ 0.0180	0.8965 $\pm$ 0.0120	0.7364 $\pm$ 0.0090	0.6576 $\pm$ 0.0060	0.5263 $\pm$ 0.0290	0.5026 $\pm$ 0.0460	0.3718 $\pm$ 0.0260	0.7438 $\pm$ 0.0320
3 2-Stage Decoupled (D2S)	0.9617 $\pm$ 0.0280	0.8912 $\pm$ 0.0220	0.7212 $\pm$ 0.0460	0.6313 $\pm$ 0.0310	0.5220 $\pm$ 0.0480	0.5266 $\pm$ 0.0560	0.3893 $\pm$ 0.0320	0.7890 $\pm$ 0.0240
4 Classifier Re-training (cRT)	0.9617 $\pm$ 0.0280	0.8910 $\pm$ 0.0240	0.7212 $\pm$ 0.0460	0.6313 $\pm$ 0.0310	0.5196 $\pm$ 0.0250	0.5311 $\pm$ 0.0480	0.3930 $\pm$ 0.0290	0.7845 $\pm$ 0.0260
5 Joint Stage 2 Tuning (All Heads)	0.9583 $\pm$ 0.0350	0.8875 $\pm$ 0.0310	0.7310 $\pm$ 0.0340	0.6435 $\pm$ 0.0310	0.5155 $\pm$ 0.0360	0.5129 $\pm$ 0.0590	0.3794 $\pm$ 0.0380	0.7680 $\pm$ 0.0290

Table 7. Ablation 2: Hierarchy loss scheduling and curriculum warmup across 3 validation splits. Bold indicates highest value per column.

# Scheduling Variant	Weight Schedule $w_{hrc}(t)$	Binary AUROC	Coarse Acc	Coarse F1	Fine Acc	Fine F1 (Supp)	C-F Cons.
1 Proposed Warmup	$0.25 \cdot \min(1.0, t/12)$	0.9571 $\pm$ 0.0210	0.7357 $\pm$ 0.0180	0.6525 $\pm$ 0.0120	0.5307 $\pm$ 0.0400	0.5415 $\pm$ 0.0363	0.8228 $\pm$ 0.0050
2 Two-Phase Step	$w = 0 \rightarrow 0.25$ at P2	0.9521 $\pm$ 0.0280	0.7176 $\pm$ 0.0110	0.6371 $\pm$ 0.0080	0.4898 $\pm$ 0.0410	0.5240 $\pm$ 0.0250	0.8155 $\pm$ 0.0180
3 Fixed Hierarchy	$w = 0.25$ constant	0.9466 $\pm$ 0.0310	0.7009 $\pm$ 0.0230	0.6119 $\pm$ 0.0180	0.4721 $\pm$ 0.0240	0.5199 $\pm$ 0.0480	0.8188 $\pm$ 0.0200
4 w/o Hierarchy Loss	$w = 0$ (Unconstrained)	0.9649 $\pm$ 0.0220	0.7346 $\pm$ 0.0170	0.6426 $\pm$ 0.0090	0.5272 $\pm$ 0.0200	0.5414 $\pm$ 0.0770	0.7240 $\pm$ 0.0410
5 w/o Binary-Coarse	$w_{bc} = 0, w_{cf} = 0.25$	0.9528 $\pm$ 0.0570	0.7175 $\pm$ 0.0070	0.6206 $\pm$ 0.0110	0.4906 $\pm$ 0.0280	0.5120 $\pm$ 0.0350	0.8243 $\pm$ 0.0280
6 w/o Coarse-Fine	$w_{bc} = 0.25, w_{cf} = 0$	0.9605 $\pm$ 0.0210	0.7151 $\pm$ 0.0400	0.6313 $\pm$ 0.0290	0.5292 $\pm$ 0.0410	0.5312 $\pm$ 0.0280	0.8131 $\pm$ 0.0310

ngay từ đầu (*Fixed Hierarchy*), mạng bị gò bó không gian đặc trưng biểu mô sớm, khiến Coarse Accuracy tụt xuống 0,7009 và Fine Accuracy chỉ đạt 0,4721. Việc tăng dần trọng số $0 \rightarrow 0,25$ trong 12 epoch đầu giúp mạng vừa tự do học biểu diễn phong phú, vừa đạt độ nhất quán phủ hệ cao nhất **0,8228 $\pm$ 0,0050**.

Ablation 3: Loss Component Marginal Contributions (Table 8): Khảo sát đóng góp cận biên của từng hàm mục tiêu xác định: (1) Loại bỏ Supervised Contrastive Loss ($\mathcal{L}_{supcon}$) gây suy giảm mạnh nhất Primary Fine F1 ($-0,0487$, từ 0,6114 $\rightarrow$ 0,5627), chứng minh vai trò quyết định của việc co cụm không gian đặc trưng; (2) Loại bỏ Smoothed Balanced Softmax làm giảm Tail Recall $-0,0537$ (từ 0,6523 $\rightarrow$ 0,5986) và giảm C-F Consistency $-0,0422$.

Ablation 4: Architectural Head Placement & Backbone Freezing Depth (Table 9): Khi phân nhánh các đầu phân loại từ các tầng sớm (Intermediate Heads: Binary tại Stage 2, Coarse tại Stage 3), Binary AUROC sụt giảm nghiêm trọng $-0,1216$ và Fine Accuracy giảm $-0,1043$, khẳng định trường tiếp nhận toàn cục tại Stage 4 là bắt buộc để giải quyết nhiễu quang học. Về độ sâu đóng băng (Part B), việc đóng băng Stage 1–2 giúp giảm 0,2600 thời gian huấn luyện trong khi vẫn duy trì Fine F1 cao (0,4556 vs 0,4396), cung cấp một phương án huấn luyện tiết kiệm tài nguyên cho các cơ sở y tế.

Ablation 5: Hyperparameters & Hierarchical Marginalization Blending (Table 10): Khảo sát nhiệt độ co cụm cho thấy $\tau = 0,10$ và trọng số $w_{supcon} = 0,10$ đạt điểm cân bằng tối ưu giữa Fine F1 (0,6114) và độ nhất quán phủ hệ (0,8280). Đặc biệt, cơ chế hòa trộn xác suất Hierarchical Marginalization với $\lambda = 0,25$ nâng Coarse Accuracy trên tập Validation từ 0,7076 lên **0,7837 $\pm$ 0,0100** và trên tập Test độc lập từ 0,8118 lên **0,8642 $\pm$ 0,0352** ($+0,0524$).

Table 8. Ablation 3: Loss component marginal contributions on validation hold-outs. Bold indicates highest value per column.

#	Experimental Configuration	Binary AUROC	Binary F1	Coarse Acc	Fine Acc	Primary Fine F1	Tail Recall	C-F Cons.
1	Full Proposed (Anchor)	0.9596 $\pm$ 0.0320	0.8998 $\pm$ 0.0380	0.7276 $\pm$ 0.0150	0.5102 $\pm$ 0.0390	0.6114 $\pm$ 0.0230	0.6523 $\pm$ 0.0740	0.8280 $\pm$ 0.0260
2	w/o SupCon ($w = 0$)	0.9591 $\pm$ 0.0290	0.9015 $\pm$ 0.0380	0.7031 $\pm$ 0.0270	0.4774 $\pm$ 0.0150	0.5627 $\pm$ 0.0730	0.6708 $\pm$ 0.0690	0.8142 $\pm$ 0.0270
3	w/o Smoothed Balanced Softmax	0.9534 $\pm$ 0.0210	0.8937 $\pm$ 0.0260	0.7093 $\pm$ 0.0110	0.4892 $\pm$ 0.0320	0.6004 $\pm$ 0.0260	0.5986 $\pm$ 0.0940	0.7858 $\pm$ 0.0370
4	w/o Hierarchy Loss ($w = 0$)	0.9583 $\pm$ 0.0340	0.9009 $\pm$ 0.0280	0.7197 $\pm$ 0.0190	0.5129 $\pm$ 0.0120	0.5890 $\pm$ 0.0290	0.6554 $\pm$ 0.0640	0.8149 $\pm$ 0.0290
5	w/o Data Augmentation	0.9596 $\pm$ 0.0320	0.8998 $\pm$ 0.0380	0.7276 $\pm$ 0.0150	0.5102 $\pm$ 0.0390	0.6114 $\pm$ 0.0230	0.6523 $\pm$ 0.0740	0.8280 $\pm$ 0.0260

Table 9. Ablation 4: Architectural head placement and backbone freezing depth analysis. Bold indicates highest value per column.

#	Architecture / Freezing Configuration	Binary AUROC	Coarse Acc	Fine Acc	Fine F1 (Supp)	Compute Time / Ep
<i>A. Head Placement Analysis (Validation 3-Splits)</i>						
1	Shared Late-Stage (All 3 Heads at Stage 4)	0.9571 $\pm$ 0.0210	0.7357 $\pm$ 0.0180	0.5307 $\pm$ 0.0400	0.5415 $\pm$ 0.0363	59.41s
2	Multi-Stage Intermediate (S2 $\rightarrow$ Bin, S3 $\rightarrow$ Coarse, S4 $\rightarrow$ Fine)	0.8355 $\pm$ 0.0450	0.6873 $\pm$ 0.0310	0.4264 $\pm$ 0.0380	0.4806 $\pm$ 0.0490	56.12s
<i>B. Backbone Freezing Depth & Compute Trade-off (Split 0)</i>						
1	Full Fine-Tuning (100% Unfrozen: 27.52M)	0.9571	0.7404	0.4884	0.4396	59.41s (1.0 $\times$)
2	Freeze Stages 1–2 (95.7% Trainable: 26.32M)	0.9520	0.7021	0.4922	0.4556	43.97s (-0.2600)
3	Freeze Stages 1–3 (55.8% Trainable: 15.37M)	0.9140	0.6460	0.3798	0.4168	31.75s (-0.4660)

Table 10. Ablation 5: Hyperparameter sensitivity (τ, w_{supcon}) and hierarchical marginalization blending (λ). Bold indicates highest value per column.

Ablation Group	Parameter Configuration	Binary AUROC	Binary F1	Coarse Acc	Fine Acc	Fine F1 (Supp)	C-F Cons.
Temperature τ ($w = 0.10$)	$\tau = 0.05$	0.9664 $\pm$ 0.0240	0.9092 $\pm$ 0.0320	0.7251 $\pm$ 0.0400	0.5167 $\pm$ 0.0390	0.5847 $\pm$ 0.0130	0.8169 $\pm$ 0.0280
	$\tau = \mathbf{0.10}$ (Optimal)	0.9596 $\pm$ 0.0320	0.8998 $\pm$ 0.0380	0.7276 $\pm$ 0.0150	0.5102 $\pm$ 0.0390	0.6114 $\pm$ 0.0230	0.8280 $\pm$ 0.0260
	$\tau = 0.20$	0.9550 $\pm$ 0.0310	0.8954 $\pm$ 0.0270	0.7129 $\pm$ 0.0260	0.5194 $\pm$ 0.0100	0.5914 $\pm$ 0.0610	0.7941 $\pm$ 0.0360
Weight w_{supcon} ($\tau = 0.10$)	$w = 0.05$	0.9602 $\pm$ 0.0280	0.9035 $\pm$ 0.0300	0.7255 $\pm$ 0.0150	0.5367 $\pm$ 0.0420	0.6081 $\pm$ 0.0460	0.7980 $\pm$ 0.0340
	$w = \mathbf{0.10}$ (Optimal)	0.9596 $\pm$ 0.0320	0.8998 $\pm$ 0.0380	0.7276 $\pm$ 0.0150	0.5102 $\pm$ 0.0390	0.6114 $\pm$ 0.0230	0.8280 $\pm$ 0.0260
	$w = 0.20$	0.9630 $\pm$ 0.0290	0.9117 $\pm$ 0.0310	0.7159 $\pm$ 0.0240	0.5052 $\pm$ 0.0250	0.6228 $\pm$ 0.0300	0.7933 $\pm$ 0.0350
<i>Inference Marginalization Weight (λ): $P_{\text{out}}(C) = \lambda P_{\text{coarse}}(C) + (1 - \lambda) P_{\text{fine}}(C)$</i>							
	$\lambda = 1.00$ (Coarse Direct)	—	—	0.7076 $\pm$ 0.0110 (Val)	—	—	0.8118 $\pm$ 0.0410 (Test)
	$\lambda = 0.50$ (Equal Blend)	—	—	0.7650 $\pm$ 0.0090 (Val)	—	—	0.8510 $\pm$ 0.0420 (Test)
	$\lambda = \mathbf{0.25}$ (Optimal)	—	—	0.7837 $\pm$ 0.0100 (Val)	—	—	0.8642 $\pm$ 0.0352 (Test)
	$\lambda = 0.00$ (Fine Marg. Only)	—	—	0.7810 $\pm$ 0.0070 (Val)	—	—	0.8487 $\pm$ 0.0370 (Test)

5.5 External Cohort Validation on the Independent Lazo et al. Dataset

Nhằm đánh giá năng lực tổng quát hóa ngoại kiểm (*External Generalization*) khi chuyển giao sang một trung tâm y tế độc lập hoàn toàn với quang sai camera và chế độ quang học khác biệt, chúng tôi tiến hành kiểm định ngoại kiểm trực tiếp trên toàn bộ **1.754 ảnh nội soi từ 23 bệnh nhân** của bộ dữ liệu Lazo et al. [4] (Table 11).

Chi tiết quy chuẩn ánh xạ chẩn đoán (Diagnostic Mapping Protocol): Toàn bộ các mô hình được huấn luyện và lựa chọn checkpoint **chỉ trên bộ dữ liệu CystoDS** (không qua bất kỳ bước fine-tuning hay domain adaptation nào trên Lazo). Đánh giá được thực hiện theo ontology chẩn đoán tương thích y khoa:

- **Phân loại Nhị phân (Binary Mapping):** Nhóm dương tính ROI (Lesion) = LGC (647 ảnh) $\cup$ HGC (469 ảnh) $\cup$ NTL (134 ảnh) ($N = 1.250$ ảnh tổn thương); nhóm âm tính Non-ROI (Normal) = NST (504 ảnh) ($N = 504$ ảnh không nghi ngờ).
- **Phân loại Đa tầng (Taxonomy Mapping):** LGC $\leftrightarrow$ Coarse: Malignant $\leftrightarrow$ Fine: LowGradePapillary; HGC $\leftrightarrow$ Coarse: Malignant $\leftrightarrow$ Fine: HighGradePapillary; NTL $\leftrightarrow$ Coarse: Non-malignant $\leftrightarrow$ Fine: InflammationNOS/BenignNOS; NST $\leftrightarrow$ Coarse: Normal mucosa $\leftrightarrow$ Fine: NormalMucosa.

Phân tích lâm sàng và Giải thích chuyển giao miền quang học:

1. *Năng lực tổng quát hóa zero-shot vững chắc:* Mô hình **CystoHier** đạt AU-ROC ngoại kiểm **$0,9587 \pm 0,0118$** và F1-Score **$0,8875 \pm 0,0179$** trên dữ liệu hoàn toàn độc lập từ châu Âu mà không cần bất kỳ bước fine-tuning nào. Ước lượng bootstrap mức bệnh nhân 1.000 lần (Patient-Level Bootstrap) xác nhận khoảng tin cậy 95% của AUROC là $[0,9312; 0,9788]$.
2. *Cải thiện phát hiện tổn thương không tạo u (NTL):* Đối với các tổn thương viêm loét phẳng khó chẩn đoán (NTL), không gian biểu diễn phân cấp của **CystoHier** giúp nâng độ nhạy phát hiện từ 0,3905 lên **0,4602** (+0,0697), đồng thời cải thiện độ nhạy phát hiện ung thư biểu mô độ cao (HGC) lên **$0,8948 \pm 0,0196$** .
3. *Cơ chế chống trôi dạt đặc trưng dưới ánh sáng dải hẹp (NBI):* Chế độ nội soi NBI sử dụng hai bước sóng hẹp 415 nm (xanh lam) và 540 nm (xanh lục) nhằm làm nổi bật cấu trúc vi mạch máu niêm mạc. Do baseline đơn nhiệm học trực tiếp trên WLC dễ bị phụ thuộc vào phân bố màu sắc dải rộng, mô hình này bị sụt giảm độ nhạy trên ảnh NBI (Sensitivity 0,6978, Accuracy 0,7601). Ngược lại, việc tích hợp Supervised Contrastive Loss ($\mathcal{L}_{\text{supcon}}$) trong **CystoHier** giúp mạng học được các biểu diễn hình thái học và vi cấu trúc mao mạch bất biến trước sự thay đổi dải màu quang học, từ đó đạt Accuracy **0,8100** và Sensitivity **0,7547** vượt trội tại điểm vận hành lâm sàng NBI.

Table 11. External cohort benchmark on the independent Lazo et al. dataset (1,754 images / 23 patients across 3 CystoDS splits, Mean $\pm$ Std). Bold indicates superior single-model performance.

Subgroup / Pathology Metric	AUROC	Accuracy	Sensitivity	Specificity	F1-Score	Bal. Acc
<i>A. Toàn bộ tập Ngoại kiểm (Overall External Cohort: WLI + NBI, N=1,754 images / 23 Patients)</i>						
Swin Baseline (Binary Only)	0.9503 $\pm$ 0.0170	0.8480 $\pm$ 0.0251	0.8016 $\pm$ 0.0362	0.9630 $\pm$ 0.0034	0.8821 $\pm$ 0.0221	0.8823 $\pm$ 0.0170
CystoHier (Proposed Direct)	0.9587 $\pm$ 0.0118	0.8537 $\pm$ 0.0205	0.8123 $\pm$ 0.0315	0.9563 $\pm$ 0.0155	0.8875 $\pm$ 0.0179	0.8843 $\pm$ 0.0136
<i>B. Phân nhóm độ nặng mô bệnh học (Pathology Subgroup Sensitivity)</i>						
LGC Sensitivity (Low-Grade Carcinoma, N=647)	Swin: 0.8259 $\pm$ 0.0410			CystoHier: 0.8253 $\pm$ 0.0499		
HGC Sensitivity (High-Grade Carcinoma, N=469)	Swin: 0.8856 $\pm$ 0.0246			CystoHier: 0.8948 $\pm$ 0.0196		
NTL Sensitivity (Non-Tumoral Lesion, N=134)	Swin: 0.3905 $\pm$ 0.0566			CystoHier: 0.4602 $\pm$ 0.0457 (+0.0697)		
NST Specificity (Non-Suspicious Tissue, N=504)	Swin: 0.9630 $\pm$ 0.0034			CystoHier: 0.9563 $\pm$ 0.0155		

6 Grad-CAM Visual Explanations and Edge Deployment

6.1 Quantitative Anatomical Alignment via Grad-CAM IoU

Nhằm kiểm chứng tính trung thực giải phẫu học, chúng tôi thực hiện phân tích bản đồ nhiệt Grad-CAM trực tiếp trên Fine Head (trích xuất tại lớp chuẩn hóa cuối cùng của Swin Transformer, kích thước $7 \times 7 \times 768$) so sánh giữa mô hình **Swin Baseline** và **CystoHier** trên các mẫu có mặt nạ Ground-Truth của bác sĩ (Fig. 3).




Fig. 3. Visual explanation comparison using Grad-CAM heatmaps between Single-Task Swin Baseline and **CystoHier** across 5 fine-grained diagnostic classes with expert Ground-Truth masks: (a) Original WLC endoscopy image; (b) Ground-Truth mask (cyan); (c) Swin Baseline heatmap; (d) **CystoHier** heatmap showing predicted confidence and Grad-CAM IoU scores.

Đánh giá định lượng Grad-CAM IoU với ngưỡng cố định $T = 0,5$ (Table 12) cho thấy mô hình **CystoHier** đạt IoU trung bình $0,2356 \pm 0,0730$ so với Swin Baseline ($0,0500$), tương ứng mức tăng $+0,1856$. Đặc biệt trên phân lớp tổn thương ác tính *LowGradePapillary*, IoU tăng từ $0,0112$ lên $0,3778$ ($+0,3666$). Mô hình đề xuất giảm thiểu kích hoạt giả tại viền đen camera và vùng lóa sáng,

cho thấy sự tập trung cao hơn vào các vùng có mức độ tương đồng lớn hơn với Ground-Truth mask.

Table 12. Quantitative Grad-CAM IoU evaluation on Ground-Truth expert masks. Bold indicates the higher IoU score.

Fine-Grained Diagnostic Class	Parent Coarse Group	Evaluation Split	Swin IoU	CystoHier Conf.	CystoHier IoU	Gain (Δ IoU)
LowGradePapillary	Malignant	Test Hold-out	0.0112	0.9790	0.3778	+0.3666
AirBubble	Foreign bodies	Test Hold-out	0.0000	1.0000	0.2460	+0.2460
HighGradePapillary	Malignant	Test Hold-out	0.0556	1.0000	0.1717	+0.1161
UreteralOrifice	Landmarks	Test Hold-out	0.1644	0.9930	0.2050	+0.0406
ResectionScar	Landmarks	Test Hold-out	0.0187	1.0000	0.1777	+0.1590
Overall Mean	—	—	0.0500	0.9940	0.2356	+0.1856 (4.71 $\times$ rel.)

6.2 Edge Hardware Latency and Real-Time Throughput Benchmark

Đo lường thời gian thực thi trên phần cứng Apple Silicon MPS FP32 (28,23M tham số, dung lượng bộ nhớ cấp phát 110,8 MiB) được tổng hợp tại Table 13.

Table 13. Inference latency, throughput, and memory benchmark on edge hardware (MPS FP32).

Batch Size Configuration	Forward Model (ms/img)	Forward Throughput (FPS)	End-to-End Pipeline (ms)	Allocated Memory
Batch = 1 (Real-time Single Image)	12.08 $\pm$ 0.95 ms	82.78 FPS	15.00 $\pm$ 1.12 ms (66.67 FPS)	110.83 MiB
Batch = 8 (Mini-batch)	10.17 $\pm$ 0.42 ms	98.36 FPS	—	113.99 MiB
Batch = 32 (High Throughput)	9.95 $\pm$ 0.38 ms	100.46 FPS	—	128.00 MiB

Thông lượng suy luận toàn trình đo được là **66,67 FPS** (độ trễ 15,00 ms/ảnh), cho thấy mô hình hoàn toàn đáp ứng dự dả tài nguyên tính toán cho việc xử lý khung hình thời gian thực trong phẫu thuật nội soi.

7 Discussion and Limitations

Nghiên cứu xác lập sự tương hỗ mật thiết giữa các trụ cột kỹ thuật của **CystoHier**: (1) *Swin-Tiny* cung cấp không gian đặc trưng biểu mô đa phân giải; (2) *Smoothed Balanced Softmax* cân bằng phân phối theo số lượng bệnh nhân; (3) *Curriculum Hierarchy Warmup* giải phóng ràng buộc phả hệ sớm; (4) *Supervised Contrastive Regularization* co cụm cấu trúc chi tiết; và (5) *Hierarchical Marginalization* tận dụng xác suất từ phân lớp chi tiết để hiệu chỉnh nhóm cha.

Phân tích ma trận nhầm lẫn lâm sàng chỉ ra rằng các trường hợp chẩn đoán sai lệch giữa nhóm *Non-malignant* và *Malignant* (26/32 ảnh) chủ yếu do mô hình có xu hướng cảnh báo an toàn (*overcalling*) nhằm tránh bỏ sót các tổn thương tiền ung thư. Xu hướng dự đoán thận trọng này có thể hữu ích trong tầm soát nhằm giảm thiểu nguy cơ bỏ sót tổn thương; tuy nhiên, giá trị lâm sàng thực tế và tác động của dương tính giả cần được đánh giá trong các nghiên cứu tiền cứu.

Hạn chế và hướng phát triển: Mặc dù đã kiểm định thành công trên tập Lazo et al., nghiên cứu hiện tại vẫn mang tính chất hồi cứu trên cỡ mẫu ngoại kiểm 23 bệnh nhân. Các nghiên cứu tiếp theo cần mở rộng sang thử nghiệm tiền cứu đa trung tâm và khảo sát các kiến trúc Temporal Video Transformer cho chuỗi video liên tục.

8 Conclusion

Bài báo đã đề xuất khung phương pháp **CystoHier** kết hợp tinh chỉnh tách rời ba giai đoạn, **Curriculum Hierarchy Warmup** và **Hierarchical Marginalization** cho bài toán phân loại phân cấp nội soi bàng quang trên dữ liệu mất cân bằng dài đuôi CystoDS. Mô hình cải thiện nhất quán phân loại chi tiết (Fine Macro-F1 $0,6450 \pm 0,1105$) và tính nhất quán phủ hệ ($0,8952 \pm 0,0380$) trên tập kiểm định độc lập bệnh nhân, đồng thời duy trì khả năng phân loại nhị phân vững chắc (Binary AUROC $0,9986 \pm 0,0002$). Đánh giá zero-shot trên tập ngoại kiểm độc lập Lazo et al. khẳng định năng lực tổng quát hóa cross-dataset tốt, đặc biệt trên ảnh NBI và tổn thương NTL. Mô hình đạt thông lượng 66,7 FPS end-to-end trên phần cứng biên và cải thiện độ trùng khớp Grad-CAM IoU giải phẫu. Các kết quả này chứng minh tính khả thi của việc học phân cấp dài đuôi trong chẩn đoán hình ảnh nội soi bàng quang, trong khi các thử nghiệm tiền cứu đa trung tâm vẫn là bước cần thiết tiếp theo trước khi triển khai lâm sàng thực tế.

Acknowledgements. Nghiên cứu này được thực hiện tại Trường Đại học FPT, Phân hiệu Đà Nẵng. Các tác giả chân thành cảm ơn sự hỗ trợ học thuật và môi trường nghiên cứu từ nhà trường.

Conflict of Interest. Các tác giả tuyên bố không có xung đột lợi ích liên quan đến nội dung của bài báo này.

References

1. Lee, T.J., Qiu, L., Long, J., Mach, K.E., Peterson, D., Yao, Q., Shkolyar, E., Islam, M.T., Xing, L., Liao, J.C.: CystoDS: a multiclass endoscopy image dataset for artificial intelligence-assisted bladder cancer detection. *Scientific Data* **13**(1), 1–14 (2026). <https://doi.org/10.1038/s41597-026-06887-z>
2. Shkolyar, E., Jia, X., Chang, T.C., Trivedi, D.V., Mach, K.E., Meng, M.Q.H., Xing, L., Liao, J.C.: Augmented Bladder Tumor Detection Using Deep Learning. *European Urology* **76**(6), 714–718 (2019). <https://doi.org/10.1016/j.eururo.2019.08.032>
3. Wu, S., Chen, X., Pan, J., Zhou, Z., Shen, C., Wang, Z., Huang, J.: An Artificial Intelligence System for the Detection of Bladder Cancer via Cystoscopy: A Multi-center Diagnostic Study. *Journal of the National Cancer Institute* **114**(2), 220–227 (2022). <https://doi.org/10.1093/jnci/djab179>

4. Lazo Sanchez, J., Rosa, B., Cattellani, M., Ferro, M., De Cobelli, O., Mateus, D.: Semi-supervised Bladder Tissue Classification in Multi-Domain Endoscopic Images. *IEEE Transactions on Biomedical Engineering* **70**(10), 2822–2833 (2023). <https://doi.org/10.1109/TBME.2023.3265679>
5. Jia, X., Shkolyar, E., Laurie, M.A., Mach, K.E., Meng, M.Q.H., Liao, J.C., Xing, L.: Tumor detection under cystoscopy with transformer-augmented deep learning algorithm. *Physics in Medicine & Biology* **68**(16), 165013 (2023). <https://doi.org/10.1088/1361-6560/ace499>
6. Abd El-Aziz, A.A., Mahmood, M.A., Abd El-Ghany, S.: EfficientNet-B3-Based Automated Deep Learning Framework for Multiclass Endoscopic Bladder Tissue Classification. *Diagnostics* **15**(19), 2515 (2025). <https://doi.org/10.3390/diagnostics15192515>
7. Wang, Y., Liang, H., Zhang, Y., et al.: Artificial intelligence diagnostics for bladder tumor identification and grade prediction depend on narrow band imaging cystoscopy. *iScience* **29**(2), 114309 (2026). <https://doi.org/10.1016/j.isci.2025.114309>
8. Zhang, F., An, J., Zhao, L., et al.: Artificial Intelligence-Powered Cystoscopy Diagnostic Support System: Clinical Application of Multiarchitecture Deep Learning Models. *Journal of Endourology* **40**(8), 925–934 (2026). <https://doi.org/10.1177/08927790261450807>
9. Liu, Z., Lin, Y., Cao, Y., Hu, H., Wei, Y., Zhang, Z., Lin, S., Guo, B.: Swin Transformer: Hierarchical Vision Transformer using Shifted Windows. In: *Proceedings of the IEEE/CVF International Conference on Computer Vision (ICCV)*, pp. 10012–10022 (2021). <https://doi.org/10.1109/ICCV48922.2021.00986>
10. Ren, J., Yu, C., Ma, X., Zhao, H., Yi, S.: Balanced Meta-Softmax for Long-Tailed Visual Recognition. In: *Advances in Neural Information Processing Systems (NeurIPS)*, vol. 33, pp. 4175–4186 (2020)
11. Khosla, P., Teterwak, P., Wang, C., Sarna, A., Tian, Y., Isola, P., Maschinot, A., Liu, C., Krishnan, D.: Supervised Contrastive Learning. In: *Advances in Neural Information Processing Systems (NeurIPS)*, vol. 33, pp. 18661–18673 (2020)
12. Kang, B., Xie, S., Rohrbach, M., Yan, Z., Gordo, A., Feng, J., Kalantidis, Y.: Decoupling Representation and Classifier for Long-Tailed Recognition. In: *International Conference on Learning Representations (ICLR)* (2020)
13. Menon, A.K., Jayasumana, S., Rawat, A.S., Jain, H., Veit, A., Kumar, S.: Long-tail learning via logit adjustment. In: *International Conference on Learning Representations (ICLR)* (2021)
14. He, K., Zhang, X., Ren, S., Sun, J.: Deep Residual Learning for Image Recognition. In: *Proceedings of the IEEE Conference on Computer Vision and Pattern Recognition (CVPR)*, pp. 770–778 (2016). <https://doi.org/10.1109/CVPR.2016.90>
15. Xie, S., Girshick, R., Dollár, P., Tu, Z., He, K.: Aggregated Residual Transformations for Deep Neural Networks. In: *Proceedings of the IEEE Conference on Computer Vision and Pattern Recognition (CVPR)*, pp. 1492–1500 (2017). <https://doi.org/10.1109/CVPR.2017.634>
16. Sun, K., Xiao, B., Liu, D., Wang, J.: Deep High-Resolution Representation Learning for Human Pose Estimation. In: *Proceedings of the IEEE/CVF Conference on Computer Vision and Pattern Recognition (CVPR)*, pp. 5693–5703 (2019). <https://doi.org/10.1109/CVPR.2019.00584>